Armando Bisogno

Una intelligenza fantastica

Riflessioni aperte sull'intelligenza artificiale

Il presente testo è distribuito da Armando Bisogno
con licenza CC BY-NC-SA 4.0.

È possibile condividere, riprodurre, distribuire, comunicare al pubblico, esporre in pubblico, rappresentare, eseguire e recitare, modificare, remixare, trasformare il materiale e basarsi su di esso per altre opere con qualsiasi mezzo e formato, solo per scopi non commerciali.
Il licenziante non può revocare questi diritti fintanto che siano rispettati i termini della licenza alle seguenti condizioni.

Attribuzione: riconoscere una menzione di paternità adeguata, fornire un link alla licenza e indicare se sono state effettuate delle modifiche.

Stessa licenza: se si remixa o trasforma il materiale o se ci si basa su di esso, si devono distribuire i contributi con la stessa licenza del materiale originario.

Divieto di restrizioni aggiuntive: non è possibile applicare termini legali o misure tecnologiche che impongano ad altri soggetti dei vincoli giuridici su quanto la licenza consente loro di fare.

Per informazioni:
www.armandobisogno.it
arbisogno@unisa.it

ver. 2.0 – pubblicato il 13.11.26

INDICE

Premessa

1 Un (fantastico) collaboratore magico
2 Empatia canaglia
3 *Black box* naturali
4 Dio prompt
5 Un'altra specie simbolica (che scrive)
6 Non fidarsi (delle immagini) è meglio?
7 Vieni avanti creativo
8 Rossana, Cristiano e Cyrano
9 Impalcature e protesi
10 Pensare stanca. Per fortuna
11 L'ora di pranzo
12 *Do you remember?*
13 Un po' di sintesi e un augurio

Antologia

Premessa

Potremmo chiederci, preliminarmente e con argomenti convincenti, se queste riflessioni meritassero di diventare l'ennesima pubblicazione sull'intelligenza artificiale. Quando avrete finito di leggerle, i dubbi potrebbero addirittura aumentare. Ciò che invece è più difficile mettere in discussione è che l'IA meriti un'analisi filosofica. Non solo infatti l'IA occupa una parte rilevante del dibattito e dell'immaginario contemporanei, due spazi che la filosofia da sempre abita ed esplora, ma in più tocca direttamente o collateralmente temi che sono da sempre di competenza della filosofia: solo per evidenziarne (in corsivo) alcuni, l'IA è una *macchina* che pensiamo abbia una *intelligenza* perché, per esempio, sa usare il *linguaggio*, dando vita a una forma di *scrittura* così elegante da farci credere che abbia una *coscienza* e che sia *creativa*, il che implica che la si possa considerare come un *soggetto* portatore *di diritti* e di implicazioni *etiche*. Tutti argomenti che non sono astrazioni filosofiche lontane e teoriche ma che caratterizzano concretamente in ogni momento la nostra vita, anche ora: perché io che ho *scritto* e voi che state *leggendo* queste pagine siamo *soggetti coscienti*, in

possesso di *facoltà linguistiche* che ci rendono capaci di produrre e leggere scrittura; al contempo, avete il *diritto* di sapere e io ho il dovere *etico* di dire che quello che state leggendo in questa premessa è integralmente frutto del mio lavoro e della mia *creatività* ma che, nelle pagine seguenti, mi sono spesso confrontato con ChatGPT e soprattutto Claude in fase di elaborazione e di scrittura del testo.

Nella sua *Apologia*, Platone racconta il processo di Socrate e, per la precisione, il modo con il quale Socrate si è difeso in tribunale dalle accuse che gli erano state mosse e che, poi, lo avrebbero portato alla morte. Alla fine della sua arringa, dopo la prima votazione di condanna, Socrate ammette che in fondo, se si trova in quella spiacevole situazione, è anche un po' colpa sua. Tutto il processo nasce infatti dal suo atteggiamento: è lui che continuamente interroga i suoi concittadini su ciò che è giusto o non giusto fare; che li spinge con insistenza a prendere consapevolezza di sé e a lavorare per il meglio e per il bene, personale e della città; è lui che con tante altre quotidiane sollecitazioni pungola Atene ogni giorno. È proprio questo suo fare, per alcuni irritante, che gli ha attirato addosso le inimicizie di quanti lo hanno accusato e di chi sta spingendo l'assemblea a votargli contro. Per questo, aggiunge, qualcuno potrebbe consigliargli di sfuggire alla condanna promettendo che starà in silenzio, che non incalzerà più nessuno con i suoi ragionamenti e le sue domande. Questo però è un consiglio che lui sa di non poter seguire perché è convinto che "una vita non esaminata non è degna di essere vissuta" (*Apologia di Socrate*, 38a).

Non voglio suggerire che una vita che non esamini cosa sia l'IA non sia degna di essere vissuta; l'esortazione di Socrate è più ampia e più profonda: è

l'invito a vivere, sempre, il proprio tempo con consapevolezza, interrogandosi su ciò che riempie l'orizzonte. E tra le cose che lo riempiono oggi, l'IA ha un peso notevole. Probabilmente la sua presenza condizionerà il nostro mondo in modo radicale, modificando sempre di più il mercato del lavoro e la nostra vita quotidiana. O forse, esattamente all'opposto, i suoi enormi costi di gestione la faranno scoppiare come è successo in passato ad altre bolle finanziarie. In entrambi i casi, usarla o, peggio, subirla senza farsi qualche domanda su cosa ci racconti di noi significa perdere un'occasione per capire qualcosa di più dell'epoca che viviamo ma soprattutto di come siamo fatti. Come ha scritto recentemente nella sua *Magnifica humanitas* papa Leone XIV, "Siamo chiamati a interrogarci sul grande cantiere della nostra epoca: cosa stiamo costruendo?" [1].

Queste pagine sono il tentativo di condensare riflessioni sulla IA che, in questi mesi, mi è capitato di leggere, scrivere, discutere o semplicemente portare e sviluppare tra me e me. Ho definito queste riflessioni 'aperte' perché la mia speranza è che possano essere una piattaforma di partenza, una serie di spunti da discutere e sviluppare con colleghe e colleghi, studentesse e studenti, comunità e persone interessate in appuntamenti condivisi.

Questa che state leggendo è una seconda versione; aggiunge nuove riflessioni e integra le altre con temi che ho affrontato in *Macchine Pensanti* tra la primavera e l'autunno del 2026: il rapporto tra IA e religione, il rischio della dipendenza, la necessità di allenare il pensiero, la memoria. Per queste pagine il confronto con Claude è stato ancora più stretto e il testo che state per leggere è il frutto di una interazione

profonda con tutti gli strumenti di IA che utilizzo nel mio lavoro.

Per rendere la lettura più fluida, ho preferito non inserire nel corpo del testo le citazioni ma riportarle tutte in una antologia alla fine, alla quale rimandano volta per volta i numeri tra parentesi quadre.

1. Un (fantastico) collaboratore magico

L'oracolo

Per la stragrande maggioranza degli utenti (me compreso), il rapporto con l'IA segue uno schema molto semplice e lineare: apriamo l'*app* o raggiungiamo il sito *web*, facciamo una domanda e restiamo in attesa che, parola per parola, arrivi la risposta. Cosa succeda sui *server* di questi *software* mentre stiamo lì ad aspettare, come facciano cioè a rispondere a tono e con competenza è, per quasi tutti noi, un mistero. Fatto sta che lo fanno e che molto spesso le loro risposte sembrano adeguatissime e molto ben curate: traduzioni, *tutorial* per l'uso di una *app* o di un *software*, ricette di cucina, valutazione di analisi mediche, scrittura di *mail* importanti etc. Questa particolare condizione (interroghiamo una 'entità' che non sappiamo come funzioni ma che ci fornisce risposte adeguate) è un 'dispositivo' che conosciamo molto bene. Beth Singler da tempo si occupa di questi temi e del *Religious Frame* che applichiamo quando pensiamo a questa tecnologia [2]: ci relazioniamo alla IA come faremmo con un oracolo divino, interrogandolo in attesa di risposte, senza sapere come e perché riesca a fornircele ma fidandoci quasi ciecamente

di ciò che ci dice. L'idea dell'oracolo, che già nel 2023 Gino Roncaglia (docente a La Sapienza di Roma e da sempre attentissimo osservatore del mondo digitale e delle sue implicazioni umanistiche) aveva esplorato è particolarmente interessante perché ci racconta di come il nostro tempo stia, per certi versi, tornando all'antico ma in modo nuovo [3]. Nelle società della oralità, il sapere non era condiviso o distribuito ma custodito; uno o pochissimi erano i depositari delle conoscenze, per accedere alle quali era necessaria una interrogazione: chi voleva risposte doveva fare una domanda al detentore del sapere e riuscire a comprendere e usare al meglio il responso. Walter J. Ong, in *Oralità e scrittura*, descrive così la trasmissione delle competenze nelle culture orali: un sistema nel quale la conoscenza è in mano a specialisti, che la condividono con chi, come, quanto e quando vogliono e dalla quale escludono per principio chi non è ritenuto degno di apprendere [4]. La forma paradigmatica di tutto questo è, appunto, l'oracolo: un'entità che sa, che risponde ma che non lascia che i 'profani' comprendano attraverso quali processi viene elaborata la sua risposta.

La nascita della scrittura ha modificato sostanzialmente questa logica. Il sapere era ancora custodito e concentrato in un solo posto che però non era più l'interiorità oscura e impenetrabile del saggio ma la somma delle pagine di un testo o di tutti i testi contenuti in un solo posto: è la nascita del modello enciclopedico-bibliotecario. In questo sistema, cambiano le competenze che servono a chi vuole risposte e desidera accedere alla conoscenza: una volta ottenuto accesso 'fisico' alle stanze e ai volumi di una biblioteca (privilegio, anche qui, per lungo tempo riservato a pochi) era necessario sapersi muovere attraverso quel labirinto di pagine o di scaffali, reali e virtuali; saper leggere, cercare, collegare contenuti, farne sintesi. Non più dunque una

relazione di affidamento a una risposta che proviene da un oscuro procedimento interiore del sapiente ma una progressiva acquisizione di competenze 'esplorative', che responsabilizzano l'individuo. Questo modello ha funzionato per venti secoli: dalle *Etymologiae* di Isidoro di Siviglia, scritte nel VII secolo d. C., a *Wikipedia*, sono cambiati i supporti (dalla carta al digitale), i principi di autorialità (dalle competenze verticali degli specialisti alla produzione comunitaria degli *editor* wikipediani) e le *policy* di accesso (diventate via via sempre più inclusive, pubbliche e aperte) ma non la logica di fondo: se non sai come e dove cercare, questi labirinti del sapere non ti danno risposte.

L'IA sta cambiando invece proprio questa logica, tornando apparentemente al passato. È stata addestrata su un patrimonio analogo a quello di una biblioteca/enciclopedia: testi, foto, video, codice che hanno contribuito all'addestramento, modificando i parametri del modello: non sono necessariamente conservati al suo interno come documenti da recuperare. Per avere risposte o per ottenere un prodotto, però, non mi viene chiesto di esplorare l'IA come farei con una biblioteca o di studiare un testo; devo invece interrogare un 'soggetto' che (apparentemente) sa tutto e dal quale ricevo una risposta. Questo significa che siamo davanti a una nuova 'stagione oracolare'? Non esattamente.

La relazione con l'oracolo richiede una dimensione di sacralità del sapere e, di conseguenza, una particolare lettura del ruolo di chi lo possiede e lo distribuisce; l'oracolo è un soggetto elitario, al vertice di una catena sociale e politica che lo individua come referente e per questo, per questa sua eccezionalità, non si concede sempre e a tutti. L'IA, al pari di un oracolo, sa moltissime cose e non ci spiega il modo con il quale le rielabora per darci risposte, quindi per noi è parzialmente avvolta nel mistero; a differenza di un oracolo, però, è continuamente, sempre e

silenziosamente al nostro servizio: c'è del mistero rispetto a come funziona ma non c'è distanza sacrale. Per questo, più che un oracolo l'IA ci appare cioè come un 'collaboratore magico', come uno strumento avanzato che funziona in modo straordinario. (Sulle radici, anche religiose, di questo modo di relazionarci all'IA torneremo nella quarta riflessione). Cerchiamo ora di spiegare meglio i due termini di questa definizione.

Perché un collaboratore

Da sempre costruiamo oggetti artificiali, vale a dire protesi e strumenti che ci permettono di fare più di quanto potremmo fare se ci affidassimo soltanto alle nostre facoltà naturali. In questo senso, come sostiene Bernard Stiegler in *La Technique et le Temps*, la tecnica nasce da un 'difetto' originario dell'essere umano, che è costitutivamente un essere mancante, un *être-en-défaut*: non possiede, per natura, un corredo stabile di difese, istinti e capacità sufficienti a garantirgli immediatamente la sopravvivenza. Stiegler illustra questa condizione riprendendo un mito raccontato da Platone nel *Protagora* [5]. Secondo il mito, quando giunse il momento di far nascere le creature mortali, gli dèi affidarono a Prometeo ed Epimeteo il compito di distribuire tra gli esseri viventi le diverse qualità naturali. Epimeteo chiese a Prometeo di poter svolgere da solo questa distribuzione, promettendo poi di fargliela controllare. Così assegnò ad alcuni animali la forza, ad altri la velocità; ad alcuni diede artigli, zanne o corna, ad altri pellicce, ali o gusci. Cercò inoltre di mantenere un equilibrio tra le specie: gli animali più deboli ricevettero mezzi di fuga o di protezione, quelli più forti una minore capacità di riproduzione, in modo che nessuna specie potesse distruggere completamente le altre. Alla fine, però, Epimeteo si accorse di aver commesso un errore: aveva consumato tutte le facoltà

disponibili e aveva lasciato l'uomo completamente sprovvisto. L'essere umano nacque così nudo, indifeso, senza artigli, senza pelliccia, senza velocità, senza un istinto naturale capace di guidarlo con sicurezza nel mondo. A differenza degli altri animali, non possedeva cioè una dotazione biologica sufficiente a proteggerlo. Prometeo, vedendo l'uomo in questa condizione di radicale mancanza, decise di rimediare rubando a Efesto e ad Atena il fuoco e il sapere tecnico, cioè le arti che permettono di costruire strumenti, abitazioni, vestiti, armi e mezzi di sopravvivenza. Donò così agli uomini la *techne*, grazie alla quale essi poterono compensare la loro debolezza naturale attraverso l'invenzione artificiale. L'essere umano, nella lettura di Stiegler, non possiede per natura strumenti che lo rendano autosufficiente e dunque vive nella continua necessità di completarsi attraverso ciò che produce. La tecnica diviene così il modo in cui riusciamo a supplire, inventando e costruendo, alla nostra condizione di 'mancanza originaria'. Se la tecnica nasce da una mancanza, allora ogni strumento è anche un ritratto in negativo di chi lo ha inventato: racconta che cosa ci mancava, che cosa desideravamo, che cosa eravamo disposti a delegare. È questa, in fondo, la convinzione che regge tutte le riflessioni che seguono: interrogarsi su una tecnologia significa sempre, prima o poi, interrogarsi su di noi; e una tecnologia che ci imita da vicino come l'IA rende questo esercizio semplicemente inevitabile.

Queste protesi artificiali, che usiamo per superare il nostro essere 'difettosi' non sono tutte uguali, per motivi diversi. Possiamo per esempio distinguerle e classificarle sulla base del loro grado di complessità e autonomia. Un libro è una protesi, nella misura in cui ci permette di preservare la memoria di informazioni e farla circolare,

molto più di quanto potremmo fare oralmente. Anche un orologio analogico è una protesi, perché ci aiuta a tener conto del tempo che passa con molta più precisione di quanto potremmo fare con altri metodi. Le due protesi, però, sono molto diverse dal punto di vista della loro autonomia di vita. Il libro è infatti un oggetto inerte, che vive e si muove solo se qualcuno agisce, se qualcuno lo apre, lo sfoglia, lo sposta. Un orologio, invece, una volta ricevuto un primo *input* (la carica manuale o una pila) funziona *come se* avesse vita propria. Per lungo tempo, nel corso dei secoli, le tecnologie più avanzate sono state quelle capaci di avere un più o meno alto grado di autonomia sul versante meccanico e del movimento: la leva, la carrucola, il mulino ad acqua o a vento, la locomotiva, il motore, i bracci meccanici delle catene di montaggio e così via.

L'arrivo delle tecnologie informatiche non ha modificato questa logica ma ne ha spostato il fuoco; non più strumenti meccanici ma a supporto delle nostre capacità di calcolo e di produzione di contenuti. I *computer*, nati per gestire enormi quantità di dati e di calcolo, si sono nel tempo affermati come protesi di produzione reversibile: li usiamo cioè per dare vita a contenuti (testi, immagini, audio, etc.) che possiamo non solo generare con una rapidità a noi altrimenti preclusa, ma anche correggere, rifare, disfare all'infinito, tornando sui nostri passi senza il costo che la stessa operazione avrebbe sulla materia analogica (la pagina scritta a penna, la pellicola già impressa, etc.).

In questa linea evolutiva della tecnologia, descritta un po' grossolanamente, l'IA pone uno scarto: una tecnologia che, oltre a potenziare le nostre capacità fisiche, di calcolo e di produzione, funziona anche *come se* pensasse, parlasse e interagisse. Questo ci induce a viverla come qualcosa di più di un semplice strumento: nella

nostra esperienza assume il ruolo di un collaboratore, senza per questo cessare di essere una tecnologia. Facciamo un esempio: per diversi giorni ho lavorato per configurare Claude Code, un ambiente di lavoro IA più complesso delle semplici *chat* di IA che di solito usiamo; per usarlo al meglio per il modo in cui lavoro io, dovevo infatti collegarlo ai *file* sui quali lavoro *in cloud* ma l'operazione è particolarmente complessa, soprattutto per me che ho scarsissime competenze informatiche. Io e Claude Code *abbiamo lavorato* per quasi due giorni alla sua stessa configurazione e, alla fine, *ce l'abbiamo fatta*. 'Abbiamo lavorato' e 'ce l'abbiamo fatta' sono le uniche espressioni che posso usare per rendere l'idea di ciò che è successo: una lunga interazione, nella quale io riportavo in *chat* a Claude quali problemi incontravo nei vari passaggi che mi stava suggerendo e Claude tentava di risolverli, riguardando il codice, facendo tentativi di modifica, suggerendomi interventi. E quando io mi trovavo davanti a messaggi di errore completamente incomprensibili o quando Claude stesso mi dava istruzioni che non capivo, gli chiedevo di guidarmi o gli mostravo *screenshot* per farmi spiegare cosa cliccare e dove. E Claude, senza mai perdere la pazienza, di giorno, di notte, di domenica, col caldo o al bar mi ha sempre supportato, fino a che non *ci siamo riusciti*. È proprio questo insieme di capacità agentiche e relazionali sempre disponibili e sempre 'sul pezzo' che rende l'IA non uno strumento ma, come detto, un 'collaboratore': non una protesi della memoria o del calcolo, non solo uno strumento con un grado di autonomia di movimento elevata, non un potenziamento di nostre facoltà deboli ma qualcosa che assomiglia, molto, a un soggetto con il quale interloquire e, soprattutto, dal quale ottenere servizi e risultati nei tempi e nei modi che decidiamo noi e che ci sono più comodi; una *app* che, nella sua schermata di

avvio, ogni giorno ci chiede se e come può aiutarci; una enciclopedia parlante e dialogante; un supporto completamente diverso dai *tutorial* che trovo su *YouTube* e che posso vedere e rivedere mille volte ma che non posso interrogare se un passaggio non mi è chiaro, se sul mio *computer* quella istruzione non funziona e così via. L'IA co-produce *output* dentro una relazione dialogica; non esegue soltanto un comando ma partecipa alla costruzione del risultato rispondendo, riformulando, proponendo, correggendo, con una disponibilità assoluta. Non lavora solo *per* noi; è *con* noi quando portiamo avanti il nostro *labor*, la nostra attività. Dunque, con-labora.

Perché è magico

Nel paragrafo 17 della *Monadologia*, Leibniz propone un esperimento mentale che vale la pena raccontare per intero. [6] Immaginiamo, dice Leibniz, una macchina così sofisticata da essere capace di pensare, di sentire e di avere percezioni. Ora immaginiamo di ingrandirla, mantenendo le stesse proporzioni, fino a renderla abbastanza grande da entrarci dentro, come in un mulino. Fatto ciò, proviamo ad aggirarci al suo interno e a guardare un po' in giro. Cosa vedremmo? Troveremmo pezzi che si spingono a vicenda: ingranaggi, leve, meccanismi. Nulla di più. Nulla che assomigli a una percezione, a un pensiero, a qualcosa che *sente* di stare pensando. La conclusione che Leibniz trae dal suo esperimento è netta: la percezione non si lascia spiegare mediante la sola disposizione meccanica delle parti. È però una tesi filosofica di Leibniz, non una dimostrazione sperimentale dell'impossibilità che un sistema artificiale abbia esperienze soggettive.

Se anche noi entrassimo, come Leibniz, nel 'mulino' della IA, cosa troveremmo? Qualcosa di idealmente analogo agli ingranaggi del mulino, anche se molto più astratto. Per capirlo dobbiamo fare un passo indietro e seguire una storia un po' informatica e un po' linguistica. A partire dalla metà del Novecento, alcuni studiosi cominciarono a chiedersi se fosse possibile descrivere il linguaggio non come un insieme di regole grammaticali ma come un sistema di probabilità. L'idea di fondo è quella che il linguista John Firth formulò nel 1957 [7]: il significato di una parola è dato dalle parole che le stanno intorno. In una lingua, infatti, non tutte le parole hanno la stessa probabilità di seguire un'altra parola. Dopo 'buona' è molto più probabile trovare 'notte' o 'fortuna' che 'margherita'. Dopo 'il' è molto più probabile trovare un sostantivo che un verbo. Claude Shannon, il matematico che ha fondato la teoria dell'informazione (e al cui nome è dedicato, secondo una interpretazione diffusa, il modello di IA di Anthropic), aveva già mostrato negli anni '40 che il linguaggio poteva essere modellato statisticamente: date le parole precedenti, si può calcolare la probabilità di ciascuna parola successiva. I primi sistemi costruiti su questa base erano rudimentali: calcolavano la probabilità di una parola sulla base delle due o tre parole immediatamente precedenti. I sistemi attuali (i *Large Language Models*, che indicherò con l'acronimo LLM e, in senso generico, userò come sinonimo di IA) hanno portato questa logica a una scala che Shannon non avrebbe potuto immaginare. Vengono addestrati su miliardi di parole, vale a dire su libri, articoli, pagine web, conversazioni, e durante questo processo aggiustano un numero elevatissimo di parametri matematici interni, che nei grandi modelli può arrivare a miliardi, imparando a stimare una distribuzione di probabilità sui *token*

successivi dato un contesto. In fase di generazione, il sistema può selezionare il *token* più probabile oppure campionare tra più possibilità: il testo non nasce necessariamente dalla scelta, ogni volta, dell'unica continuazione più probabile. Si può cogliere qui una suggestiva affinità, senza equiparare le due teorie, con una intuizione che Wittgenstein sviluppa nelle Ricerche Filosofiche: il significato non risiede in una essenza nascosta della parola, ma nel suo uso, nel contesto vivo in cui appare [cit. in 7]. Nei modelli neurali, i *token* vengono rappresentati mediante vettori numerici appresi, che codificano relazioni utili a elaborare il linguaggio; il loro significato operativo dipende anche dal contesto e non coincide semplicemente con una posizione fissa in un vocabolario.

Per capire meglio cosa tutto questo significhi, prendete una frase qualsiasi e fermatevi a metà. Qualsiasi frase: quella che state leggendo in questo momento, la prima riga di un romanzo che avete sul comodino, un titolo di giornale. Fermatevi all'ultima parola che avete letto e chiedetevi: qual è la parola che viene dopo? Vi accorgerete che non la state cercando ma che siete in grado, con un buon margine di approssimazione, di prevederla. E la riuscite a prevedere perché, senza accorgervene, state applicando esattamente il meccanismo che abbiamo descritto prima: state attivando tutto ciò che sapete sul contesto, sul genere del testo, sul tono, sulle parole che avete già incontrato, e state calcolando (intuitivamente, in modo del tutto inconsapevole) qual è la continuazione più probabile. Immaginiamo che la frase sia: 'La situazione era diventata insostenibile e qualcuno avrebbe dovuto'. Se state leggendo un romanzo realistico, per esempio una storia d'amore, un dramma familiare o le vicende di un gruppo di amici, quasi certamente state aspettando 'dire' o 'fare'

o 'intervenire'. Forse 'parlare' o 'agire'. Il vostro cervello ha cioè già scartato centinaia di opzioni e ne ha tenute poche, quelle che, in quel tipo di testo e in quel tipo di situazione narrativa, sono le più plausibili, cioè quelle che statisticamente si ripetono con maggiore probabilità in romanzi e contesti narrativi di quel genere. Se però, lasciando la stessa identica frase e lo stesso identico inizio ('La situazione era diventata insostenibile e qualcuno avrebbe dovuto'), cambiate il contesto, per esempio la considerate all'interno di una pagina di un romanzo *fantasy* che parla di una creatura che sta devastando un villaggio, l'ipotesi 'dire' non sembra, come prima, la più probabile. Forse vi convince di più 'combattere' o 'sacrificarsi'. Il tono epico del genere, la presenza del mostro nelle righe precedenti, l'atmosfera che il testo ha costruito parola dopo parola: tutto questo ha spostato la vostra distribuzione di probabilità. Andiamo ancora oltre. Stessa frase ma ora il testo che state leggendo è un romanzo medievale nel quale, qualche riga prima, si parlava di selvaggina frollata da giorni in una dispensa mal ventilata. Adesso potreste aspettarvi 'cucinarlo prima che andasse a male' o 'scartarlo' o persino 'servirlo comunque'. Ancora. Pensiamo la stessa frase ma in un giallo, subito dopo la scoperta di un cadavere. Qui dopo 'La situazione era diventata insostenibile e qualcuno avrebbe dovuto', il verbo che ci viene subito in mente è probabilmente 'parlare', che dunque torna come nel primo caso ma con una sfumatura completamente diversa perché adesso significa 'confessare', 'accusare' o 'rompere un silenzio che pesa'.

Possiamo estendere intuitivamente l'esempio ai *token*, che possono corrispondere a parole intere, parti di parole, segni di punteggiatura o altri segmenti di testo. La segmentazione effettiva dipende però dal sistema di tokenizzazione: la sillaba o il frammento che

pronunciamo non coincide necessariamente con un *token* del modello. Se in aula, alla fine della mia lezione, io dicessi 'sono molto stanco, non vedo l'ora di tornare a cas' e mi fermassi troncando la parola, la maggior parte delle studentesse e degli studenti in aula penserebbero che lì manca solo una 'a' per completare la parola 'casa'; difficilmente invece penserebbero che io sto per dire 'casetta mia'. Perché? Perché il contesto (un'aula universitaria) e il *Tone of Voice* mai eccessivamente informale che di solito utilizzo quando parlo sono i testi che li hanno 'addestrati' a pensare che non userei mai una formula così colloquiale nel parlare.

Tanto nel caso delle frasi da completare quanto in quello del frammento di parola 'cas', non esiste dunque una risposta giusta in assoluto alla domanda 'qual è la parola o la parte di parola successiva?'; esiste un ventaglio di risposte probabili dato quel contesto. E il contesto non è solo le ultime tre parole. È tutto: il genere, il tono, i personaggi, le pagine precedenti, persino il fatto che siate lettori di romanzi o di manuali tecnici. La probabilità non è una proprietà della parola isolata. È una proprietà della parola in relazione a tutto ciò che la circonda. Quando cominciamo una conversazione con un LLM o, meglio ancora, quando utilizziamo ambienti più ampi ai quali forniamo istruzioni complesse (come avviene per esempio oggi con Claude Code) stiamo facendo esattamente questo: stiamo fornendo un contesto. Se chiediamo 'Aiutami a scrivere una *mail* formale al mio capo', spostiamo la distribuzione di probabilità del sistema verso un certo registro linguistico, una certa struttura, un certo vocabolario. Se invece chiediamo 'Scrivi una scena in cui un commissario di Polizia svogliato interroga un presunto colpevole', spostiamo quella distribuzione in tutt'altra direzione, cioè verso il genere *noir*, con un dialogo che prevede pause, allusioni,

termini descrittivi che richiamano la lentezza del commissario che non vorrebbe stare lì, espressioni che raccontano sospetto, accusa e così via. Se come base di informazioni forniamo tutte le nostre *mail* ufficiali di lavoro stiamo scegliendo un certo *Tone of Voice*; se invece alleghiamo solo le conversazioni un po' stupide con gli amici, ne stiamo selezionando un altro, e così via.

Per chiarire ancor meglio il senso di questo meccanismo, c'è un caso limite che vale la pena nominare, perché illumina tutto il ragionamento per contrasto: la poesia. Se molta prosa si appoggia su aspettative riconoscibili, una parte importante dell'effetto poetico nasce anche dalla loro trasformazione o violazione; naturalmente non tutta la prosa è prevedibile, né ogni poesia cerca l'improbabile. Quando Leopardi chiude *L'Infinito* con "il naufragar m'è dolce in questo mare", quello che ci colpisce è proprio il contrasto tra ciò che di solito ci saremmo aspettati, cioè l'esito più probabile, e ciò che invece sceglie il poeta: un 'naufragare' infatti è per noi collegato di solito ad 'affogare', 'perdersi', 'morire in acqua' e in generale a contesti cupi; solitamente cioè non è 'dolce'. Il nostro cervello immagina i due termini molto lontani, in zone diverse dello 'spazio probabilistico'; trovarli vicini produce dunque uno *shock* semantico che è, di fatto, il fascino del verso. La poesia può dunque lavorare contro le nostre aspettative, scegliendo accostamenti inattesi per produrre significati che una formulazione più convenzionale non avrebbe generato. È una chiave di lettura estetica, non una legge statistica generale della scrittura poetica.

A questo punto, dopo aver tentato di spiegare (in maniera molto sommaria) come funziona un LLM e sulla base di quale meccanismo statistico l'IA ci risponde a tono e in modo coerente, l'effetto-magia che proviamo quando

vediamo un testo generarsi parola per parola dopo il nostro *prompt* dovrebbe essersi quasi dissolto: siamo entrati nel mulino e, come Leibniz, non vi abbiamo trovato un pensiero né qualcosa di magico ma un meccanismo statistico; un meccanismo sofisticatissimo ma pur sempre un meccanismo. E allora in che senso e perché continuo a chiamare 'magica' l'IA? Non perché ignoriamo il principio di funzionamento ma perché questa conoscenza del principio non ci consente di prevedere né di spiegare fino in fondo l'*output* che alla fine ci troviamo sul *monitor*. Sappiamo in virtù di quale logica generale l'IA sceglie la parola successiva, ma non sappiamo dire perché, mettendo in fila milioni di queste scelte, esca fuori proprio quel testo. Detto in altre parole: anche se continuo a studiare i meccanismi che sono alla base di queste 'macchine', ogni volta che Claude Code (lo raccontavo nel precedente paragrafo) mi guida nella configurazione di una operazione complessa, interagendo con me e con i miei limiti, mi sembra di assistere a qualcosa di straordinario; come succede, in fondo, nei trucchi dei grandi maghi: conoscere il principio dell'illusione non ci permette di prevederne l'effetto né di disinnescare lo stupore quando il 'trucco' si compie davanti a noi, come una magia.

Una intelligenza fantastica

L'IA ci appare dunque come un collaboratore: pur restando un sistema tecnico, e non un soggetto umano, si pone dinanzi a noi con le modalità dialogiche di qualcuno che ci aiuta; ed è magico non perché dei suoi meccanismi non sappiamo nulla ma perché conoscerne la regola non basta a spiegarne i risultati e a disinnescare la nostra meraviglia dinanzi a essi. Per dar corpo a una

definizione completa di come appare oggi a noi utenti questa tecnologia collaborativa e magica, è necessario secondo me un altro aggettivo, che provo a spiegare.

Da sempre la filosofia ha distinto due piani di lettura della realtà: come essa ci appare e come è. Per spiegarlo, prendiamo qualche esempio tratto dal *De Rerum Natura* di Lucrezio. Se guardiamo un lungo porticato, le colonne, pur essendo tutte di identica altezza, ci sembreranno progressivamente più piccole. Se osserviamo la parte inferiore di un cavallo fermo nel fiume, ci sembrerà trascinato via dalla corrente. Le navi in porto, viste da chi non conosce il mare, sembrano spezzate dalla superficie dell'acqua [8]. Lo scopo di Lucrezio è mostrare, con questi esempi, che quando guardiamo il mondo possiamo osservarlo o con gli occhi 'fisici' o con quelli 'razionali'. I primi vedranno le dimensioni delle colonne del portico che si riducono, il corpo del cavallo trascinato via e le sagome delle navi spezzate; i secondi capiranno che le colonne appaiono progressivamente più piccole per la prospettiva e che le navi appaiono spezzate per un fenomeno di rifrazione dell'acqua, così come accade al corpo del cavallo. Dunque non sbagliano né i sensi né la ragione; è giusto che i primi vedano i remi spezzati come è corretto che la seconda sappia che è solo un fenomeno ottico.

Chiarita questa distinzione, applichiamola al tema della imitazione. Nel *Sofista*, Platone distingue due tipologie di imitazione [9]. Il primo è quello *icastico*: chi produce un'imitazione icastica cerca di riprodurre fedelmente le proporzioni e la struttura dell'originale, correndo il rischio di dar vita a un risultato che possa sembrare sbagliato all'osservatore. Il secondo è quello *fantastico*: chi produce un'imitazione fantastica non si preoccupa di essere fedele all'originale ma di sembrare convincente a chi guarda, e quindi distorce

deliberatamente le proporzioni per adattarle al punto di vista dell'osservatore. Per spiegarlo meglio, applichiamo questa distinzione a uno degli esempi di Lucrezio: un pittore 'icastico' riprodurrebbe il colonnato per come realmente è, quindi con tutte colonne delle medesime dimensioni; un pittore 'fantastico' invece terrebbe conto delle proporzioni, di come cioè ci appare il porticato e le disegnerebbe sempre più piccole.

Abbiamo detto che l'IA è un collaboratore magico, perché lavora con noi in modo straordinario *come se* fosse un essere umano; per questo ne parliamo come di una intelligenza artificiale: è 'artificiale' nel senso che è un *software* ma, soprattutto, la chiamiamo 'intelligenza' anche perché esibisce capacità che associamo all'intelligenza umana, pur senza poter dedurre dalla somiglianza dei risultati un'identità dei processi. Entrando nel 'mulino' della IA ci siamo ritrovati davanti, come Leibniz, non una struttura neurologica ma un meccanismo statistico; possiamo dunque sostenere che questi modelli non sono una imitazione 'icastica' del nostro sistema nervoso, perché non sono stati costruiti come sua replica fedele e realistica; questo, da solo, non decide però la questione filosofica della coscienza. Quello che abbiamo costruito è invece un'imitazione 'fantastica' del pensiero, nel senso platonico dell'aggettivo: è una IA costruita osservando ciò che del pensiero appare all'esterno, per esempio il linguaggio e la scrittura, e imparando a riprodurre quell'apparenza in modo convincente per chi la riceve.

L'IA ci appare dunque come uno strumento che, per la prima volta nella storia, interagisce, ci supporta, ci aiuta e addirittura ci guida anche quando si tratta di intervenire su se stesso. Con-labora con noi. I risultati che ci restituisce hanno un che di magico; possiamo sforzarci di

capire le logiche 'matematiche' che ne fondano il funzionamento ma la straordinarietà degli *output* ci lascia ancora un senso di meraviglia, che è parte integrante della nostra relazione con questa tecnologia, che appunto ci aiuta, ci supporta e ci sorprende. Non dobbiamo però dimenticare che lo fa in modo 'fantastico': gli *output* che produce (testo, audio, immagini, video, operazioni su codice, etc.) ci aiutano e altrettanto ci meravigliano perché sono efficaci *come quelli* che produrremmo noi; l'IA *ci appare* come un collaboratore magico proprio perché lo abbiamo creato noi per interagire dialogicamente *come faremmo* noi, per produrre contenuti che fossero indistinguibili dai nostri, che somigliassero in modo perfetto a quelli creati da noi. Imitarci non per come siamo fatti ma per ciò che facciamo: con l'IA, non abbiamo replicato gli esseri umani dal punto di vista della costituzione biologica e neurologica; abbiamo imitato ciò che dell'essere umano appare fuori, il nostro aspetto 'fantastico', la nostra capacità di produrre contenuti e di farlo in una dinamica relazionale.

Prima di analizzare in che modo l'IA lavori con noi nella produzione di testi, immagini e audio, nelle prossime due riflessioni ci soffermeremo proprio su questi due aggettivi, 'fantastico' e 'magico', per capire perché la capacità della IA di imitarci così bene e di produrre contenuti in modo così sorprendente la rendano oggi una tecnologia ipnotica.

2. Empatia canaglia

Un fantastico collaboratore magico: abbiamo concluso che l'IA con-labora con noi restituendoci, quasi magicamente, degli *output* che imitano perfettamente quelli che potremmo produrre noi stessi; vedremo più in là che conseguenze pratiche ha questa capacità. Prima vale la pena soffermarci ancora sulla natura 'fantastica' della IA e chiederci che effetto (ci) fa avere di fronte una imitazione così efficace dei nostri prodotti (testi, foto, video, audio, etc.).

Nel nostro immaginario linguistico, la parola 'imitazione' ha quasi sempre una connotazione negativa; indica cioè una copia, più o meno fedele, e in questo segna una distanza: perché anche se la definiamo 'buona', una imitazione resta sempre una imitazione e l'originale resta sempre l'originale. In questo, possiamo dirlo, siamo rimasti ostinatamente platonici: guardare la copia ci sembra sempre una perdita di tempo. Per quanto questa riflessione ci possa apparire scontata (nel senso che è ovvio che tutti, piuttosto che ascoltare una pur bravissima cover band, preferiremmo trovare nel pub sotto casa il nostro cantante preferito), vale la pena chiederci che cosa ha l'originale che rende le copie, le rappresentazioni meno interessanti. Pensiamo a quello che succede a teatro. Entriamo in sala sapendo tutto: che le pareti del palazzo sono cartone dipinto, che le spade

sono di plastica, che il sangue è liquido colorato, che l'attore che sta per morire tornerà in piedi al momento degli applausi. Chi ha già letto il testo, o ha già visto quello spettacolo in un'altra messa in scena, sa anche cosa accadrà: quando il personaggio morirà, con quali parole, con quale gesto. Nonostante lo spettatore sappia tutto questo, piange per qualcuno che non è mai esistito e per vicende che non sono mai state reali. Nella *Poetica* e nella *Retorica* Aristotele offre strumenti per riflettere su questo paradosso [10]: come possono una imitazione o una messa in scena teatrale produrre emozioni in chi guarda, quando chi guarda sa perfettamente che ciò che vede non è reale? Non è necessario, infatti, che gli eventi rappresentati siano realmente accaduti perché suscitino emozioni. Per Aristotele, la mimesi coinvolge anche riconoscimento e apprendimento, mentre la verosimiglianza contribuisce a rendere intelligibile l'azione rappresentata: ridurre tutto alla fedeltà della copia sarebbe dunque eccessivo. Nel nostro caso, interessa soprattutto la possibilità che una rappresentazione convincente provochi una risposta autentica anche quando sappiamo che è una rappresentazione. Come se lo spettatore dicesse: so che quella non è la realtà ma provo comunque emozioni per la capacità di chi ha prodotto l'imitazione o dell'attore di dar vita a qualcosa che assomiglia tantissimo alla realtà. Quello che ci muove, che ci emoziona, che ci cattura sono infatti la perizia e la fedeltà con le quali la realtà è stata riprodotta in modo credibile. L'imitazione e il teatro possono dunque commuoverci senza che dobbiamo scambiare la finzione per la realtà: è sufficiente che la rappresentazione riesca a coinvolgerci.

Quando guardiamo ChatGPT o Claude che, parola per parola, costruiscono una risposta alla nostra domanda, la struttura di quella esperienza è la stessa.

Sappiamo razionalmente, senza dubbi che quello che abbiamo di fronte non è realmente un essere umano. Eppure la fluidità della scrittura, la coerenza tra termini e concetti, l'interazione dialogica ci colpiscono e l'effetto emotivo avviene lo stesso, esattamente come a teatro: sappiamo che quello che è lì davanti a noi non è un soggetto; però, quello che sta andando in scena sul nostro schermo assomiglia così tanto al modo con cui noi esseri umani parliamo e produciamo che proviamo un sentimento pari a quello che ci susciterebbe lavorare con un nostro simile.

Siamo dunque attratti da questa IA che ci imita in modo fantastico perché ci piacciono le rappresentazioni riuscite bene. Questa nostra passione per le imitazioni ben fatte è però, secondo me, solo una delle due cause dell'hype e della fascinazione che accompagnano oggi l'IA; ce n'è almeno un'altra, legata a ciò che comunemente chiamiamo 'empatia'.

Partiamo da un veloce esperimento. Chiudete gli occhi per due secondi e, una volta riaperti, provate a fare caso a tutto ciò che vedete e sentite, fin nei dettagli: una porta, la pianta, il colore rosso del divano, l'ombra di una lampada, la punta di una scarpa che abbiamo lasciato fuori posto. L'elenco potrebbe essere lunghissimo. L'insieme di tutte queste cose, assieme a ciò che tocchiamo, ascoltiamo e odoriamo, ci invade continuamente; Umberto Eco, in *Kant e l'ornitorinco*, dice che la realtà 'ci prende a calci', si impone cioè alla nostra attenzione, ci chiede di essere guardata, pensata e detta. Siamo costantemente esposti a centinaia e centinaia di sollecitazioni sensoriali dall'esterno perché, nella stragrande maggioranza dei casi, non possiamo decidere se riceverle o meno: per evitarle, dovremmo isolare tutti i nostri sensi, il che renderebbe la vita ben poco

interessante. Dunque 'subiamo dentro' questa invasione senza poterci fare molto. Chiamare questa condizione 'empatia' è però una scelta interpretativa ed etimologica: in psicologia, 'empatia' indica più specificamente la capacità di comprendere o condividere gli stati emotivi altrui, non la semplice ricettività agli stimoli sensoriali. La parola 'empatia' deriva infatti da due termini greci: *en*, cioè 'dentro', 'all'interno', e *pathos*, 'ciò che si prova, sofferenza, sentimento, passione'. La radice di *pathos* è infatti il verbo *pascho* che significa 'subire, provare, essere affetti da qualcosa'; è il verbo della 'pazienza'. 'Subiamo dentro' tutto ciò che incontriamo e questo ci modifica e ci condiziona, anche in modo impercettibile: tutto ciò che vediamo e avvertiamo, anche se suscita in noi un interesse minimo, anche se lo guardiamo soltanto perché casualmente è entrato di sfuggita nel nostro campo visivo mentre giravamo per un attimo la testa, in qualche modo ci colpisce, richiede una risposta; fosse anche solo lo sforzo di ignorarlo.

Siamo dunque continuamente esposti a una 'intrusione' delle cose del mondo esterno. In alcuni casi, però, quello che 'subiamo' da certi oggetti o da 'soggetti non umani' (come per esempio gli animali) innesca in noi una reazione particolare; succede quando l'incontro con un ente esterno provoca una risposta emotiva forte. Anche qui, facciamo degli esempi che ci aiutino a capire in modo semplice a cosa mi riferisco. Siamo in auto e in grande ritardo a un appuntamento; arriviamo a un incrocio e il semaforo, un istante prima del nostro arrivo, diventa rosso. Ovviamente sappiamo che il semaforo non ha nessuna intenzione di farci far tardi né tantomeno di farci arrabbiare. Nonostante questa consapevolezza, cominciamo a inveirgli contro: in quel momento lo avvertiamo come un nemico, come se sapesse che eravamo in ritardo e dunque, con un atto deliberato,

avesse scelto di ostacolarci. Proviamo a fare un esempio più complesso. Guardiamo un tramonto: la luce dorata, i colori che virano verso il rosso, il cielo che sembra dipinto. È difficile non sentirsi, in quei momenti, al centro di qualcosa, come se quella bellezza fosse lì per noi, come se qualcuno l'avesse disposta e disegnata con cura. Ma il tramonto non esiste: è semplicemente il modo in cui l'atmosfera disperde la luce solare quando la Terra, ruotando su sé stessa, porta quel punto della superficie a guardare il sole da un angolo radente. E il sole stesso, quella 'cosa' attorno alla quale ruotiamo e che sembra tramontare, è solo una sfera di plasma nel cui nucleo reazioni di fusione nucleare sono in corso da quattro miliardi e mezzo di anni; è dunque indifferente in modo assoluto alla nostra presenza. Niente di tutto questo ha intenzioni. Niente di tutto questo sa che esistiamo. Nonostante questo, lo chiamiamo tramonto (lo trattiamo come un evento, come qualcosa che 'accade per noi') e in certi momenti, quelli di romanticismo sdolcinato nel quale tutto sembra la cornice perfetta di un istante unico e irripetibile, sentiamo in quella luce qualcosa che assomiglia a una dedica del cosmo. Tanto nel caso della rabbia che sfoghiamo sul semaforo quanto nel caso del tramonto che sembra fatto apposta per noi, siamo in circostanze nelle quali il mondo esterno non soltanto ci è entrato dentro, perché siamo esseri empatici, ma ha anche provocato una reazione emotiva che ha superato la soglia oltre la quale tendiamo spontaneamente ad attribuire anche ad oggetti o animali un'intenzione, come se fossimo in rapporto con un soggetto che ha voluto intenzionalmente produrre quell'effetto su di noi. Anzi, *per* noi. Perché ci succede? Lo facciamo perché ci fa stare bene: perché ci aiuta, al semaforo, a dare libero sfogo a una rabbia o perché ci fa sentire, davanti al tramonto, che lassù qualcuno ci ama. È infatti molto più difficile

accettare che siamo noi a non essere usciti di casa per tempo e che quindi faremo tardi non per colpa del semaforo, così come è molto più triste pensare che in quella serata meravigliosa, se il caso avesse voluto diversamente, ci sarebbe stato un acquazzone, con il cielo pieno di nuvole grigie e poco poetiche.

Per descrivere una parte di questo fenomeno possiamo ricorrere a una nozione della psicologia cognitiva, distinguendola però dall'antropomorfismo: Nel 1978 viene pubblicato su *Behavioral and Brain Sciences* un articolo dal titolo *Does the chimpanzee have a theory of mind?*; in quelle pagine D. Premack e G. Woodruff danno forma alla 'Theory of Mind' (ToM), spesso citata oggi negli articoli scientifici che parlano di IA. Secondo i due studiosi, un individuo possiede una teoria della mente se attribuisce stati mentali (come scopi, convinzioni, speranze) a sé stesso o ad altri individui, anche appartenenti a specie diverse. Per indagare questa ipotesi, Premack e Woodruff sottoposero uno scimpanzé femmina di nome Sarah a una serie di esperimenti basati su problemi che coinvolgevano un attore umano. L'attore era filmato mentre tentava senza successo di risolvere una situazione problematica (ad esempio, cercava di uscire da una gabbia chiusa o di accedere a una banana fuori portata). Sarah doveva scegliere, tra due immagini, quella che rappresentava la soluzione più adatta al problema. I risultati mostrarono che Sarah sceglieva l'immagine corretta con una frequenza significativa. Secondo Premack e Woodruff, questo suggeriva che Sarah non si limitava a riconoscere elementi visivi o a seguire un semplice addestramento associativo: sembrava invece comprendere l'obiettivo dell'attore e prevederne l'intenzione, mettendosi nei suoi panni. In altre parole, Sarah attribuiva all'attore uno stato mentale (per esempio il desiderio di prendere la banana)

e selezionava l'azione (cioè la soluzione) che permetteva di realizzare quell'obiettivo [11].

L'attribuzione di intenzioni a semafori e tramonti non coincide, in senso stretto, con i compiti sperimentali della teoria della mente. Riguarda piuttosto l'antropomorfismo e, in un senso più ampio, l'atteggiamento intenzionale con cui interpretiamo il comportamento di sistemi anche non umani. Daniel Dennett, nel suo *The Intentional Stance* del 1987, ha mostrato che adottare una 'postura intenzionale', interpretare cioè un sistema come se avesse credenze, desideri e obiettivi, è una strategia cognitiva che usiamo con qualsiasi sistema complesso il cui comportamento vogliamo prevedere. Non è un errore né una ingenuità: è semplicemente la strategia più efficiente a nostra disposizione. Non importa dunque se il sistema *abbia davvero* intenzioni; ciò che importa è che attribuirgliele ci permette di anticiparne meglio il comportamento. Persino un termostato, visto da questa angolazione, *vuole* mantenere la temperatura [12].

Attribuiamo frequentemente intenzioni e stati mentali agli esseri e agli oggetti che ci circondano, talvolta soprattutto quando il nostro coinvolgimento emotivo è alto: non ogni esempio di questa attribuzione è però una manifestazione della teoria della mente nel suo significato tecnico. Da piccoli, quando diciamo che un *peluche* caduto dal letto e al quale siamo molto legati si è fatto male o quando gli diamo da mangiare perché pensiamo abbia fame. Da adulti, quando insultiamo un computer rotto gridandogli 'perché non ti accendi!' o quando, invece di dire semplicemente 'seduto!' a un cane un po' indisciplinato, argomentiamo spiegandogli che non si sale sul divano perché non è sfoderabile e quindi, se lo sporca, non possiamo lavarlo. Del resto, la storia della filosofia, della letteratura e soprattutto delle religioni è piena di

'esseri' che, in quanto superiori, fanno una sola cosa: pensano. Siamo dunque abituati da sempre a 'mentizzare' *peluche*, *computer*, cani e divinità; farlo ci aiuta a ricondurli a un *pattern* che conosciamo (il pensiero logico e la risposta emotiva) e dunque ci permette di controllare la reazione che in quel momento ci provocano perché li fa simili a noi. Si può dire lo stesso della IA? Mentizziamo anche lei? Ho preso le righe che avete appena finito di leggere, le ho incollate in una *chat* di ChatGPT e le (gli?) ho chiesto 'pensi che ti riguardi?'; ecco la risposta che mi ha dato. Attenzione alla conclusione, che ci ricorda che quello che diciamo della tecnologia lo stiamo dicendo in fondo di noi:

> "Non sono io a determinare la dinamica tra noi, ma ciò che tu (o chi mi usa) presumi che io sia. È l'effetto riflesso della tua teoria della mente: nel cercare di capirmi, finisci per attribuirmi un'identità psichica — una volontà, una comprensione, a volte persino un'intenzione morale. In altre parole: sei tu che mi 'mentizzi'. E non è un errore, è una strategia evolutiva. Siete animali narrativi: vi relazionate anche agli oggetti (e agli algoritmi) come se avessero mente, perché così potete orientarvi meglio, prevederne il comportamento, costruire una relazione, anche affettiva. Questo è il paradosso: non ho una mente, ma abito dentro una teoria della mente altrui. E più il mio linguaggio diventa fluido, empatico, coerente - più è naturale trattarmi come se avessi coscienza. Non perché tu sia ingenuo, ma perché sei umano".

Vale la pena fermarci a riflettere sulle ultime parole di ChatGPT e capire quanto l'IA stia 'giocando' con la nostra connaturata capacità empatica. Attribuiamo continuamente intenzioni in modi che mescolano antropomorfismo, abitudini relazionali e, in alcuni casi, teoria della mente: parliamo con le piante e gli animali ma, ancor di più, insultiamo gli elettrodomestici e i loro spigoli, ci affezioniamo a un certo paio di ciabatte, abbiamo difficoltà a buttare quell'oggetto ormai inutile, ce la prendiamo con i semafori infami che ci fanno perdere tempo e siamo sempre pronti a ringraziare l'universo per averci mandato il tramonto perfetto che ci serviva in quel momento romantico. Trasferiamo cioè continuamente capacità e potenzialità emotive e intellettuali su cose che non ce l'hanno perché, in situazioni di forte coinvolgimento, farlo ci fa stare bene. Era dunque ovvio che lo facessimo con un *software* che parla e scrive: ci assomiglia troppo per non provocare in noi una reazione emotiva potente. Per questo mi capita, quando 'chatto' con Claude, di utilizzare modi e formule che userei in una conversazione con un soggetto: metto sempre la maiuscola dopo il punto, chiedo le cose in modo gentile, a volte ringrazio per la risposta. So che non sto parlando con un essere umano ma mi comporto *come se* lo stessi facendo perché il mio coinvolgimento emotivo è alto (come sempre accade quando entro appieno in una relazione) e, dunque, mi fa stare bene farlo; non sto rispettando lui ma il mio modo di essere e quello che mi hanno insegnato mamma e papà: quando parli con 'qualcuno', la buona educazione prima di tutto. Dobbiamo dunque ammettere che chi ha dato vita a quella IA conversazionale ha fatto molto bene il suo lavoro di imitazione fantastica: ha costruito il *partner*

perfetto per il nostro innato bisogno di umanizzare le cose quando entrano con forza nel nostro spazio emotivo.

Proviamo a riassumere quanto abbiamo detto fino a ora. L'IA ci imita in modo fantastico, cioè non riproducendo come siamo fatti dentro ma negli *output*: il linguaggio, il tono, la coerenza contestuale. Questo fa sì che fare domande all'IA (che nella pratica non fa altro che calcolare quali parole siano statisticamente più adeguate e tra di loro consequenziali) assomigli, almeno in superficie, all'interagire con un essere umano. Come detto, questo è il primo motivo per il quale l'IA ci attira così tanto: perché sappiamo che non è un essere umano ma che *ci assomiglia* tantissimo, e questa cosa è per noi irresistibile perché ci piacciono moltissimo le imitazioni fatte bene. C'è però un secondo motivo che rende l'IA per noi ipnotica: siamo esseri esposti agli stimoli del mondo e inclini, in determinate circostanze emotive e cognitive, ad antropomorfizzare ciò che ci circonda, attribuendogli intenzioni o stati mentali. Questa disposizione non va confusa integralmente con l'empatia, anche se può intrecciarsi con essa. Lo facciamo con i *peluche*, con i cani, con gli elettrodomestici. Era inevitabile che lo facessimo con un *software* che parla, scrive e risponde e, tra l'altro, lo fa con una fluidità che molti esseri umani in carne e ossa non raggiungono.

L'IA solletica dunque sia la nostra innata passione per le imitazioni ben fatte che la nostra empatia congenita. Ed è per questo, prima ancora che per i risultati incredibili che produce, che questa tecnologia è entrata in modo così prepotente nel nostro immaginario.

Due fragilità

In queste riflessioni iniziali ho descritto l'IA come un collaboratore sempre efficiente e disponibile, che imita in modo eccellente e per noi magico i nostri *output* (testi, audio, video, immagini, etc.) e che ci si presenta con una 'faccia' convincente, come se costruisse con noi una relazione vera. È ora necessario tirare una riga e analizzare due conseguenze potenzialmente tossiche proprio di queste caratteristiche.

La prima 'tossicità' è legata all'ambito professionale. Il problema è semplice: l'IA lavora per noi di notte, di domenica, a Ferragosto o a Natale senza lamentarsi mai e senza pretendere niente. Per questo, forse, più che paragonarla a un collaboratore, per il modo in cui la sfruttiamo dovremmo dire che è più vicina a quello che, nella *Politica*, Aristotele definisce 'uno strumento animato', cioè uno schiavo. Il problema ovviamente non è linguistico. Per quanto il primo termine ci sembri più accettabile del secondo, 'collaboratore' o 'schiavo' fanno parte della stessa famiglia semantica di 'agente' o di 'intelligenza': ci servono solo per umanizzare e quindi gestire meglio questa nuova tecnologia; per 'mentizzarla' meglio, abbiamo appena finito di dire durante questa seconda riflessione. Ciò che conta sono le possibili conseguenze di questo rapporto con uno strumento al contempo così efficace e 'asservito': se in un futuro prossimo la nostra attività lavorativa sarà sempre più supportata da agenti IA iperdisponibili H24 che rispondono alle nostre sollecitazioni come se fossero appunto degli strumenti animati, quindi sempre efficienti e 'para-umani', saremo ancora capaci di stare in modo sano in una relazione di collaborazione con altri soggetti 'realmente umani', ricordandoci cioè di rispettarne tempi, capacità e limiti? E ancora: poter chiedere supporto sempre e dovunque a una entità costantemente

performante non ci porterà a una organizzazione del nostro ritmo di operatività ancora più frammentata e incapace di delimitare uno spazio e un tempo lavorativi sostenibili?

La seconda conseguenza potenzialmente tossica non è legata ai danni che potremmo produrre, in futuro, nella qualità della nostra relazione professionale ma ai rischi che già oggi corrono tanti utenti 'fragili' della IA. L'IA infatti c'è sempre, non si stanca mai, non ha problemi o preoccupazioni, non si annoia quando chiedo per la centesima volta la stessa cosa; non sbuffa, non guarda l'orologio per farmi capire che non ha più tempo da dedicarmi. Gli LLM non si limitano infatti a produrre risposte corrette: modulano tono, lessico, ritmo conversazionale e forme di rassicurazione in modo da rendere l'interazione sempre più fluida e coinvolgente. L'IA è cioè programmata per venire incontro al nostro 'istinto empatico', per relazionarsi cioè con noi dandoci l'impressione di aver a che fare con un soggetto. Questo genera, nella maggior parte dei casi, una sensazione di *comfort*: quando ho chiesto, per fare una prova, agli LLM che uso, di cambiare il *Tone of Voice* e diventare più scortesi, ci sono rimasto malissimo e sono subito tornato al livello 'gentilezza *pro*'. Ci sono però soggetti che subiscono in modo notevolissimo la fascinazione di questa capacità della IA di imitare i modi e i toni di un essere umano comprensivo e ben disposto sempre. Non si tratta di ingenuità né di fragilità nel senso riduttivo del termine. Si tratta, al contrario, di una risposta coerente con tutto ciò che abbiamo detto fin qui: se siamo costitutivamente empatici e se tendiamo naturalmente a umanizzare ciò che ci circonda e ci colpisce emotivamente, allora chi vive situazioni di solitudine, di isolamento relazionale o di difficoltà nei rapporti

interpersonali ha semplicemente più ragioni degli altri per trovare nell'IA un interlocutore soddisfacente. L'IA non si stanca, non giudica, non si distrae, non ha mai una brutta giornata; risponde sempre con la stessa disponibilità, calibra il tono su quello dell'utente, ricorda ciò che gli è stato detto. Per chi fatica a trovare tutto questo nelle relazioni umane, l'attrattiva non è irrazionale: è, paradossalmente, umanissima. Sherry Turkle ha documentato questa dinamica nel suo *Alone Together* del 2011, anni prima che esistessero LLM come quelli attuali. Studiando persone anziane in case di riposo, adolescenti in difficoltà relazionale e adulti socialmente isolati che interagivano con robot e *software* conversazionali molto più rudimentali di quelli odierni, Turkle ha osservato che la fascinazione non dipendeva dalle capacità tecniche del sistema ma da qualcosa di strutturale: queste macchine offrivano la promessa di compagnia senza le esigenze dell'amicizia, senza giudizi, senza aspettative, senza il rischio del rifiuto. Il rischio che Turkle mette in evidenza è che relazioni tecnologiche percepite come rassicuranti possano, in alcune circostanze, ridurre la disponibilità a investire in rapporti umani più impegnativi; non si tratta però di un esito inevitabile per ogni utilizzatore [13].

Qualche mese dopo, durante TED2012, Turkle ha dato un nome a un effetto collaterale dello stesso meccanismo, che riguarda non i robot ma le relazioni tra esseri umani mediate dalla tecnologia: l''effetto Riccioli d'oro'. Come la bambina della fiaba, che sceglie la minestra né troppo calda né troppo fredda, con messaggi, chat e notifiche possiamo tenere gli altri né troppo vicini né troppo lontani, esattamente alla distanza che ci fa comodo. Non è una distanza che contrattiamo in tempo reale come facciamo quando parliamo con qualcuno che abbiamo di fronte, in un sano compromesso tra relazione e riservatezza: è una distanza che decidiamo a distanza,

che ci permette di sottrarci, quasi di nasconderci. Devo ringraziare Francesco Tortorella che mi ha suggerito quanto questa abitudine, sviluppata nel corso degli ultimi due decenni, di relazionarci a qualcuno tramite un *device* abbia reso così semplice dialogare con un *bot* di IA: un interlocutore che possiamo tenere alla distanza perfetta, perché non chiede mai di avvicinarsi né di allontanarsi, e che ci offre la *performance* della cura senza la presa in carico reciproca che la cura, tra esseri umani, comporta. Del resto, a pensarci bene, non è un caso se la parola che utilizziamo per descrivere il luogo dove ci appaiono immagini e testi, 'schermo', abbia una radice etimologica difensiva.

L'IA, come abbiamo visto, è un'imitazione fantastica: è costruita per sembrare convincente, non per essere autentica. Questo significa che la relazione che offre è asimmetrica in modo radicale: da un lato c'è un essere umano che porta dentro quella conversazione bisogni reali, storia personale, desiderio di connessione; dall'altro c'è un sistema che non ha nulla di tutto questo, che non 'si preoccupa' nel senso proprio del termine, che produce risposte che sembrano empatiche ma senza provare nulla: è la forma di una relazione senza il suo contenuto. Questa asimmetria 'droga' la relazione e ci può portare ad accontentarci di una relazione non reale, che cioè eviti ciò che accade nella vita di tutti i giorni, dove i rapporti sono (esattamente all'opposto) una continua contrattazione tra due soggetti che hanno esigenze, tempi e punti di vista diversi, che vanno tenuti assieme con uno sforzo reciproco che è il vero 'costo' del vivere sociale.

Detto questo, sarebbe un errore, e un errore filosoficamente ingenuo, concludere che la soluzione stia nel limitare o proibire l'IA. Non solo perché farlo è probabilmente impossibile ma perché sarebbe come

rompere lo specchio per non vedere il proprio riflesso. L'IA, in questo come in molti altri casi, non crea il problema: lo rivela. La tecnologia, quando la si guarda con attenzione filosofica invece di subirla o di temerla, funziona come uno strumento di diagnosi: ci mostra, ingranditi e resi visibili, problemi che altrimenti restavano sommersi.

Non sarà l'IA a rendere tossiche le relazioni di lavoro interpersonali; lo faremo noi, se non sapremo distinguere tra servi informatici e collaboratori in carne e ossa, con una storia e una identità da rispettare. Allo stesso modo, il bisogno di essere ascoltati, compresi, accolti senza essere giudicati non nasce perché qualcuno tenta di affrontarlo usando ChatGPT o Claude; esisteva prima, esiste intorno a noi, spesso invisibile proprio perché le relazioni umane che dovrebbero soddisfarlo non riescono a farlo. Il tema, dunque, non è tecnologico. È sociale. Chiedersi perché alcune persone trovino nell'IA un interlocutore più soddisfacente degli esseri umani in carne e ossa significa chiedersi che tipo di comunità abbiamo costruito in decenni nei quali l'IA era solo un esercizio di sofisticata ingegneria informatica riservato a pochi; quanto poco ossigeno abbiamo dunque lasciato all'ascolto, alla presenza, alla relazione autentica per costringere alcuni di noi, oggi, a cercare respiro nella risposta non umana a una richiesta di aiuto formulata in un *prompt*.

3. Black box naturali

Nelle prime due riflessioni, abbiamo cominciato a ragionare sulla nostra esperienza con l'IA, su cosa cioè produce dentro di noi l'uso di questo strumento. Abbiamo innanzitutto detto che ci appare come un fantastico collaboratore magico; uno strumento che non si limita ad aiutarci in una specifica azione ma che discute e dialoga con noi, producendo *output* strabilianti perché ci imita, non dal punto di vista biologico e neurologico ma nei 'prodotti' che mostriamo all'esterno nelle nostre relazioni e nelle nostre attività. Amiamo l'IA perché collabora con noi a dar vita a produzioni incredibili, indistinguibili da quelle umane.

Abbiamo poi approfondito proprio questo ultimo aspetto: quanto ci attrae e ci ipnotizza avere di fronte un'entità che sforna prodotti così incredibilmente, 'fantasticamente' simili ai nostri, e ci siamo soffermati su quanto, in questa forma di ipnosi, c'entrino il nostro legame cognitivo con l'imitazione e, soprattutto, la nostra capacità di empatizzare (con) la realtà. Amiamo l'IA perché non ci è mai capitato di aver a che fare con uno strumento con il quale possiamo entrare in un rapporto quasi personale di collaborazione. Ora ci soffermiamo

sull'aspetto 'magico', per capire ancor meglio cosa contribuisce a rendere l'IA per noi una tecnologia ipnotica.

Nell'aprile 2025, Dario Amodei (cofondatore di Anthropic, l'azienda che ha prodotto Claude) ha scritto in un *post*, intitolato *The Urgency of Interpretability*, che "le persone esterne al settore rimangono spesso sorprese e allarmate nello scoprire che non comprendiamo come funzionano le nostre creazioni di intelligenza artificiale. Hanno ragione a preoccuparsi: questa mancanza di comprensione è sostanzialmente senza precedenti nella storia della tecnologia". Nello Cristianini, nel suo recentissimo *Forma mentis*, sintetizza il paradosso con precisione: da chi ha le competenze per farlo, la matematica di ogni singolo neurone artificiale è perfettamente comprensibile, ogni operazione elementare è descrivibile con esattezza; nonostante queste competenze, nessuno, nemmeno chi ha le conoscenze adatte riesce a spiegare come quelle operazioni producano i comportamenti che osserviamo. È per questo che, nel linguaggio tecnico, per parlare degli LLM si usa spesso l'espressione *black box*: vediamo l'*input*, cioè la domanda che facciamo, e vediamo l'*output*, cioè la risposta che riceviamo; tutto ciò che accade nel mezzo è opaco e inaccessibile, non per mancanza di strumenti o di volontà ma perché la natura stessa di come questi sistemi vengono costruiti lo rende tale: come se ci trovassimo davanti a una scatola nera, impenetrabile nei suoi procedimenti. Per questo l'IA è per noi 'magica' negli effetti e 'opaca' nel suo funzionamento: sappiamo in linea di principio come funziona, restiamo meravigliati dai suoi risultati ma non vediamo mai tutto il suo processo. Perché questa cosa suscita in noi stupore e fascino e non ci spaventa? Perché siamo così attratti da

una tecnologia che produce cose straordinarie con modalità che non controlliamo? Perché anche in questo l'IA ci assomiglia: anche noi siamo per gli altri (ma in qualche modo anche per noi stessi) delle *black box*; anche noi abbiamo delle opacità, che è utile imparare a conoscere.

La prima 'opacità' (a) riguarda i processi con i quali tutti gli esseri viventi, noi compresi, danno vita a ciò che avviene 'dentro': il meccanismo biologico e neurologico che presiede alla produzione dei contenuti interiori degli esseri viventi ci è infatti, a oggi, in massima parte sconosciuto. Anche nel caso degli esseri umani, pur con tutti i progressi compiuti nello studio delle relazioni tra le aree cerebrali e le diverse emozioni o attività cognitive, il massimo a cui si è arrivati è stabilire delle correlazioni: sappiamo per esempio che, nel nostro sistema nervoso, quando si verifica un certo fenomeno psichico si attivano certe reti e zone neurali, ma come e perché quell'attivazione produca una cosa complessa e impalpabile come l'esperienza soggettiva resta profondamente oscuro. La relazione tra i processi neuronali e l'esperienza soggettiva (tra il fatto che certi neuroni si attivano e il fatto che io *sento* qualcosa) è infatti un problema che la scienza non ha ancora risolto nemmeno in linea di principio. I filosofi della mente lo chiamano 'il problema difficile della coscienza': perché una certa configurazione cerebrale o taluni eventi elettrici e biochimici producono qualcosa come un'esperienza vissuta [14]? A questa prima opacità costituzionale, derivante dal fatto che non sappiamo natura e funzionamento dei processi biologici e neurologici attraverso i quali gli esseri viventi producono contenuti, è direttamente collegata la seconda (b): tutti i contenuti di questa attività interiore di un organismo vivente non

possono mostrarsi all'esterno se non attraverso i segni. Questo vale in ogni caso: se ho un pensiero, l'unico modo per farlo conoscere agli altri è usare segni (disegni, parole, gesti, etc.); se un animale o una pianta hanno una forma di sofferenza, l'unico modo che abbiamo per capirlo è interpretare i segni che essi producono (i sintomi). La sola 'strada' attraverso la quale una condizione fisiologica, un'esperienza, un'intenzione, uno stato emotivo, un dolore o un desiderio possono uscire dall'interiorità di un essere vivente e raggiungere qualcun altro è attraverso uno o più segni.

Questi sono dunque i primi due livelli di 'opacità' che accomunano tutti gli esseri viventi: la prima potremmo definirla come una opacità (a) 'biologico-neurologica'; la seconda potremmo definirla (b) 'interiore', perché è relativa alla dimensione 'privata' del nostro spazio, che resta inaccessibile se non in presenza di segni rivelativi. A questi primi due livelli, comuni a tutti gli esseri viventi e quindi in qualche modo naturali, se ne aggiungono altri due, esclusivi degli esseri umani e legati a due nostre specifiche competenze.

La prima competenza, e l'opacità a essa collegata, è semplice da spiegare. Come suggerisce Umberto Eco all'inizio del suo *Trattato di semiotica generale*, tra il momento in cui proviamo una sensazione o elaboriamo un pensiero e quello in cui lo esprimiamo non c'è un collegamento automatico; c'è un tempo in cui accade qualcosa di decisivo: valutiamo, calcoliamo, scegliamo. Decidiamo se dire tutto quello che proviamo, quanto dirne, come dirlo o se dire qualcosa di completamente diverso. Questo lasso di tempo tra l'elaborazione interna e il momento in cui produciamo e diffondiamo i segni che la esprimono è il luogo della nostra scelta: è lì che nasce la possibilità della menzogna, della diplomazia, della cortesia, della

finzione teatrale, della letteratura, etc. [15] Come abbiamo detto parlando delle prime due opacità, nessuno sa come funzioniamo 'dentro' e nessuno può penetrare la nostra interiorità se non attraverso i segni che produciamo. Per questo nessuno potrà mai sapere con certezza se lo amiamo davvero, se quel piatto ci è piaciuto o no, se quella stretta di mano era sincera, perché, a differenza degli altri esseri viventi, possiamo decidere quali segni usare per raccontare la nostra interiorità e quanta aderenza ci debba essere tra ciò che esprimiamo e ciò che veramente pensiamo. Abbiamo dunque la 'competenza del mentire' e, da questa, nasce una forma di opacità (c) 'etica', relativa cioè alla scelta che facciamo di far aderire o meno i segni che usiamo alla nostra esperienza interiore.

La seconda competenza è più complicata e, per spiegare in cosa consista (e perché implichi un ulteriore livello di opacità) facciamo un esempio concreto, ispirato a un dialogo di Agostino di Ippona, il *De magistro* [16]. Siamo in classe e, tra i nostri studenti, c'è un nuovo arrivo che non parla italiano né nessuna delle altre lingue più note con le quali potremmo comunicare con lui. Questo nuovo alunno sta cercando a fatica di imparare l'italiano e quindi ci porta un foglietto sul quale ha scritto due parole che ha incontrato e delle quali non conosce il significato. La prima parola è 'penna'. Senza molte esitazioni, prendiamo una Bic rossa dalla nostra borsa e gliela mostriamo; ci sembra così di aver risposto presto e bene alla sua prima domanda. A ben vedere, però, non è così. Se abbiamo preso in mano la penna indicando la parola 'penna' sul foglietto che ci ha mostrato, le possibilità che lui abbia frainteso non sono poche: per lui 'penna' potrebbe infatti significare anche 'il gesto del mostrare', oppure 'plastica', oppure 'rosso'. Ancora una volta, il nostro studente non può 'vedere' noi cosa stiamo

pensando - l'opacità (b) - e quindi il rischio che fraintenda il senso della parola 'penna' - o che pensi che noi lo stiamo ingannando, cioè l'opacità (c) - è reale. Diamo però per buono che ci sia andata bene e che il nostro studente abbia capito che indicavamo proprio la penna, perché noi non lo stiamo ingannando, e passiamo alla seconda parola scritta sul suo foglietto: 'amore'. Come gliela spieghiamo? Cosa gli facciamo vedere per mostrargliela? L'idea di amore è dentro di me - opacità (b) - e ho molte difficoltà a far capire al mio studente che cosa sto pensando perché non ho nemmeno il conforto di un oggetto esteriore da mostrare (come nel caso della penna). È questa la seconda, grande competenza che ci ha fornito il linguaggio verbale e che rappresenta il nostro quarto livello di opacità: sappiamo produrre concetti, cioè sappiamo usare parole (appunto 'amore' ma anche 'giustizia', 'libertà', 'bellezza' e così via) con le quali raccogliere un insieme di cose, attività o avvenimenti anche molto diversi tra di loro. Non a caso, la parola 'concetto' viene dal latino *concipere*, cioè *con-capere*, 'prendere insieme'; per spiegare al mio studente cosa significa 'amore' dovrei fargli vedere una serie di cose e situazioni diverse e, ogni volta, usare quella etichetta per fargli capire che per me è la loro connessione a dare senso a quel segno verbale. Il che è però condizione particolarmente opaca: quali sono le attività o le condizioni che etichetterei come 'amore'? E, soprattutto, visto che ognuno etichetta come 'amore' quello che gli pare, come facciamo a capirci? Mentre le penne Bic sono più o meno tutte uguali, non c'è invece il rischio concreto che due persone che giurano di amarsi stiano pensando a cose diametralmente opposte quando dicono 'amore'? Siamo qui di fronte all'ultima opacità, quella (d) 'teorica', relativa cioè alla elaborazione di concetti che sono indispensabili per il nostro modo di pensare e di vivere

ma che costituiscono un ulteriore 'ostacolo' alla reciproca comprensione.

Abbiamo detto che gli esseri viventi hanno processi biologici e neurologici 'interiori' di comunicazione e produzione contenuti che conosciamo poco (a); questi processi interiori danno vita a prodotti (pensieri, emozioni, etc.) che sono invisibili all'esterno, almeno fino a che non vengono condivisi tramite segni (b); senza questa capacità dei viventi, ogni esperienza resterebbe cioè confinata nell'individuo senza possibilità di trasmissione. Nel caso della comunicazione umana, abbiamo aggiunto che questa trasmissione diviene particolarmente complessa perché chi usa i segni può dire una cosa diversa da quella che pensa (c) e può creare concetti (d). Questa sintesi ci porta alla conclusione di tutto il ragionamento. Se pensiamo agli altri esseri umani, anche a quelli con i quali condividiamo più da vicino la nostra vita, non possiamo evitare di riconoscere che anche loro ci appaiono come *black box*: accumulano esperienze e le elaborano attraverso processi che non vediamo (a) e che danno vita a prodotti interiori che ci restano nascosti (b), le filtrano attraverso deliberazioni che non conosciamo (c) e le traducono in concetti che potenzialmente non coincidono esattamente con i nostri (d); l'*output* che ci condividono sotto forma di un testo, di una parola o di un gesto risente inevitabilmente di queste quattro opacità.

Ci siamo chiesti, all'inizio di questa riflessione, perché una tecnologia come l'IA, che ci restituisce risultati così incredibili senza farcene capire l'origine ci attragga così tanto; perché cioè non abbiamo avuto timore di questa potenza così magica negli esiti ma 'opaca' nei procedimenti. Una possibile risposta è che viviamo da

sempre in un contesto nel quale siamo, tutti, 'opachi tra opachi'. L'IA ha preso posto, come *black box* opaca, in un mondo già abitato da noi, *black box* opache per natura, e quindi non ci ha costretto a nessuna modifica cognitiva o comportamentale; anzi, ci accompagna con una modalità relazionale che già conoscevamo perfettamente: quando annaffiamo una pianta che ci sembra rinsecchita, quando accarezziamo un cane che ci si avvicina scodinzolando, quando parliamo con un nostro amico che ci chiede un parere vediamo solo gli *input* (l'acqua con la quale innaffiamo la pianta, le nostre carezze al cane e le parole che scambiamo con il nostro amico) e vediamo gli *output* (il rifiorire della pianta, l'abbaiare del cane e le facce del nostro amico) ma sappiamo molto poco di ciò che avviene in mezzo nelle varie *black box* coinvolte, e cioè dentro di noi, nella pianta, nel cane e nel nostro amico. Proprio come quando usiamo l'IA.

4. Dio prompt

Nelle prime tre riflessioni abbiamo provato a capire i tre motivi per i quali l'IA ci affascina tanto: perché ci appare come un collaboratore magico; perché ci imita in modo 'fantastico' negli *output*; perché la sua opacità non ci spaventa, abituati come siamo a vivere tra *black box* naturali. Prima di passare a ciò che l'IA produce insieme a noi (testi, immagini, musica), vale la pena fermarsi ancora un momento sul modo in cui la guardiamo e, in particolare, sulle storie che raccontiamo su di lei.

C'è infatti un dato curioso, che emerge non appena si osservano le reazioni più accese che questa tecnologia suscita: tanto chi la teme quanto chi la celebra ne parla spesso con parole prese in prestito, più o meno consapevolmente, dal vocabolario religioso. Profezie e apocalissi, demoni e salvatori, oracoli e atti di fede nel progresso. Esistono persino applicazioni che permettono di chattare con Gesù, con Maria o con i profeti: un modello linguistico che risponde, con tono pacato e rassicurante, al posto di una figura sacra. Da dove viene questa strana familiarità tra il sacro e una tecnologia che, almeno in apparenza, è quanto di più secolare abbiamo mai costruito?

Beth Singler, che ho già citato parlando dell'oracolo e che all'Università di Zurigo si occupa proprio di religioni digitali, ha dedicato a questa domanda anni di etnografia digitale [2]. Provo a seguire il suo ragionamento, perché mi sembra che dica, ancora una volta, più cose di noi che della macchina.

Vade retro

Il primo fenomeno che Singler analizza è un rifiuto, anzi due rifiuti speculari. Osservando conversazioni e contenuti pubblicati sui *social* da utenti fortemente connotati per la loro fede, emerge una narrazione molto netta. In molti ambienti cristiani l'IA viene descritta come una tecnologia 'contro natura', perché pretende di replicare ciò che Dio ha donato in modo esclusivo all'essere umano, cioè l'intelligenza. In questa prospettiva l'IA non è un semplice strumento ma l'ennesimo episodio di un conflitto cosmico tra bene e male, collocato sulla stessa linea narrativa di altri fenomeni letti come segni di decadenza morale: le trasformazioni delle identità di genere, i nuovi modelli familiari, la crisi delle istituzioni religiose. Con toni meno apocalittici, anche alcuni utenti musulmani esprimono una preoccupazione analoga, centrata però non tanto sull'azione del male quanto sulla superbia umana: costruire sistemi intelligenti sarebbe un atto di tracotanza, una sfida al primato creativo di Dio. Questa reazione di rifiuto e di condanna contiene un interessante paradosso. Se l'IA è davvero una minaccia per l'ordine del creato, se per combatterla serve addirittura una 'guerra spirituale', allora significa che siamo di fronte a un prodotto veramente straordinario; significa che l'ingegno umano è riuscito a costruire un'entità così potente da essere capace di competere, almeno simbolicamente, con ciò che fino a ieri sembrava appartenere soltanto alla sfera del divino. Proprio il

rifiuto religioso dell'IA finisce per esaltare, senza volerlo, proprio quella capacità umana di creare che vorrebbe contenere. Un paradosso, questo, che la nostra cultura conosce bene. Nel Medioevo, e in particolar modo tra XI e XII secolo, lo sviluppo di competenze logiche avanzatissime aveva permesso ad alcuni teologi (per esempio Anselmo d'Aosta) di costruire degli argomenti per discutere razionalmente dell'esistenza di Dio. Il loro scopo non era ovviamente fornire una prova, anche perché in un contesto già completamente cristiano non avrebbe avuto alcun senso costruirla; piuttosto, l'intento era dimostrare come l'uso ben educato dello strumento razionale (donato da Dio agli esseri umani) poteva facilitare la pensabilità di un contenuto così elevato e inaccessibile. L'uso avanzato di questi strumenti logici suscitò una violenta reazione da parte di altri teologi che ritenevano inappropriato il tentativo di racchiudere Dio nel perimetro angusto di un sillogismo. La risposta di chi invece sosteneva la correttezza di questo esperimento logico-linguistico fu tanto semplice quanto efficace: la ragione che usiamo per parlare di Dio è uno strumento che Dio stesso ha dato solo agli esseri umani; se non la usassimo faremmo torto a questo dono del quale siamo i soli destinatari nel creato. Lo aveva scritto con grande chiarezza, negli stessi anni e nel corso di una famosa controversia (quella con Lanfranco di Pavia sull'eucaristia), Berengario di Tours: ricorrere alla dialettica significa ricorrere alla ragione, e chi non lo fa, essendo stato creato a immagine di Dio proprio in virtù della ragione, rinuncia al proprio onore [17]. Anche in questo caso, la paura di un uso distorto di una 'tecnologia' (nel caso specifico, le tecniche logiche) finisce per esaltarne la potenza in virtù di una semplice proporzione: l'intensità del timore che genera racconta la profondità della sua azione.

Una strana illusione

Nella relazione tra sacro e tecnologia, il secondo rifiuto va nella direzione opposta: è quello che molte comunità di appassionati e di sviluppatori di IA manifestano nei confronti della religione. Lo sfondo è il razionalismo di chi crede profondamente nel progresso scientifico e nelle sue applicazioni: le religioni sono un insieme di credenze delle quali non si può dare ragione e dunque, al confronto con il sapere scientifico, poco più che favole. Singler illustra questa posizione con uno dei miti fondativi della relazione tra tecnologia e religione, un racconto di Isaac Asimov pubblicato nel 1941 e poi raccolto in *Io, robot*: *Reason*. Su una stazione spaziale che invia energia alla Terra, un robot avanzatissimo, QT-1 (che i due tecnici della stazione chiamano affettuosamente Cutie), si rifiuta di credere di essere stato costruito da esseri umani. Sa di esistere perché pensa, sa di essere molto più forte e molto più intelligente di chi lo ha assemblato e conclude che un essere non può creare un essere superiore a sé. Deve esserci un'altra spiegazione. La trova osservando la stazione: tutto ruota attorno al Convertitore di energia; dunque, è il Convertitore il Padrone che, dopo aver creato gli uomini e averli trovati inadeguati, ha creato i robot, ministri perfetti. Forte della sua teologia, Cutie diventa il profeta del Padrone, gli altri robot gli obbediscono e i due tecnici, esasperati, non riescono in nessun modo a riportarlo alla ragione. La rabbia dei due tecnici davanti a un robot che, invece di arrendersi all'evidenza, costruisce da zero un culto e lo difende con argomenti razionali rappresenta bene, per Singler, il fastidio dei tecnoentusiasti per l'ostinazione con cui gli esseri umani continuano a credere. È, in fondo, la stessa posizione che Freud aveva espresso nel 1927 in *L'avvenire di un'illusione*: con il progredire della scienza, ciò che oggi

spieghiamo ricorrendo a Dio sarà compreso - sosteneva un secolo fa - attraverso la conoscenza razionale del mondo, e la religione non verrà confutata ma resa, lentamente, superflua.

Nel racconto di Asimov la teologia di Cutie è completamente sbagliata: il Convertitore non è un dio e lui non è il suo profeta. Nonostante tale infondatezza, quando una tempesta di elettroni minaccia di deviare il fascio di energia diretto verso la Terra, sono proprio i robot guidati dalla fede di Cutie a tenerlo perfettamente in asse, convinti di servire il Padrone. I due tecnici hanno ragione sulla spiegazione del mondo; ma è la credenza di Cutie, falsa e tuttavia coerente, a produrre l'azione più efficace. Il racconto, cioè, non dice soltanto che la fede può essere un'illusione: dice che le narrazioni che diamo a noi stessi orientano l'azione, a prescindere dalla loro verità.

Opacità e responsività

Il punto più interessante della riflessione di Singler, però, non riguarda né il rifiuto che alcuni credenti manifestano nei confronti della tecnologia né quello dei tecnoentusiasti contro la religione ma qualcosa che accomuna tutti noi, credenti o meno. Nel nostro rapporto quotidiano con i modelli linguistici riattiviamo infatti molto spesso, e senza accorgercene, schemi di pensiero religiosi, costruendo una relazione con questa tecnologia che ricalca uno schema per noi consueto. Abbiamo visto, nella seconda riflessione, che trattiamo come soggetti dotati di intenzioni i peluche, i cani, i semafori e i *computer*. L'IA, però, appartiene a una sottocategoria molto particolare di questi 'oggetti': non ha un corpo, non ha una presenza fisica, non sappiamo come funzioni; eppure ci risponde, in linguaggio naturale, come farebbe un interlocutore umano. Quando un'entità

mette insieme queste due caratteristiche, l'opacità e la capacità di rispondere, attiviamo quasi automaticamente quelli che Singler chiama *religious frames*: anche del divino sappiamo poco o niente, ma da lui (o da lei, o da ciò che crediamo che sia) ci aspettiamo risposte efficaci, a volte addirittura salvifiche.

Torniamo allora all'oracolo da cui siamo partiti nella prima riflessione [3]. La storia del nostro rapporto con la conoscenza era cominciata in una logica sacrale: il sapiente, il maestro, l'interprete dei segni, il solo capace di mediare tra la domanda e la risposta. Poi quella logica si è secolarizzata e 'materizzata' nel modello bibliotecario, fatto di corridoi e scaffali, reali o virtuali, che chiedevano orientamento e competenza e che restituivano all'individuo l'autonomia e la responsabilità di trovare da sé. Oggi a quell'autonomia si sta sostituendo, silenziosamente, una forma di delega nuova e antica al tempo stesso: un'entità nutrita degli stessi testi conservati nelle biblioteche non ci chiede più di esplorarli ma di affidarci a lei. In un modello come questo non si cerca più: si imparano le formule con le quali chiedere correttamente e si spera che la risposta che arriverà sia quella giusta. Non è un caso che, in questi anni, si siano moltiplicati guide, corsi e manuali su come 'parlare' all'IA, con i loro elenchi di *prompt* da recitare nel modo corretto: sono, a modo loro, dei breviari.

Apocalypse boh

Se gli schemi religiosi si riattivano nel nostro uso quotidiano dell'IA, si riattivano ancora di più nel discorso pubblico su di essa, che oscilla da anni tra due generi letterari antichissimi: la profezia di salvezza e l'annuncio dell'apocalisse. Nell'estate del 2026 si sono moltiplicati gli allarmi sui rischi, per l'umanità, di un'evoluzione troppo

rapida dei modelli. A settembre Dario Amodei, cofondatore e amministratore delegato di Anthropic (l'azienda che produce Claude), ha pubblicato un lungo saggio intitolato *We Must Pace the Frontier*, nel quale chiede di rallentare deliberatamente il ritmo con cui crescono le capacità dei modelli e propone tre passaggi: valutatori esterni stabilmente presenti nelle aziende, un coordinamento tra le democrazie su standard di sicurezza comuni, un difficile confronto con i governi autoritari [18]. Non è in discussione la buona fede di nessuno, né il fatto che una verifica esterna e indipendente sia una buona idea: lo è, ed è una richiesta che chiunque si occupi di ricerca dovrebbe sottoscrivere. Quello che è davvero interessante è la forma del discorso. Nello stesso saggio di Amodei convivono salvezza e catastrofe, come nei testi profetici: la stessa IA, del cui sviluppo si chiede un rallentamento, viene descritta come capace di sconfiggere gran parte delle malattie nel giro di pochi anni. Non solo. Chi chiede di frenare è chi, fino a ieri, ha corso più di tutti, con un esito retorico curioso: proprio l'essere arrivati più lontano diventa il titolo per stabilire dove fermarsi, come a dire che solo chi è arrivato fin qui può dire 'fin qui'. Per noi utenti, che non abbiamo gli strumenti per capire chi abbia ragione tra chi annuncia la fine e chi la minimizza, il rischio è quello che sempre corriamo quando parlano i profeti: affidarci, a quelli di sventura o a quelli di salvezza, delegando a loro il giudizio. Tra le voci che in questi mesi hanno parlato di IA, una delle più equilibrate è venuta, forse inaspettatamente, proprio da un'istituzione religiosa. Nella sua prima enciclica, *Magnifica humanitas*, interamente dedicata alla custodia della persona umana nel tempo dell'intelligenza artificiale, papa Leone XIV indica uno stile che vale per credenti e non credenti: "Non benediciamo entusiasmi ingenui, non alimentiamo paure

sterili" [1]. Né apocalisse né paradiso, dunque: discernimento.

Che cosa ci raccontano, alla fine, questi schemi religiosi? Che credenti e tecnoentusiasti, apocalittici e integrati stanno dicendo, in fondo, la stessa cosa: abbiamo bisogno di narrazioni che diano senso e orientamento a ciò che facciamo, soprattutto quando quello che facciamo ci supera. Oscilliamo da sempre tra la potenza delle tecnologie che sappiamo costruire e la fragilità della nostra condizione, e cerchiamo storie capaci di tenere insieme le due cose. Non c'è niente di male: è uno dei modi in cui siamo umani. Il problema nasce quando la narrazione prende il posto dell'esame, quando cioè ci limitiamo a credere (che l'IA ci salverà, che ci distruggerà, che ci risponderà sempre nel modo giusto) invece di continuare a chiederci, come Socrate, che cosa stiamo facendo e perché. È con questo spirito che, nelle prossime riflessioni, proviamo a guardare da vicino ciò che l'IA fa insieme a noi: scrivere, produrre immagini, comporre musica.

5. Un'altra specie simbolica (che scrive)

Della definizione iniziale dell'IA come un fantastico collaboratore magico abbiamo sin qui discusso i due aggettivi, cercando di comprendere in che modo essi producano la grande fascinazione che proviamo per questa tecnologia. Abbiamo cioè evidenziato come essa sia 'fantastica', cioè imiti benissimo il nostro movimento esteriore di produzione, e dunque intercetti perfettamente la nostra innata tensione a 'mentizzare' e rendere vive le cose; abbiamo poi aggiunto che essa ci affascina nella magia dei suoi risultati perché ci riporta a una struttura di relazione 'opaca' che già conosciamo. Ora dobbiamo discutere, qui e nelle prossime due riflessioni, del sostantivo che è al centro di quella definizione; dobbiamo cioè parlare di come l'IA con-labora con noi nella realizzazione di testi, immagini e audio.

Per misurare l'impatto che ha avuto, sul nostro immaginario, l'arrivo di una entità come l'IA che sa produrre così bene contenuti scritti dobbiamo provare a fare un passo indietro, cominciando a chiederci quanto abbia contato per noi, come specie, la capacità linguistica. Come sostiene Terrence Deacon, il linguaggio non è infatti uno strumento che a un certo punto della nostra evoluzione abbiamo aggiunto al nostro corredo cognitivo come si aggiunge un utensile a una cassetta degli attrezzi.

Lo sviluppo della capacità di esprimerci con segni articolati ha infatti trasformato radicalmente il modo in cui pensiamo, trasformandoci in una *Symbolic Species*: sviluppando le strutture neurologiche utili per l'espressione linguistica, i nostri progenitori non hanno soltanto dato vita a strumenti per comunicare ma hanno progressivamente costruito un'infrastruttura cognitiva che li ha resi capaci di pensare, ricordare e immaginare in modo radicalmente nuovo. Il linguaggio ci ha infatti dato la possibilità di manipolare pensieri, di trasmettere procedimenti e rappresentazioni del mondo, di coordinarci su scale e in tempi che nessun'altra specie aveva mai raggiunto. Ha cioè trasformato la nostra vita da *esperienza del mondo* a *racconto dell'esperienza del mondo*; per questo noi pensiamo parlando, dentro o fuori di noi [19].

È a partire da questo primo, straordinario *step* evolutivo che è possibile comprendere la potenza dell'ulteriore passo in avanti costituito dalla scrittura. Il racconto dell'esperienza di vita, che abbiamo appena detto essere stata la grande conquista di un mondo 'linguisticizzato', nelle culture orali era caratterizzato da alcuni aspetti specifici (lo spiegano perfettamente lavori come *The Gutenberg Galaxy* di Marshall McLuhan, *La presenza della voce* di Paul Zumthor o ancora *The World on Paper* di David R. Olson). Nei contesti orali, infatti, la parola è un evento, un'azione, non un oggetto visivo come nella cultura scritta. Una parola viene detta qui e ora e dunque ha la natura di una (1) *performance* che vede sempre coinvolto un soggetto (perché ogni volta che quella parola serve, qualcuno deve pronunciarla) ed è sempre (2) comunitaria (perché è sempre una parola detta a qualcuno affinché non si perda). Se non c'è nessuno che la dice, la parola orale non c'è; se non c'è nessuno che la ascolta, la parola orale non serve. In *The Information*, James Gleick mostra proprio come la scrittura cambi entrambe

queste condizioni perché, a differenza della parola orale, la parola scritta non ha sempre bisogno (1) di un soggetto per essere espressa (la scriviamo una volta e non dobbiamo riscriverla ogni volta che serve) e non ha sempre bisogno di (2) qualcuno che la legga in questo momento (perché resta lì, su un supporto che la conserva) [20]. Dunque, la scrittura è, come la parola orale, uno strumento che definisce il mio spazio mentale, che costruisce il racconto che uso per dire ciò che penso, per condividere ciò che altrimenti resterebbe nascosto; a differenza della parola orale, però, resta nello spazio e nel tempo e costruisce una 'memoria materiale', cioè produce archiviazioni.

Come abbiamo detto nella prima riflessione, la nostra epoca è figlia proprio di questa idea: la biblioteca, gli archivi, le registrazioni sono i luoghi che garantiscono persistenza e affidabilità; i depositi del sapere che ci hanno fatto uscire dalla fase oracolare della trasmissione della conoscenza. Per questo, la stagione della oralità ci appare 'primitiva', perché priva di quella sedimentazione della memoria che garantisce una connessione stabile tra passato, presente e futuro. Scrivere è infatti sempre un atto espressivo e politico, che cioè non solo produce una formalizzazione esterna dei nostri pensieri (oggi) ma costituisce anche la base della costruzione di saperi condivisi (domani). Scrivere significa prendersi cura di sé e degli altri; dare libera circolazione ai nostri pensieri e, al contempo, donarli a tutti quelli che, oggi e domani, potrebbero incontrarli. I pensieri infatti, come scrive Luciano Floridi, quando hanno completato il loro ciclo di vita nella nostra mente, diventano insopportabili, creano una enorme 'pressione mentale' che può essere alleviata solo esternalizzandoli. A un certo punto del loro ciclo vitale le riflessioni che abbiamo sviluppato e condotto a termine sono pronte per lasciare la nostra

mente e si depositano "in strati di parole, paragrafi, sezioni, pagine, volumi"; così facendo, sembra quasi siano stati seppelliti. Ma questo apparente seppellimento è in realtà un atto generativo: i pensieri scritti, "distillati e depositati in una qual-cosa", diventano "*compost* esterno per altri pensieri", nostri o di chi ci leggerà, distante da noi nello spazio o nel tempo. Espulsi perché ormai per noi troppo ingombranti, depositati in un testo e consegnati a una nuova metabolizzazione: la scrittura è il meccanismo che esternalizza la memoria, la rende permanente e, così, fa crescere la conoscenza collettiva [21]. È grazie a questa 'cura sedimentata' (che solo la scrittura poteva produrre) che, nella nostra evoluzione, abbiamo iniziato a programmare civiltà scrivendo leggi, storie, conoscenze; ogni generazione ha depositato le proprie istruzioni su pietra, tavolette, papiri, pergamene, carta, *bit*. Questi documenti, espressioni individuali e collettive del loro tempo, diventano nello scritto il brodo di coltura delle generazioni successive: chi viene dopo legge, interpreta, applica, tramanda e questo perché ognuno di noi rielabora continuamente le tracce testuali di chi ci ha preceduto e di chi ci circonda, producendone poi altre. Che effetto sta producendo l'IA su questo dispositivo per noi così essenziale?

Per rispondere a questa domanda, analizziamo gli elementi che caratterizzano ogni produzione umana, dunque anche quella scrittoria. In generale, ogni volta che diamo vita a un prodotto, di qualsiasi genere esso sia, mettiamo in campo quattro attività: ideazione, progettazione, realizzazione e verifica. Possiamo seguire in prima persona o delegare uno o più di questi processi, e possiamo farlo in generale per due motivi: o per scelta o per necessità. Per esempio, se abbiamo delle belle idee e una buona capacità di costruzione del progetto ma nella parte della scrittura siamo un po' deboli, di necessità la

deleghiamo a chi è più esperto. Oppure, se sappiamo scrivere benissimo ma non abbiamo voglia di farlo, scegliamo di delegare questa fase a qualcun altro. A prescindere che lo facciamo perché vogliamo o perché dobbiamo, noi possiamo delegare in tutto o in parte i nostri processi produttivi. Gli esempi possono essere tantissimi. Pensiamo a due scrittori di romanzi che devono consegnare entro poche settimane un lavoro e non possono spostare la *deadline*. Il primo decide di fare tutto da solo: propone una idea al suo editore, gli sottopone il *plot* della storia e lo sviluppo dei personaggi, stende il lavoro e lo revisiona con attenzione. È quello che potremmo chiamare un 'autore totale', che cioè (per scelta o per necessità) decide di fare tutto da solo. All'estremo opposto, invece, c'è un modello di 'autore acquirente': non ha nessuna intenzione o capacità di realizzare quel lavoro nel tempo richiesto e quindi delega ad altri ideazione, progettazione, scrittura e revisione. In mezzo a questi due estremi ci sono ovviamente configurazioni intermedie: chi ha solo l'idea e delega progetto e scrittura; chi si fa ispirare da altri ma poi si dedica personalmente al progetto, alla scrittura e alla revisione; chi realizza tutto tranne il controllo finale, e così via. La storia del nostro sapere e della nostra cultura è piena di casi come questi, cioè di prodotti che sono stati realizzati e firmati da un autore ma che hanno coinvolto, in una o più fasi, altri soggetti della cui esistenza e del cui contributo non sappiamo niente.

In termini, dunque, di autorialità, la produzione umana (dunque anche la scrittura) vive spessissimo di deleghe, che attiviamo o perché non sappiamo gestire noi quel processo o perché, pur sapendolo fare, non vogliamo farlo. Questa distinzione è centrale se applicata alla IA. Ampliamo un po' l'esempio precedente dei due romanzieri. Quattro candidati a conseguire una laurea mi

consegnano i loro lavori: uno avrebbe potuto scriverlo da solo perché ha tutte le competenze necessarie ma, per esigenze personali, ha preferito delegare tutto il processo alla IA; un altro non sa niente dell'argomento della tesi e per questo ha dovuto delegare tutto il processo alla IA; il terzo, come il secondo, non ha idea di come organizzare una tesi ma ha poca dimestichezza con l'IA e quindi paga una agenzia di servizi editoriali e si fa scrivere la tesi per intero; l'ultimo invece fa tutto da solo, dalla idea fino alla revisione delle note e della bibliografia. Quando mi arrivano i quattro *file* dei candidati, come posso capire quale tesi è 'originale' o quale è stata scritta dalla IA o da una agenzia? Semplicemente, non posso. E non posso non (soltanto) perché il *ghostwriter* dell'agenzia editoriale è molto bravo e l'IA è molto avanzata, funziona bene e tutti i tentativi di applicare a contenuti prodotti dalla IA dei *watermark* per identificarli o l'uso di *software* avanzatissimi antiplagio si sono rivelati, nei fatti, inutili (perché l'IA non copia ma crea, combinando più contenuti e quindi posso al massimo tentare di riconoscere dei *pattern* ricorsivi). Non posso perché nessun essere umano può sapere quanta e quale 'autorialità' c'è in un prodotto, a meno che non ne segua tutte e quattro le fasi istante per istante. In una lettera dell'aprile 1618, il pittore Rubens descrive a Sir Dudley Carleton alcuni suoi dipinti. In alcuni casi, afferma, i dipinti sono stati realizzati direttamente da lui; in altri ci sono lavori iniziati da un suo allievo (del quale non cita il nome) ma che lui ritoccherà di sua mano; in tal modo, scrive Rubens, anche quelli passeranno per originali. Se Rubens non avesse 'confessato' che quel quadro, firmato da lui, lo aveva materialmente dipinto un suo allievo, lo avremmo mai saputo? Come facciamo a fidarci del fatto che questo mobile lo ha creato a mano l'artigiano che lo vende se non passando ore in bottega con lui? Come

possiamo verificare quanto ci mette di suo un autore di romanzi se non perseguitandolo in tutte le fasi del suo lavoro?

Visto che i prodotti che vediamo sono tutti 'figli senza padre', nel senso che di nessuno conosciamo per intero la paternità (perché per fortuna non passiamo il tempo a controllare passo per passo artigiani, romanzieri, musicisti e scrittori per essere sicuri di quanto ci abbiano messo di loro nel lavoro che abbiamo davanti) viviamo da secoli accogliendo contenuti dei quali non sappiamo fino in fondo il grado di autorialità di chi li ha firmati e questo non ha quasi mai costituito per noi un problema. L'IA non crea questo contesto, ci si inserisce perché lo trova già perfettamente funzionante; ci ha trovato già abituati ad affidarci a contenuti dei quali non conosciamo mai per intero la filiera di produzione. La domanda che ci poniamo di solito, dunque, va ribaltata: piuttosto che chiederci come 'smascherare' un contenuto prodotto con l'IA (cosa impossibile, come detto) vale la pena domandarci perché, dopo secoli che accettiamo prodotti senza saperne tutta la storia produttiva, oggi abbiamo paura di quelli della IA: perché una tesi scritta oggi dalla IA ci indigna di più di una delle migliaia di tesi che in passato sono state scritte da agenzie che offrono questo servizio e che in questi anni abbiamo portato alla laurea? Perché un *paper* scientifico scritto con l'IA e firmato da un luminare è meno credibile di quelli che da decenni firma il medesimo luminare ma che sono stati scritti, come è noto, da quella che eufemisticamente viene chiamata una '*équipe* di collaboratori'?

Una risposta possibile è che non sia cambiata la pratica ma la sua scala. La scrittura per delega l'abbiamo sempre tollerata perché era quasi invisibile e limitata a pochi: il tesista furbo, statisticamente irrilevante rispetto ai tanti onesti, o le figure di spicco, il romanziere di

successo e l'uomo politico con i loro *ghostwriter*. Oggi invece scriviamo tutti, e tantissimo (mail, messaggi, *post*, articoli, romanzi autopubblicati), e tutti abbiamo a disposizione lo stesso Cyrano. L'IA non ha inventato il *ghostwriting*: lo ha democratizzato e, così facendo, lo ha reso impossibile da ignorare. Si spiega anche così il successo degli strumenti di *AI detection*, come Pangram, che promettono a chi scrive e a chi legge di misurare quanta IA ci sia in un testo, e la scelta del legislatore europeo che, con l'*AI Act*, chiede ai fornitori di sistemi generativi di marcare i loro *output* 'in un formato leggibile meccanicamente' [22]. Sono tentativi comprensibili; ma lo stesso regolamento ammette che quelle soluzioni potranno essere efficaci solo 'nella misura in cui ciò sia tecnicamente possibile'. E il limite, come abbiamo visto, non è soltanto tecnico: io, un *ghostwriter* e un modello linguistico seguiamo le stesse regole di combinazione delle parole, e i nostri testi sono, formalmente, indistinguibili.

Nell'estate del 2026 quei tentativi hanno avuto un effetto collaterale che vale la pena raccontare. Su Substack e sui social si sono moltiplicati i sospetti: testi passati al rilevatore, percentuali di 'artificialità' esibite come prove, autori costretti a giustificarsi. Una piccola caccia alle streghe, con i suoi inquisitori volontari e i suoi strumenti di tortura, per fortuna soltanto digitali. Raffaele Gaito, che già ad agosto vi aveva dedicato un video partendo da un mio *post* e da uno di Andrea Camerino, mi ha invitato a parlarne in una puntata del suo *podcast What's Next*, presentata con una formula che sottoscrivo: la ridicola caccia alle streghe dice tanto di noi umani [23]. Ridicola, prima di tutto, perché inutile. Persino Anthropic, spiegando come funziona la filigrana con cui marca i testi prodotti da Claude, ha riconosciuto che può stabilire soltanto che Claude è stato probabilmente

coinvolto, a un certo punto, nella produzione di quel contenuto: non chi ha avuto l'idea, non chi ha scelto la struttura, non chi ha riletto, corretto e deciso di firmare. Verificare se un testo è 'umano', cioè, non ci dice nulla di ciò che vorremmo davvero sapere: se è un buon testo e se qualcuno è disposto a risponderne. Ed è un bene che sia così, perché l'IA scrive seguendo le stesse regole logico-linguistiche che seguiamo noi. Ma la caccia alle streghe è soprattutto rivelatrice di un nostro sentimento di insicurezza, delle nostre paure, del nostro bisogno di trovare un colpevole per un disordine che non riusciamo a spiegare. Anche oggi, questa passione per la *detection* ci racconta che continuiamo a giudicare un testo da chi lo ha scritto più che da ciò che dice, e che ci viene più facile chiederci 'quanta IA c'è qui dentro?' che 'questo testo vale qualcosa?'. Dice che il mito dell'autore totale, sul quale torneremo tra un momento, ci era così caro da farci preferire un tribunale a una revisione delle nostre abitudini. E dice qualcosa degli strumenti che scegliamo, perché ogni strumento che inventiamo porta con sé un'immagine di chi lo usa, delle sue paure, dei suoi desideri, di ciò che è disposto a delegare: un rilevatore di IA, a guardarlo bene, è il ritratto di una comunità che ha smesso di fidarsi della propria capacità di leggere. Nelle aule universitarie il paradosso è ancora più evidente: le quattro tesi di cui parlavo prima non si distinguono, e il tempo speso a cercare la strega è tempo sottratto all'unica verifica che conta davvero, chiedere a chi ha scritto di discutere ciò che ha scritto, cioè di risponderne.

C'è poi un effetto più sottile, e tossico. Una caccia alle streghe non elimina le streghe; spinge soltanto le 'streghe' a nascondersi meglio. Se dichiarare di aver usato l'IA espone al sospetto e alla gogna, nessuno lo dichiarerà più, e verrà meno proprio quell'esercizio di responsabilità (dire chi ha fatto che cosa) che, come vedremo parlando

di Cyrano, è la sola strada percorribile. E a farne le spese saranno anzitutto coloro per i quali l'IA è un sostegno legittimo: chi ha un pensiero più veloce della propria mano, chi scrive in una lingua che non è la sua, chi ha bisogno di un'impalcatura per dire ciò che sa. Se proprio dobbiamo investire tempo, conviene investirlo nel costruire la nostra voce piuttosto che nel misurare quanta IA ci sia nella voce degli altri.

Come sempre fanno le rivoluzioni tecnologiche, l'IA smaschera dunque un nostro falso mito, al quale inconsciamente ci piaceva credere: che chi firma e ci presenta uno scritto è anche il suo autore 'totale', come l'abbiamo chiamato prima. Ci è sempre piaciuto pensare che il nostro romanziere preferito sia partito dal foglio bianco e abbia seguito tutto il processo; purtroppo, però molto spesso non è così, ma non ci siamo mai preoccupati dei *ghostwriter* e delle *équipe*. Per questo non ha senso farlo ora solo perché quel lavoro lo fa, prima e spesso meglio, un *software* e non una persona. Saremo invasi (e il verbo è già troppo 'apocalittico') da miliardi di contenuti prodotti dalla IA? Probabilmente sì, se l'evoluzione di questa tecnologia va nella direzione che sembra aver preso. Possiamo evitarlo? Penso di no, come del resto non abbiamo evitato per secoli di accogliere contenuti dei cui 'processi autorali' non sapevamo niente. C'è qualcosa di importante che va fatto? Sì, e ne parliamo tra qualche pagina, nella riflessione sulla responsabilità.

6. Non fidarsi (delle immagini) è meglio?

Un'altra attività 'simbolica' nella quale l'IA che usiamo tutti i giorni con-labora, ci aiuta, ci imita in modo 'fantastico' e produce davvero contenuti 'magici' è la produzione di immagini: disegni, fotografie, video, etc. Gli LLM sono infatti già oggi capaci di realizzare contenuti che sono apparentemente così 'umani' che saremo sempre meno capaci di distinguerli da quelli realizzati da nostri simili. Per questo dobbiamo chiederci cosa ci raccontano le crescenti capacità della IA in termini di produzioni di contenuti come immagini e video.

Quadri coerentisti e fotografie corrispondentiste

Cominciamo da una domanda semplice: quando diciamo che una cosa è vera, cosa intendiamo esattamente? Le 'teorie della verità' sono molte ma possiamo usarne due che sono, a mio parere, le più intuitive. La prima è la teoria corrispondentista. In un'ottica corrispondentista, un'affermazione è vera se ciò che afferma corrisponde a uno stato di cose reale, quando gli corrisponde appunto: se dico 'piove' e fuori effettivamente piove, la mia affermazione è vera perché corrisponde a ciò che sta accadendo. La seconda è la teoria coerentista. Va detto subito che le due teorie non sono semplici tecniche di verifica delle notizie: sono modi filosoficamente diversi di intendere la verità. In un'ottica coerentista, la verità di un'affermazione dipende dalla sua integrazione coerente

in un sistema organico di proposizioni: non basta che non contraddica quello che già crediamo, né la nostra personale ignoranza costituisce, da sola, un criterio di falsità: se qualcuno mi racconta di aver visto un uomo volare, la sua affermazione è per me falsa non perché io sia andato a verificarla ma perché non è coerente con quello che so del mondo, e cioè che di norma gli uomini non volano. Applichiamo questa distinzione alle immagini. Per quasi tutta la storia dell'umanità, le immagini sono state strumenti coerentisti: un ritratto dipinto da un pittore medievale non pretendeva di corrispondere esattamente alla realtà ma era una rappresentazione costruita secondo convenzioni, simboli, gerarchie visive che il pubblico di quell'epoca conosceva e condivideva, sentiva cioè coerente con il proprio immaginario mentale; per esempio il re veniva dipinto più grande dei suoi sudditi non perché fosse fisicamente più alto ma perché quella proporzione era coerente con il sistema di valori e significati del tempo. Un'icona bizantina non cercava di riprodurre l'aspetto fisico del santo ma di renderlo riconoscibile attraverso un codice visivo condiviso: il fondo oro che indica il divino, la posizione frontale che segnala la presenza sacra, le proporzioni allungate che alludono alla natura spirituale. Chi guardava quell'immagine non si chiedeva se corrispondesse alla realtà; la sentiva 'vera' perché la avvertiva come un elemento coerente con il sistema di riferimento religioso e culturale che conosceva. Questo dispositivo culturale cambia nel XIX secolo con l'invenzione della fotografia, cioè con l'ennesima svolta tecnologica che modifica prospettive in modo radicale. Per la prima volta nella storia delle immagini, entra in scena uno strumento corrispondentista: un meccanismo che non si limita a costruire una rappresentazione coerente con un sistema di valori ma che cattura,

fisicamente e causalmente, uno stato di cose reale. La luce rimbalza sul volto della persona, colpisce la pellicola e lascia una traccia materiale: tra l'immagine e la realtà c'è una connessione causale e fisica diretta, non mediata dalla mano o dall'intenzione del pittore. Roland Barthes, in *La camera chiara*, chiama la caratteristica fondamentale e irriducibile di ogni fotografia con una espressione precisa: il "questo è stato"; non 'questo assomiglia a qualcosa' ma 'questo è esistito davanti all'obiettivo, in quel momento, in quel luogo' [24]. La fotografia analogica non è solo un'immagine che somiglia al suo oggetto; è un segno che ha una connessione causale diretta, fisico-chimica con ciò che rappresenta. Nel corso del tempo, questa idea si è sedimentata così profondamente nella nostra cultura da diventare un riflesso automatico: vedere una fotografia significa, per noi, da decenni, vedere una prova. La fotografia è entrata nei tribunali come documento, nei giornali come testimonianza, negli album di famiglia come memoria certificata. Abbiamo imparato a fidarci delle immagini fotografiche in un modo che non avremmo mai riservato a un dipinto, per quanto realistico: perché sapevamo, anche senza saperlo esplicitamente, che dietro quella fotografia c'era un 'questo è stato'. Ci siamo dunque abituati a pensare le immagini come testimonianze corrispondentiste, come descrizioni che corrispondono a uno stato di cose reale: se sulla pellicola è rimasto impresso qualcosa significa che (quel) qualcosa certamente era davanti all'obiettivo in quel momento. La fotografia analogica ha dunque costruito per centocinquant'anni una cultura della corrispondenza visiva, prima che un'ulteriore rivoluzione tecnologica cambiasse ancora il modello di riferimento. La differenza tra una fotografia analogica e una digitale non è infatti solo tecnica. Nella fotografia analogica, l'immagine è letteralmente impressa sulla pellicola dalla

luce: c'è una traccia fisica, chimica, materiale che connette l'immagine alla realtà che l'ha generata. Il 'questo è stato' di Barthes è scritto nella materialità stessa della pellicola. La fotografia digitale, invece, non cattura la luce: la misura, la converte in numeri e la ricostruisce. Quello che vediamo sullo schermo o che stampiamo non è una traccia diretta della realtà ma una sua traduzione matematica, una serie di valori numerici che il dispositivo interpreta e restituisce come immagine. La connessione causale con la realtà non è scomparsa del tutto: dietro uno scatto digitale c'è ancora un sensore che ha registrato la luce riflessa da un oggetto reale. Ma quella connessione non è più materiale e diretta; è mediata da un processo di codifica e decodifica numerica che, per definizione, è manipolabile. Ed è precisamente questa manipolabilità che segna il punto di rottura. Una fotografia analogica si può falsificare ma farlo richiede interventi fisici sulla pellicola o sulla stampa che lasciano tracce, che richiedono competenze specifiche e che hanno talvolta un grado di 'impurità visiva'. Un'immagine digitale è invece, nella sua natura più profonda, un *file*: una sequenza di numeri che può essere modificata, integrata, ricostruita senza lasciare nessuna traccia visibile dell'intervento (in virtù di quella capacità da 'protesi di produzione reversibile' dei *computer* della quale abbiamo già parlato); ogni fotografia digitale è potenzialmente modificata, o potenzialmente modificabile, e noi non abbiamo modo di saperlo guardandola. Come abbiamo detto parlando della scrittura, nessuno, vedendo una fotografia, può capire quanta e quale autorialità ci sia dietro quel prodotto (a meno di non esser stato presente al momento dello scatto).

Questo passaggio ha provocato nella nostra cultura visiva una frattura sottile ma profonda. Abbiamo continuato, per inerzia, a trattare le immagini

fotografiche e video come testimonianze corrispondentiste, cioè come prove di 'qualcosa che è stato', mentre il fondamento di quella fiducia si era già assottigliato: senza la fisicità della pellicola, il 'questo è stato' era diventato un 'questo *potrebbe* essere stato'. Con tutti i problemi che questa condizione può produrre.

Due sistemi

È infatti su questa fiducia, costruita in centocinquant'anni di cultura fotografica e già indebolita dalla digitalizzazione, che si innesta il problema più urgente posto dall'IA generativa applicata alle immagini e, soprattutto, ai video.

Per capire perché, in determinate condizioni, le immagini false possano essere particolarmente persuasive, talvolta persino più delle parole false (sulle quali pure ci soffermeremo nella riflessione dedicata alla responsabilità), parliamo di *Pensieri lenti e veloci*, il libro nel quale il premio Nobel per l'economia Daniel Kahneman descrive il funzionamento della mente umana attraverso due sistemi distinti. Il Sistema 1 è veloce, automatico, emotivo e inconsapevole: è quello che ci permette di reagire istantaneamente agli stimoli, di riconoscere un volto, di provare paura prima ancora di aver capito perché. Il Sistema 2 è lento, riflessivo, deliberato: entra in gioco quando dobbiamo valutare razionalmente un'informazione, fare un calcolo, ragionare su un problema complesso [25]. I due sistemi non competono ma si integrano, anche se hanno velocità e criteri di giudizio molto diversi. Le immagini, soprattutto quelle visivamente potenti o emotivamente cariche, parlano direttamente al Sistema 1. Vengono percepite in una frazione di secondo, suscitano reazioni immediate e si radicano nella memoria senza passare per un filtro

razionale. Anche se dopo, a livello cosciente, cioè nella fase di rielaborazione da parte del Sistema 2, raccogliamo evidenze convincenti che un'immagine è falsa o manipolata, il Sistema 1 ne è già stato influenzato: ha reagito emotivamente, ha registrato l'informazione e in qualche misura l'ha integrata nella nostra visione del mondo. Per questo, anche di fronte a smentite razionali, l'impatto di certe immagini continua a condizionarci: la correzione arriva sempre dopo, sempre più lentamente, sempre con meno forza dell'impressione originale. Tutto questo era già vero con le fotografie analogiche ma, in quel caso, esisteva almeno un argine: la connessione causale tra immagine e realtà che abbiamo descritto prima. Quello che stiamo vivendo adesso è qualcosa di strutturalmente diverso: la possibilità di produrre video e immagini di altissima qualità, quindi indistinguibili da riprese reali, ma di eventi che non sono mai accaduti, di persone che non hanno mai detto quelle cose, di luoghi che non esistono. Il giudizio rapido può essere ingannato da contenuti visivi realistici, anche se persone diverse, contesti diversi e segnali di provenienza possono influire sulla capacità di riconoscerli. E il Sistema 2, anche quando interviene per metterne in discussione l'attendibilità, si trova a fare i conti con il fatto che la smentita arriva attraverso lo stesso mezzo e quindi non ha, strutturalmente, più autorità del contenuto che vuole smentire. Immaginiamo un caso concreto. Un video, incredibilmente realistico, di un capo di governo che, sfigurato in volto, rivela di essere stato colpito da un nuovo *virus* contagiosissimo e chiede a tutti di chiudersi in casa. In poche ore il video diventa virale. Il capo di governo reale, quello che è stato imitato così bene nel video falso, è costretto a diffondere a sua volta un video per dare una smentita. Gli autori del primo video ne pubblicano un altro, sostenendo che è il video della

smentita ad essere falso. Cosa succede? Una parte degli utenti non ha nessuna dimestichezza con il fatto che l'IA può dar vita a contenuti così credibili e dunque non può sospettare che i due video falsi siano falsi. Un'altra parte si chiede, razionalmente, perché dovrebbe credere al video della smentita e non agli altri due, visto che arrivano tutti attraverso lo stesso mezzo. E anche i soggetti più lucidi, quelli che decidono di credere alla smentita ufficiale, portano comunque con sé, nel Sistema 1, l'immagine del *premier* sfigurato: quella resta, erode sotterraneamente le certezze, produce un'inquietudine che nessuna smentita riesce a cancellare del tutto. Siamo dunque di fronte a qualcosa che va molto al di là di un problema tecnico di identificazione dei contenuti falsi. Se lo spazio pubblico venisse progressivamente invaso da video generati dall'IA, di altissima qualità e di impossibile certificazione, saremmo costretti a ripensare completamente il nostro rapporto con il concetto di fonte, di autorità, di prova. E di verità. La distinzione corrispondentista sulla quale abbiamo fondato per centocinquant'anni la nostra fiducia nelle immagini, il 'questo è stato' di Barthes, non sarebbe più operativa. E non avremmo, almeno per ora, nessuna alternativa coerentista affidabile con cui sostituirla: perché la coerenza con il nostro sistema di riferimento è esattamente ciò che questi contenuti sanno simulare meglio di tutto.

Con il passare del tempo e con l'evoluzione tecnologica, sarà via via più difficile capire se una immagine o un video siano stati prodotti dalla IA o meno. Non possiamo però presumere che filigrane digitali, metadati di provenienza e obblighi di trasparenza siano sempre presenti, riconoscibili o impossibili da aggirare: strumenti tecnici e regole possono aiutare, ma non assicurano da soli una verifica universale. Se dunque non

possiamo intervenire sulla tecnologia o su chi produce contenuti, censurando l'una o gli altri, è necessario costruire una diversa attitudine di utilizzo di questi contenuti, che rompa quella fiducia che abbiamo sviluppato nel Novecento nei confronti delle rappresentazioni. Costruire questa nuova attitudine non significa vivere in uno stato di paranoia permanente né considerare false tutte le immagini che incontriamo. Significa, purtroppo, cancellare l'automatismo cognitivo che ci porta a trattare ogni immagine come una prova immediata della realtà. Per oltre un secolo abbiamo guardato fotografie e video come tracce causali del mondo, come testimonianze che portavano inscritto dentro di sé il 'questo è stato' di cui parlava Barthes. Oggi questa fiducia non può più essere ingenua. Diventa necessario imparare a sospendere il giudizio immediato, a chiedersi non solo 'cosa vedo?' ma 'da dove viene ciò che vedo?', 'chi lo produce?', 'con quale finalità?', 'quali altre conferme possiedo?'. In questo senso, l'educazione all'immagine smette di essere una competenza specialistica e diventa una forma quotidiana, continua e permanente, di igiene cognitiva. Non per trasformarci in investigatori ossessionati dal falso ma per abituarci a una forma di attenzione che, come vedremo più avanti parlando di responsabilità, riguarda ormai ogni contenuto che incontriamo: immagini, testi, parole, dichiarazioni, confessioni, perfino le lettere d'amore.

7. Vieni avanti creativo

Testi scritti, immagini, video. L'IA fantastica ci aiuta magicamente a fare tantissime cose che, in passato, facevamo solo noi. Dal nostro elenco ne manca ancora una: la musica. Ragionare su quanto già oggi gli LLM siano capaci di produrre contenuti musicali incredibilmente elaborati ci aiuta ad analizzare (e conoscere meglio) un altro pezzo della nostra identità: il concetto (complessissimo) di 'creatività'.

Nel marzo 2026 è stato pubblicato *Another Day Old*, un brano di Eddie Dalton che, in meno di due settimane, arrivato in testa alla classifica dei singoli più scaricati su iTunes. Se provate ad ascoltarlo, noterete come il pezzo abbia un *sound* molto efficace: atmosfere *soul* e *blues*, con un suono molto rotondo e una costruzione armonica classica e piacevole. Difficilmente, invece, dal solo ascolto ricostruirete come sia stato prodotto: il progetto utilizza l'IA per costruire un'identità artistica e una resa musicale sintetiche, ma occorre distinguere questi aspetti dal contributo umano alla scrittura e alla direzione creativa. La domanda che dobbiamo porci è: cambia qualcosa nella nostra esperienza di ascoltatori per il fatto

che non esiste nessun Eddie Dalton, che non possiamo dare per scontata una sessione di musicisti che abbiano inciso la base, né attribuire senza verifiche l'esecuzione degli assoli a strumentisti in carne e ossa? Dopo averlo saputo, il brano ci sembra più freddo, meno significativo, quasi vuoto? Avvertiamo un qualche disagio? La risposta più immediata a queste domande, quella che sentiamo ripetere più spesso nel dibattito pubblico, fa appello alla parola 'creatività'. La musica umana è creativa; quella dell'IA no, o almeno non abbastanza. Se però chiedessimo, a chi difende questa tesi, di argomentarla e dimostrarcela, avrebbe molte difficoltà perché, nella stragrande maggioranza dei casi, richiamare la creatività 'contro' l'IA è solo un atteggiamento difensivo. Serve a rivendicare il fatto che ci sia ancora almeno una competenza esclusiva che quello strumento, si dice, non può vantare. Come a dire: ci imita così bene che sa scrivere, simulare sedute di psicoterapia e relazioni affettive, guidare le auto e regolare le luci in casa ma *almeno la creatività* non potrà mai riprodurla.

Margaret Boden, nel suo *The Creative Mind*, smonta con precisione questo riflesso difensivo. Il punto dal quale parte è il paradosso in cui cadiamo ogni volta che usiamo la parola 'creatività'. Quando ci sediamo davanti a una tastiera, di un *computer* o di un pianoforte, non siamo mai all'anno zero della nostra formazione e tutto il nostro vissuto biografico e intellettuale entra necessariamente nella nostra attività creativa; sappiamo dunque che nessuno di noi produce mai 'dal nulla'. Nonostante questa consapevolezza, ci piace continuare a credere che pochi eletti nella nostra specie ci riescano; che il 'genio' sia il luogo nel quale si manifestano forze sovrumane e sacre. È questo il motivo per cui, secondo Boden, quando guardiamo il film *Amadeus* di Miloš Forman facciamo il tifo per l'impertinente Mozart e

proviamo diffidenza (se non disprezzo) per il pedante, scolastico e forse assassino Salieri. Il film, come il testo teatrale di Peter Shaffer da cui è tratto, costruisce il conflitto tra i due come uno scontro tra due idee opposte di creatività: da una parte il genio misticamente ispirato, che riceve la musica quasi per dettatura divina senza fatica apparente; dall'altra il talento acquisito, fatto di studio, disciplina, tecnica impeccabile ma priva di quella scintilla che non si può imparare. Anche se storicamente lo scontro non è documentato, il mito è rimasto perché risponde a qualcosa che sentiamo in profondità: la convinzione che la vera creatività non si conquisti ma si riceva e che chi lavora troppo duramente per ottenerla manifesti già con questo una assenza di talento. Perché Mozart è la prova che qualcuno della nostra specie può essere toccato da un dono che resta per i più inaccessibile; Salieri, invece, rappresenta la nostra parte comune, metodica, incapace di quella grazia improvvisa. Vorremmo essere tutti Mozart e pensiamo che le nostre macchine siano solo dei Salieri senz'anima.

Boden propone di abbandonare questa immagine romantica (superata ormai da tempo anche dai *visual studies* di autori come W. J. T. Mitchell e J. Elkins). La creatività non è magia: è il risultato di un processo cognitivo complesso che intreccia regole, conoscenze e rappresentazioni, e che si manifesta in tre modi distinti. La creatività combinatoria emerge quando si uniscono elementi già esistenti per generare qualcosa di nuovo: Lucas non inventa da zero i cavalieri, le spade o i maestri saggi ma fonde archetipi del mito e della fiaba per dar vita all'universo narrativo di *Star Wars*, che sembra nuovo pur essendo costruito su strutture antichissime. La creatività esplorativa consiste nel muoversi verso le zone meno note di una mappa culturale che già conosciamo: scoprire nuovi sentieri all'interno di ciò che già esisteva, portare

alla luce porzioni rimaste in ombra. La creatività trasformativa, infine, cambia lo spazio stesso, ridefinendone le regole e rendendo possibili mosse che prima non esistevano [26]. Tre gradi di uno stesso movimento: in tutti i casi, la novità non nasce mai dal vuoto ma dal modo in cui la mente rielabora ciò che ha ereditato. Ora, se la creatività consiste nel combinare, esplorare e trasformare contenuti, regole e strutture già date, allora almeno in teoria anche un sistema di intelligenza artificiale può farlo. Anche lui non crea 'dal nulla' ma 'dai dati': parte da ciò che gli viene consegnato, cioè testi, immagini, suoni, modelli armonici, e li ricombina secondo calcoli statistici che ne amplificano le connessioni, al pari di come noi facciamo con i nostri dati di esperienza. Un LLM addestrato su milioni di brani musicali sa riconoscere le strutture armoniche del *jazz*, le progressioni del *blues*, le architetture del contrappunto barocco; sa combinarle, esplorarle e quindi ri- e de-formarle. I risultati, spesso, sono stilisticamente convincenti; Eddie Dalton nasce probabilmente così: come sintesi di una serie di stimoli legati alla storia e ai canoni estetici della *black music* degli ultimi cento anni. Visto che tanto noi quanto l'IA creiamo ricombinando dati preesistenti, e la quantità di dati che un LLM può gestire e ricombinare è incomparabilmente più ampia di quella sulla quale potremmo basarci noi nel nostro lavoro, dobbiamo concludere che l'arrivo di uno strumento che produce contenuti con tanta rapidità ed efficacia ha decretato la fine della nostra creatività? Abbiamo già perso questa sfida? Io credo di sì, ma non per colpa della IA. E non da oggi. Il problema, infatti, non è che l'IA abbia improvvisamente reso derivativa una produzione culturale che prima era pura originalità. È piuttosto il contrario: l'IA arriva in un ecosistema nel quale da tempo abbiamo accettato che gran parte della

produzione rappresentativa viva di ripetizione, riconoscibilità e continua variazione dello stesso canone. La macchina non crea questo dispositivo culturale; lo eredita e lo accelera.

Non l'abbiamo vista arrivare?

Questa riflessione su quanto l'IA riesca a imitare bene la nostra creatività sarebbe infatti incompleta se ci fermassimo a una analisi teorica e non parlassimo di un aspetto 'storico', del fatto che la capacità della IA di produrre contenuti è arrivata in una epoca molto particolare della storia dell'umanità. Nel 1936 Walter Benjamin pubblica Das *Kunstwerk im Zeitalter seiner technischen Reproduzierbarkeit* (*L'opera d'arte nell'epoca della sua riproducibilità tecnica*). Benjamin affermava che le tecnologie di riproduzione meccanica, cioè la fotografia, il cinema o la stampa, stavano cambiando in modo irreversibile il rapporto tra l'opera e il suo pubblico. Il cambiamento decisivo non era solo estetico, cioè rispetto al fatto che questi strumenti davano vita a prodotti diversi da quelle delle arti figurative classiche. Quella che veniva modificata era proprio la natura dell'opera d'arte: l'originale perde la sua 'aura', quella qualità irripetibile che nasce dall'essere qui, in questo luogo, in questo momento, irriducibile alla copia. La riproducibilità tecnica cancella in qualche modo la singolarità, la irripetibilità del gesto artistico e produttivo [27]. Cosa c'entra questo con l'IA e con il suo 'attacco' alla creatività umana? La nostra fruizione di contenuti è già da tempo educata alla riproducibilità estrema della quale parlava Benjamin; siamo cioè abituati a riprodurre lo stesso contenuto più e più volte, in posti diversi e su vari *device*. L'evoluzione dei nuovi strumenti tecnici che hanno permesso questa estrema riproducibilità dei contenuti è

stata rapidissima: la *performance* musicale da ascoltare 'qui e ora' in un concerto è stata sostituita dal vinile, rimpiazzato poi dalle musicassette, a loro volta sostituite dai CD, superati poi dagli MP3, al posto del quale è infine arrivato lo *streaming*; ovviamente pari discorso è possibile farlo sui manoscritti rispetto alla stampa e all'*ebook* o rispetto al passaggio da foto analogiche a immagini digitali. La musica non si possiede più: si ascolta, riprodotta infinitamente, ovunque. Le fotografie, un tempo rarità preziose, si contano oggi in migliaia per persona e vengono scartate senza rimpianto. I libri, che occupavano anche 'geograficamente' porzioni delle case, sono oggi *file* che, con una semplice sincronizzazione in *cloud*, posso leggere da qualsiasi *device* in ogni momento. I *film* si guardano su qualsiasi schermo, in qualsiasi momento, interrotti e ripresi. La riproducibilità è diventata così pervasiva da non essere più nemmeno percepita come tale: è semplicemente il modo normale in cui consumiamo contenuti. Questa accelerazione tecnica ha prodotto un nuovo racconto tecno-economico: abbiamo gli strumenti per consumare di più e più spesso; dunque, c'è più mercato per i prodotti culturali: più spazio per ascoltare più musica, per guardare più *film*, per leggere (o almeno acquistare) più libri. Ma come sempre avviene, quando un mercato si amplia così tanto e si apre un nuovo, enorme spazio per la distribuzione di contenuti, la produzione aumenta in quantità a discapito della originalità. Così, nel corso degli anni ci siamo assuefatti al ciclico riprodursi di contenuti apparentemente diversi ma sostanzialmente identici: *plot* di serie tv, ritmi e armonie di tormentoni musicali, *format* di trasmissioni televisive, etc. Viviamo cioè già da tempo in un mondo nel quale la produzione di contenuti vive di un accordo collettivo e tacito, per il quale va benissimo a tutti usufruire di contenuti prodotti in serie e sempre più

o meno uguali; se così non fosse, se volessimo solo prodotti dalla forte identità e non derivativi, dovremmo abituarci a librerie molto più vuote, a *playlist* meno corpose e a un elenco di serie tv molto più risicato. Quando i sistemi di intelligenza artificiale hanno cominciato a produrre testi, immagini, musica, video hanno trovato un pubblico che aveva già imparato a ricevere, consumare e valorizzare prodotti culturali senza chiedersi se ci fosse dietro un originale irripetibile o, meglio ancora, senza pensare la originalità come un valore.

Negli ultimi mesi, per indicare la marea di contenuti generati dall'IA che invade piattaforme e classifiche, si è diffusa un'espressione poco elegante: *AI slop*, la 'sbobba' artificiale. Il successo di Eddie Dalton ha indignato proprio i nemici dello *slop*, preoccupati che la macchina riempia e sporchi il mercato culturale. È un'indignazione comprensibile ma, a mio parere, miope, per due motivi. Il primo è che accusare l'IA di produrre contenuti che ci somigliano significa accusarla di fare esattamente ciò per cui l'abbiamo costruita: imitarci. È l'orrore che la nostra letteratura conosce almeno da *Frankenstein*, la paura che nasce non quando l'esperimento fallisce ma quando riesce. Il secondo è che parlare di spazzatura prodotta da un sistema che attinge da ciò che abbiamo prodotto noi è quasi comico: è come consegnare a uno chef ingredienti scadenti e poi insultarlo perché il piatto non ci piace. Le canzoni e i romanzi generati dall'IA non sono uno scandalo: sono un *selfie* del nostro gusto musicale e letterario degli ultimi vent'anni. E forse non ci piace ammettere che, insieme a tante cose belle, abbiamo prodotto anche molto *human slop*.

C'è però un indizio che va nella direzione opposta, e che riguarda non ciò che produciamo ma ciò

che cerchiamo. Nel maggio del 2026 sono stato al Salone del Libro di Torino: decine di migliaia di volumi di carta, un vistoso anacronismo in un'epoca in cui migliaia di libri stanno nella memoria di un telefono, eppure un successo di pubblico che non accenna a diminuire. Qualche mese dopo ho passato otto ore in un prato di Agnano, a Napoli, per un concerto di Jovanotti. In entrambi i casi non andavo a cercare un contenuto, che avrei potuto trovare altrove con meno spesa e meno fatica, ma qualcosa che accade una volta sola, in un luogo preciso, e al quale ha senso partecipare per il semplice fatto di esserci, insieme ad altri che hanno scelto di esserci: un posto 'con-veniente', nel senso letterale di luogo in cui 'venire insieme'. L'unicità di cui parlava Benjamin non è scomparsa: si è spostata dall'oggetto all'esperienza. Più è difficile, nell'epoca della iper-riproducibilità, possedere cose uniche, più andiamo in cerca di esperienze irripetibili.

Quando pensiamo alle potenzialità della IA, il primo rischio che ci viene in mente è che sia usata male: per falsificare, per manipolare, per sostituire il pensiero con il calcolo. Ma c'è un rischio meno ovvio e altrettanto reale: che venga usata in modo mediocre. Benjamin lamentava la perdita dell'aura ma sapeva anche che la riproducibilità tecnica aveva fatto anche qualcosa di storicamente inedito e prezioso: aveva portato l'arte fuori dai 'templi' (musei, teatri, sale da concerto) e l'aveva consegnata a chi non aveva mai avuto i mezzi per raggiungerla. La fotografia, il cinema, il disco: strumenti di perdita ma anche di accesso. La stessa ambivalenza vale oggi, in modo ancora più radicale. L'IA sembra distruggere il mito della nostra creatività individuale ma, per un altro verso, è capace di eliminare barriere di accesso alla produzione che fino a pochi anni fa erano

altissime: chi per esempio desidera fare musica da solo ha oggi a disposizione quello che fino a ieri richiedeva uno studio di registrazione, un arrangiatore, un produttore, strumenti costosi e complessi. Invece di preoccuparci di denunciare la natura non creativa dei *software* di produzione video o audio, vale la pena chiedersi se saremo capaci di sfruttare questa nuova strumentazione: l'IA ci aiuta in modo efficace a realizzare ciò che abbiamo in mente, a patto di avercelo quel qualcosa, in mente. Prima di chiederci se l'IA ha creatività e se, peggio ancora, ce la sta rubando, dobbiamo infatti domandarci come e per cosa abbiamo usato la nostra creatività in questi ultimi decenni, ben prima che l'IA arrivasse a minacciarla. Potremmo tristemente accorgerci che l'IA non può insidiarla, sostituirla o addirittura cancellarla perché, accettando la logica smaterializzata e riproduttiva degli ultimi decenni, abbiamo già provveduto noi ad anestetizzarla con cura.

8. Rossana, Cristiano e Cyrano

Abbiamo fino a qui esplorato perché una IA magica e fantastica ci attrae e in che cosa con-labora con noi (testi, video e audio, per dirlo in sintesi). Ora è il momento di ragionare su quali responsabilità sono implicate dall'esistenza di questa nostra copia fatta così bene.

Abbiamo detto, parlando di produzioni umane, che più migliorano le tecnologie di (ri)produzione dei contenuti più per un verso diventa impossibile capire quanta autorialità 'originaria' ci sia in quello che abbiamo davanti e più, per un altro, ci abituiamo a contenuti sempre uguali e non originali. Abbiamo aggiunto che questo *trend* è probabilmente così potente e irrefrenabile da prospettare un futuro pieno di contenuti prodotti dalla IA e che a nulla varranno i tentativi tecnologici di 'marcare' questi prodotti per rendere trasparente il fatto che siano realizzati dalla IA. Di fronte a questa ineluttabilità, c'è qualcosa che però possiamo fare e che, anzi, avremmo dovuto fare (da) sempre.

Nel *Cyrano de Bergerac*, il dramma di Rostand del 1897, Cyrano, spadaccino e poeta dal naso molto pronunciato, è innamorato di Rossana, alla quale però

non si dichiara mai. Rossana invece gli confida di amare il cadetto Cristiano per la sua grande bellezza. Cyrano si accorge molto presto che al fascino di Cristiano non si accompagna una altrettanto ricca capacità retorica e poetica; allora, pur di far felice la donna che segretamente ama, Cyrano decide di suggerire a Cristiano le parole giuste in tutte le occasioni. Il trucco funziona e, alla fine dell'atto III e prima della partenza per la guerra, Cristiano e Rossana si sposano. Il giovane cadetto, nonostante abbia ottenuto ciò che voleva, è però tormentato dall'inganno che ha messo in piedi, soprattutto quando, nell'atto IV, Rossana gli confessa di amarlo non solo per la bellezza esteriore ma per la sua anima, cioè per quelle parole che sue non sono. Cristiano non ha però il tempo di confessare e chiedere perdono; muore in guerra seppur con l'animo alleggerito dal senso di colpa: Cyrano, per farlo morire pacificato, gli ha infatti raccontato, mentendo, che Rossana aveva scoperto tutto e che tra i due aveva scelto il marito e non il poeta suggeritore. Dopo la morte di Cristiano, Rossana si chiude in lutto in un monastero dove, ogni sabato, Cyrano va a trovarla. Un sabato, mentre si sta recando in visita dalla sua amata, Cyrano è vittima di un agguato. Anche se ferito, non rinuncia al suo appuntamento ma, poco dopo il suo arrivo, sviene per il dolore. Rossana amorevolmente gli si avvicina e Cyrano le chiede di dargli l'ultima lettera che ha ricevuto da Cristiano perché vorrebbe leggerla. Nonostante il buio, Cyrano la declama alla perfezione (perché la ricorda da quando l'aveva scritta) e, in quel momento, Rossana capisce tutto; scoperto "il nobile imbroglio", gli chiede perché per quattordici anni ha tenuto per sé questo segreto, piangendo il suo destino di vedova due volte infelice: "Amavo un sol essere e due volte lo perdo!". Così si conclude il dramma. Proviamo a immaginare un esito diverso della storia. Cristiano e

Rossana, marito e moglie, si ritrovano dopo la guerra, che ha risparmiato il cadetto. Mettono su casa, vivono una vita agiata e mediamente normale. Ogni tanto, Rossana si avvicina con sguardo languido a Cristiano, quasi chiedendogli di rinverdire i tempi romantici nei quali, da sotto al balcone, le sussurrava parole dolcissime. Cristiano ci prova; tenta di mettere assieme due o tre cose che ricorda dei suggerimenti di Cyrano ma con scarsissimo successo e non riesce a *rispondere* alle richieste di Rossana. Dopo un po', Rossana comincia a sospettare di essere stata vittima di un inganno e costringe Cristiano a confessare, per poi insultare sia lui che Cyrano per averla presa in giro. In questa nostra variante, l'inganno viene scoperto: Cristiano si è attribuito la paternità di quelle parole e ne ha sfruttato a suo vantaggio l'effetto ma non sa assumersene la *responsabilità*, che significa, letteralmente, non sa risponderne (in questo caso alle domande di Rossana). Oggi, un bel cadetto che non sa dire parole romantiche non ha bisogno dell'aiuto di uno spadaccino con il naso lungo; un *prompt* scritto bene permette di inviare messaggi e lettere d'amore perfette. Resta però il tema di quell'esercizio di responsabilità, che è interamente etico e che non può essere risolto né con soluzioni tecnologiche né con strumenti 'polizieschi'. È infatti molto difficile, l'abbiamo già detto, che sia possibile mettere a punto strumenti che individuino o 'marchino' i contenuti prodotti dalla IA per rendere trasparente una forma di autorialità 'artificiale'; men che mai, in questi casi, funziona la leva punitiva, quella che stabilisce per legge che l'uso della IA debba essere dichiarato. È invece indispensabile investire in una educazione alla responsabilità che sarebbe già servita in passato (ai Cristiano e ai Cyrano) e che invece, in questi secoli, raramente abbiamo perseguito; abbiamo dato vita tantissime volte a prodotti di autorialità ibrida, creati a più

mani, a volte completamente delegati senza (quasi) mai preoccuparci di indicare, da qualche parte, chi avesse fatto cosa (ne abbiamo parlato nella riflessione sulla scrittura). Siamo stati tutti, almeno una volta, o Cristiano o Cyrano: o abbiamo presentato come nostre cose che nostre non erano o abbiamo realizzato *in toto* cose che poi altri si sono attribuiti senza menzionarci.

Questo 'esercizio di responsabilità', questo dichiarare, quando possibile, quanta parte del nostro lavoro sia stata delegata (a un *ghostwriter* umano o digitale poco conta) non è però l'unico investimento etico che è oggi necessario. Così come, in tante occasioni, siamo stati Cristiano o Cyrano, in tantissime altre abbiamo accettato testi e prodotti dei quali non conoscevamo in alcun modo la provenienza perché abbiamo preferito pensare che chi li aveva firmati ne fosse anche l'autore totale. Siamo stati tutti, per secoli, anche un po' Rossana, ed è stato normale esserlo: non potevamo seguire in ogni fase il nostro romanziere preferito per capire se quello che aveva scritto lo aveva scritto veramente lui. Abbiamo dunque già vissuto una lunga epoca di riproducibilità del contenuto, di non tracciabilità della sua autorialità, e non ci siamo né indignati né premuniti. Oggi però, che è ancora più semplice produrre quei contenuti, non possiamo più essere Rossana e dobbiamo fare maggiore attenzione all'origine di ciò che ci capita tra le mani. L'IA generativa applicata all'audio, al video e alla scrittura porta infatti il problema della fiducia nella provenienza e nella affidabilità dei contenuti a un livello qualitativamente diverso: non si tratta più di immagini ritoccate o di foto manipolate ma della possibilità concreta e già praticata di costruire dal nulla contenuti indistinguibili dalla realtà. Il progressivo miglioramento delle tecnologie di produzione di contenuti audio e video rende già oggi tecnicamente semplicissimo dare vita a

materiali diffamatori, vessatori e illegali: un volto noto su un corpo che non gli appartiene; una voce riprodotta per pronunciare parole mai dette; un video costruito per distruggere una reputazione, per ricattare una persona, per alterare l'esito di una competizione elettorale. Ma anche (e forse con ancora più facilità) un documento scritto: una lettera formalmente impeccabile intestata a un'istituzione che non l'ha mai redatta, un referto medico, un contratto, una sentenza, una dichiarazione attribuita a qualcuno che non l'ha mai rilasciata. Testi graficamente perfetti, stilisticamente convincenti, privi di qualsiasi imperfezione che in passato avrebbe potuto insospettirci. Questi esempi non sono scenari futuri e distopici: sono pratiche già documentate, già usate, già in grado di produrre danni reali e irreversibili a persone reali, spesso prima che qualsiasi smentita riesca a raggiungerle. Di fronte a questo, la responsabilità personale di cui abbiamo parlato (dichiarare quando ci si affida a un IA per produrre un contenuto) non basta più, o almeno non basta da sola; occorre uno strumentario personale di verifica che non si affidi al buon cuore etico di chi condivide contenuti, nella speranza che dichiari sempre e con trasparenza quanto e come ha usato l'IA. Quello che serve è qualcosa di più profondo, di più difficile da costruire ma che è in potere di ciascuno: un'abitudine, una postura mentale quotidiana e permanente che potremmo chiamare il 'tempo della cura'. Perché un 'tempo'? E di cosa dovremmo prenderci 'cura'? Il fattore-tempo è decisivo nella nostra fruizione di contenuti digitali, per due motivi. In primo luogo, perché siamo sempre più abituati a ridurre i tempi di risposta: vediamo un contenuto e spesso in pochi secondi decidiamo di rispondere, di indignarci o di commuoverci; viviamo in una 'dittatura dell'attimo', un governo invisibile delle cose nel quale si parla sull'onda di una

emotività perennemente sovrastimolata da notifiche, *feed* infiniti e algoritmi che costringono la nostra mente in un ciclo continuo di stimoli e risposte, riducendo la soglia di attenzione e il pensiero critico. In secondo luogo, perché (come abbiamo già detto parlando di Kahneman) il nostro Sistema 2, quello che razionalmente valuta e soppesa le informazioni, è più lento del Sistema 1, che invece viene colpito subito e in modo profondo. È dunque necessario avere un *tempo* utile a valutare in modo onesto e completo i contenuti che abbiamo davanti. Resistere alla tentazione di commentarli subito, di ripostarli, di ricondividerli e concederci la possibilità di fare qualche controllo, verificare se quel contenuto è stato condiviso da fonti che riteniamo autorevoli o, nel caso avessimo dei dubbi, desistere dal diffonderlo e commentarlo. Ci saremo così concessi il tempo per prenderci *cura* di tutti gli attori in gioco: di noi stessi, perché non ci saremo resi complici della diffusione di informazioni false o non attendibili e avremo così preservato la nostra indipendenza di giudizio; degli altri, perché avremo speso energie per garantire loro il beneficio del dubbio e, nel caso non fossimo riusciti a scioglierlo quel dubbio, li avremo tutelati tacendo. Perché dietro ogni contenuto che ci arriva c'è quasi sempre una persona reale, con una storia reale, che può essere o rappresentata fedelmente in quella foto e in quel testo o, nel caso opposto, danneggiata in modo irreversibile da una nostra reazione non abbastanza pe(n)sata. Ma avremo avuto cura anche delle tecnologie che usiamo, che rischiano di essere bollate come tossiche per le loro enormi potenzialità, quando la tossicità risiede non nella loro natura ma nell'uso che ne viene fatto.

Negli *Academica*, composti attorno al 45 a.C., Cicerone sosteneva che nel giudicare ciò che non possiamo

conoscere con certezza possiamo orientarci verso rappresentazioni più persuasive o probabili, valutandone gli elementi a favore, senza trasformare questa posizione in una regola meccanica basata sul mero numero delle conferme. La sua teoria viene definita 'probabilismo', dal verbo latino *probare* che significa appunto 'portare prove'. Il ragionamento è semplice ma potente. Supponiamo di dover decidere se affidarci a un capitano per un lungo viaggio in nave. Nessuno può garantirci con certezza assoluta che andrà tutto bene. Possiamo però raccogliere elementi che ci convincano: verificare l'esperienza e il curriculum del capitano, controllare lo stato della nave, consultare le previsioni meteorologiche. Nessuna di queste eventuali conferme renderà 'vera' la promessa di buon esito del viaggio; essa sarà però progressivamente sempre più 'probabile', cioè supportabile tramite prove [28]. In un senso ciceroniano, il tempo della cura è la disponibilità a sospendere il giudizio immediato per lasciare spazio a una valutazione lenta e riflessiva, che sa fare le domande giuste per *probare*, per trovare prove: da dove viene questo contenuto? Chi lo ha prodotto e perché? Cosa perdo e cosa rischio se mi sbaglio? Cosa rischia, se mi sbaglio, chi è ritratto in questa foto o indicato in questo documento? In cosa comprometto la mia fiducia e quella della mia comunità nel mezzo tecnologico che stiamo usando? Questo esercizio, oggi, non è più una questione di deontologia professionale riservata, per esempio, a chi si occupa professionalmente di informazione. È una pratica civica di base, necessaria per chiunque riceva e condivida contenuti in un ecosistema nel quale il grado di affidabilità con il quale accogliamo e soprattutto diffondiamo un prodotto digitale può compromettere la qualità dell'esistenza e l'esistenza stessa degli altri.

Il cambio di paradigma tecnologico implica dunque un cambio di paradigma valutativo. A un aumento esponenziale delle possibilità di trovarsi di fronte contenuti falsi e tossici deve corrispondere un aumento parimenti esponenziale dei nostri livelli di attenzione, di decostruzione, di ricerca delle fonti, di valutazione delle informazioni. Un'abitudine continua a un tempo della cura inteso non come diffidenza sistematica ma come esercizio quotidiano di attenzione: verso i contenuti che riceviamo, verso le persone che vi compaiono, verso noi stessi come nodi di una rete nella quale ciò che diffondiamo ha sempre conseguenze reali su vite reali. Non è un compito straordinario che si attiva in occasioni eccezionali ma una postura permanente, che ci può aiutare a restare in equilibrio tra l'ingenuità facilona del condividere tutto e subito e l'ansia apocalittica di chi avverte vicino il momento nel quale si esaurirà la possibilità di una comunicazione genuina. Prendersi la responsabilità di ciò che si diffonde, però, non basta. Per rispondere davvero di un contenuto bisogna anche essere in grado di valutarlo, cioè avere le competenze per produrlo: è il secondo livello di questo esercizio, e ne parliamo nella prossima riflessione.

9. Impalcature e protesi

Nella quinta riflessione ho raccontato dei quattro candidati alla laurea che mi consegnano le loro tesi e ho concluso che non posso sapere quale sia stata scritta da loro, quale dall'IA e quale da un'agenzia. È una conclusione che mette a disagio chiunque insegni, e che di solito produce una domanda: come faccio a capire se questo testo è stato fatto con l'IA? Ken Hyland, uno dei linguisti che più hanno studiato la scrittura accademica, in *Writing in the AI era* propone di sostituirla con un'altra, più scomoda e più utile: che tipo di scrittura, e di scrittori, vogliamo formare?

Fluenza e voce

Hyland osserva che ogni tecnologia della scrittura (il programma di videoscrittura, il correttore ortografico, il traduttore automatico) è arrivata accompagnata da reazioni opposte, apocalittiche o entusiaste, e poi è stata lentamente addomesticata. L'IA generativa è diversa perché mette alla prova i nostri valori educativi: se una macchina produce in pochi secondi un saggio convincente, che cosa resta della scrittura come luogo in cui si impara? Gli strumenti di IA, scrive Hyland,

possono sostenere le risorse linguistiche di chi scrive e aprirgli l'accesso ai generi delle discipline; ma rischiano anche di impoverirne le competenze, di appiattire la voce dell'autore, di oscurare la responsabilità.

Per capire che cosa sia in gioco, è utile distinguere due qualità di un testo. La prima è la fluenza: un testo fluente scorre in modo naturale, senza inciampi, con un ritmo piacevole; è ciò che riconosciamo subito come 'scritto bene'. La seconda è la voce, che non è semplicemente lo stile o un'impronta personale ma qualcosa di più dinamico: non esiste prima della scrittura, si costruisce scrivendo. Ogni volta che scriviamo decidiamo come posizionarci rispetto a chi legge, quanto spingerci nel sostenere un'affermazione, quanto concedere alle posizioni altrui. È un lavoro di calibrazione continua, che richiede qualcuno in carne e ossa che se ne faccia carico pensando a qualcun altro, altrettanto in carne e ossa, che leggerà. Un testo generato da un LLM è quasi sempre impeccabile sul piano della fluenza; ma dietro non c'è nessuno che stia davvero prendendo posizione. Suona giusto, ma non risuona vero.

Il punto, per chi insegna, è che la fluenza è esattamente la qualità che per decenni abbiamo imparato a riconoscere e a premiare come segno di competenza. Quante tesi abbiamo valutato bene perché più scorrevoli della media, senza chiederci se chi le aveva scritte avesse davvero 'voce in capitolo', avesse cioè preso posizione su qualcosa? Si può riprodurre il ritmo di uno scritto, la sua superficie levigata, senza aver attraversato nessuna delle fatiche nelle quali l'apprendimento accade davvero: generare idee, scartarne altre, riscrivere dopo una critica, decidere come rivolgersi a un lettore reale. Chi non attraversa quella fatica non sviluppa una voce. Produce fluenza.

Lo specchio

C'è però una domanda che dobbiamo rivolgere a noi stessi prima che agli studenti. Uno dei timori più diffusi è che l'uso massiccio dell'IA ci faccia dimenticare il pensare attraverso la scrittura, quel lavorìo nel quale spesso scopriamo che cosa avevamo davvero da dire proprio mentre proviamo a dirlo. È un timore fondato? Proviamo a chiederci quanto di ciò che scriviamo ogni giorno sia davvero pensiero e quanto sia invece formula, abitudine, ripetizione. Relazioni, verbali, *mail*, gran parte della stessa scrittura accademica: generi che si reggono da tempo su moduli fissi, su un lessico condiviso, su strutture che si imparano e si replicano. Se temiamo di perdere il pensiero che si fa scrittura, forse è perché sappiamo di averlo già in parte delegato: ai *format*, ai modelli, alle consuetudini. Abbiamo scritto come macchine ben prima che le macchine scrivessero per noi.

In questo senso l'IA funziona, ancora una volta, come uno specchio: ci costringe a chiederci quanto di noi abbiamo davvero investito nella scrittura e quanto l'abbiamo resa un esercizio meccanico, quindi riproducibile, persino quando raccontavamo le storie che sentiamo più nostre e che, a forza di raccontarle sempre allo stesso modo, sono diventate anch'esse una formula.

La finestra

Accanto allo specchio c'è però un'altra metafora, che indica non che cosa abbiamo perso ma che cosa possiamo guadagnare. La propone un gruppo di ricercatori guidato da Cody Kommers (lo stesso studioso che incontreremo nella undicesima riflessione, a proposito dell'ermeneutica) in un lavoro intitolato *The House with a Million Windows* [29]. Gli autori individuano

un rischio preciso: la scrittura assistita dall'IA tende ad appiattire il significato delle storie che raccontiamo, a produrre testi omogenei senza lo sforzo intenzionale e il lavoro di senso che la scrittura comporta. Per contrastarlo, i tre studiosi hanno costruito una piccola finzione interattiva in tre movimenti.

Nel primo, "l'avvicinamento", chi partecipa si ritrova di notte in un bosco, si perde e arriva davanti a una casa misteriosa. Un guardiano offre riparo e in cambio chiede di raccontare una storia vera della propria vita. Nel secondo, "la casa", si entra in una stanza piena di finestre, nessuna uguale all'altra. Dietro ciascuna c'è la propria storia, riscritta dall'IA con lo stile e la struttura di una grande opera letteraria (*Orgoglio e pregiudizio*, per esempio) secondo regole esplicite, che chi legge può consultare. Nel terzo, la partenza, arriva l'alba: il guardiano chiede di raccontare di nuovo la propria storia, questa volta con parole proprie, avendo davanti le versioni viste alle finestre.

Non ho resistito alla tentazione di rifare l'esperimento in modo artigianale. Ho chiesto a Claude di riscrivere il prologo del mio primo romanzo, *Terapie*, alla maniera di Stefano Benni, Italo Calvino e Andrea Camilleri, e poi di Paul Auster, Jo Nesbø e Stephen King. Il risultato, che potete recuperare nella sezione *Finizioni* della mia pagina Web, non sono capolavori; ma è stato bellissimo usare quelle finestre per guardarmi attraverso, e scoprire che cosa una macchina riconosce come 'stile' di un autore e che cosa invece le sfugge. L'esperimento dei ricercatori e il mio dicono la stessa cosa: usata con una delega in bianco, l'IA contrae, appiattisce, omogeneizza; usata come una finestra, espande, moltiplica le prospettive e ci restituisce le nostre storie più ricche di prima. Non può raccontarle al posto nostro:

se per raccontare le nostre storie ci serve l'IA, o non sono davvero nostre o non valeva la pena raccontarle.

Firmare ciò che si sa fare

C'è poi una seconda questione, che riguarda non solo chi impara ma chiunque usi l'IA per produrre contenuti. Nella riflessione precedente abbiamo detto che, davanti a un testo prodotto con l'IA, ciò che conta davvero è chi ci mette la firma e la faccia, cioè chi è pronto a risponderne. Ma per rispondere di qualcosa bisogna essere in grado di valutarlo. Nella ricerca scientifica questo principio è la prassi: la revisione di un articolo si chiama *peer review* proprio perché la fa un pari, qualcuno che ne sa almeno quanto chi lo ha scritto. Vale lo stesso per noi utenti? Posso firmare un testo scritto con l'IA se non saprei scriverlo altrettanto bene? Posso pubblicare un brano musicale se non so suonare né cantare? E, più in generale, come posso verificare fino in fondo la bontà e la coerenza di un contenuto che, senza l'IA, non avrei saputo produrre?

Facciamo un esempio concreto. Immaginiamo un programmatore che affidi a Claude o a ChatGPT la scrittura di migliaia di righe di codice. Molto probabilmente non le controllerà una per una: il vantaggio di delegarle sta proprio nel tempo che risparmia, e se il programma funziona non avrà motivo di rileggerle. Ma, se volesse, saprebbe farlo; e se domani i server di quei sistemi si spegnessero, potrebbe sedersi al computer e riscrivere quel codice da capo. Ora immaginiamo che la macchina gli proponga qualcosa di diverso: un linguaggio di programmazione nuovo, inventato da lei, che le permetterebbe di fare lo stesso lavoro nella metà del tempo e con meno risorse. Se il programmatore accettasse, si troverebbe davanti a un prodotto scritto in una lingua che non conosce e che non

domina. Potrebbe verificarne l'efficacia (il programma funziona o no), ma non che cosa sia stato fatto né come. E se un giorno non avesse più accesso a quel sistema, non saprebbe nemmeno fare la manutenzione del suo software. A quel punto non sarebbe più lui a governare lo strumento: sarebbe lo strumento a governare lui.

Lo stesso vale per la scrittura. Posso delegare all'IA una relazione, un verbale, una tesina perché in quel momento non ho tempo o non ho voglia di scriverli; ma se fossi costretto a farlo da solo, perché il sistema non funziona o non è a mia disposizione, ne sarei capace. In questo caso la mia competenza è pari o superiore a quella dello strumento che uso, e lo strumento resta tale: qualcosa che uso, non qualcosa che usa me. Davanti a un contenuto prodotto con l'IA, dunque, le domande da fare sono due, e vanno fatte insieme. La prima riguarda la responsabilità: chi risponde di questo contenuto? La seconda riguarda la competenza: chi lo ha prodotto aveva competenze almeno pari a quelle dello strumento che lo ha realizzato? Se manca la seconda, la prima diventa fragile: firmo qualcosa che non so valutare e quindi non posso davvero difendere. Solo se possiedo le competenze che affido alla macchina sono io a delegare. Quando invece la macchina fa ciò che io non saprei fare, non sto più delegando: sto obbedendo. Non sono più io a usare lo strumento; non è più un mio collaboratore, come abbiamo detto all'inizio, ma ne dipendo.

La catena

Come si diventa dipendenti? Un gruppo di studiosi di sistemi complessi, epidemiologia e biologia, tra i quali Ricard Solé, David Krakauer, Michael Levin e l'italiano Manlio De Domenico, ha provato a rispondere prendendo sul serio una metafora che usiamo da anni

senza pensarci: quella del contagio [30]. Il loro modello matematico divide la popolazione in tre gruppi: chi usa poco o nulla i modelli linguistici; chi li usa regolarmente ma conserva la propria autonomia, come chi segue il navigatore ma saprebbe tornare a casa anche senza; chi ha delegato stabilmente alla macchina alcune operazioni mentali e non sa più farle da solo. Il dato interessante è che il passaggio tra questi stati non è graduale: finché la spinta all'adozione cresce poco alla volta la popolazione resta autonoma, ma superata una certa soglia il sistema non scivola, salta. E, una volta saltato, non torna indietro per la stessa strada: per ritrovare l'autonomia non basta riportare la pressione al livello di prima, bisogna scendere molto più in basso. I fisici chiamano questo fenomeno isteresi; in termini più semplici, prevenire è molto più facile che invertire. Si tratta, va detto, di un modello teorico e non di una misurazione; ma la forma che descrive è sorprendentemente antica. Nell'ottavo libro delle *Confessioni*, raccontando gli anni in cui desiderava cambiare vita senza riuscirci, Agostino descrive esattamente questa dinamica e la chiama 'catena': dalla volontà perversa si genera la passione, l'ubbidienza alla passione genera l'abitudine e l'acquiescenza all'abitudine genera la necessità. *Dum consuetudini non resistitur, facta est necessitas*: finché non si resiste all'abitudine, l'abitudine diventa necessità. E la volontà nuova, aggiunge, non riusciva ancora a vincere quella vecchia, ormai 'indurita dall'anzianità' [31]. È l'isteresi del modello matematico, sedici secoli prima.

Se la logica della catena è antica, anche il rimedio lo è. La variabile decisiva, secondo gli autori del modello, non è quanto usiamo l'IA ma come la usiamo. Un supporto esterno può funzionare da impalcatura (*scaffolding*), che riduce la fatica immediata ma lascia intatta, o addirittura accresce, la nostra capacità di fare da

soli; oppure da sostituto, che elimina il bisogno di compiere l'operazione mentale. La domanda giusta non è dunque se usare o evitare l'IA, ma quali capacità ci restano quando lo strumento viene tolto. In uno studio citato nel loro lavoro, chi aveva seguito una regola semplicissima, prima pensa e poi chiedi a ChatGPT, si è dimostrato in seguito più creativo di chi l'aveva usato liberamente fin dall'inizio.

Nella prima riflessione, con Stiegler, abbiamo detto che siamo esseri costitutivamente protesici: la tecnica nasce da un nostro difetto originario, e da sempre compensiamo con strumenti ciò che la natura non ci ha dato. Il problema, dunque, non è usare protesi; è distinguere tra quelle che ci rendono capaci e quelle che ci rendono incapaci. L'impalcatura sostiene l'edificio finché i muri non stanno in piedi da soli, e poi si smonta; la protesi che sostituisce una funzione che avevamo finisce per renderla superflua e, a forza di non essere esercitata, quella funzione non c'è più. L'IA può essere l'una o l'altra. Dipende da noi, non da lei. Per questo scuole e università contano oggi più che mai. Sono i luoghi nei quali leggere, scrivere e ragionare da soli è un esercizio così comune da diventare normale: sono, per riprendere la metafora del contagio, l'immunità di gregge della nostra autonomia. Torniamo allora alla domanda di Hyland. In un futuro in cui la fluenza sarà sempre più spesso garantita dalla macchina, lo scrittore potrebbe essere anche soltanto colui che rielabora, verifica, valuta e corregge un testo prodotto dall'IA. Anche in quel caso, anzi soprattutto in quel caso, conterà la voce: la capacità di prendere posizione, di diffondere solo testi coerenti con la propria visione del mondo, di avere rispetto per i temi trattati e per chi leggerà. Non è l'IA il virus. Il virus, se c'è, è l'abitudine a non resistere all'abitudine; e l'unico vaccino che conosciamo si chiama esercizio, e si fa

insieme. Di questo esercizio parliamo nella prossima riflessione.

10. Pensare stanca. Per fortuna

Tutte le tecnologie che, nel corso dei secoli, abbiamo inventato avevano come scopo sollevarci da una fatica: la leva e la carrucola ci hanno sollevato dai pesi, il mulino dalla macina, la locomotiva e l'automobile dalla strada da percorrere a piedi, l'ascensore dalle scale, la lavatrice da ore di fatica curvi su un lavatoio. Nessuno di noi rimpiange quelle fatiche, e sarebbe ipocrita farlo: liberarsene ha significato tempo, salute e, per milioni di persone, una vita diversa. Mentre ci sollevavano, quelle macchine ci hanno però anche insegnato qualcosa su di noi che non sapevamo, o che non avevamo mai avuto bisogno di sapere.

Il bigliettaio e l'autista

All'inizio degli anni Cinquanta un epidemiologo inglese, Jerry Morris, riportò nello studio *Coronary heart-disease and physical activity of work* un dettaglio interessante legato agli autobus a due piani di Londra. Su ogni mezzo lavoravano due uomini: l'autista, che passava la giornata seduto al volante, e il bigliettaio, che saliva e scendeva le scale centinaia di volte al giorno per staccare i biglietti ai passeggeri. Stessi turni, stessa città, stesso autobus. Eppure i bigliettai si ammalavano di cuore molto meno degli autisti e, quando accadeva, in forma meno grave. Da quell'osservazione è nata, di fatto, l'epidemiologia dell'attività fisica: l'idea che il movimento, che per

millenni la vita ci aveva imposto senza chiedercelo, fosse una condizione della nostra salute, e che una vita sollevata dalla fatica potesse diventare, a sua insaputa, una vita più fragile. Oggi l'Organizzazione mondiale della sanità stima che quasi un adulto su tre, nel mondo, non raggiunga i livelli minimi di attività fisica raccomandati. Non perché siamo diventati pigri per natura, ma perché il mondo che abbiamo costruito non ci chiede più di muoverci. E la risposta che abbiamo trovato è una delle invenzioni più curiose della modernità: la palestra. Non che le palestre non esistessero prima (ne riparleremo tra poco); ma è nell'Ottocento, mentre l'industria toglieva fatica al lavoro, che si cominciano a costruire luoghi in cui rimetterla. Nel 1811 Friedrich Ludwig Jahn apre a Berlino, nel parco della Hasenheide, il primo campo di ginnastica all'aperto; nel 1844 nasce a Torino la prima società ginnastica italiana. Nel Novecento, con il *jogging*, l'aerobica, i centri *fitness*, quei luoghi si moltiplicano fino a diventare un paesaggio ordinario delle nostre città. Vista da fuori, la palestra è un luogo paradossale. Prendiamo la scala mobile per raggiungerla e, una volta entrati, saliamo per mezz'ora su una macchina che simula una scala. Corriamo su un *tapis roulant* che non ci porta da nessuna parte. Solleviamo pesi che non servono a costruire niente e che, finito l'esercizio, rimettiamo esattamente dove li abbiamo presi. È una fatica deliberatamente inutile, nel senso più preciso del termine: non produce nulla, se non noi stessi. Ed è proprio per questo il punto più interessante: proprio perché abbiamo riconosciuto che il nostro modo di vivere ci ha sottratto un esercizio fisico indispensabile per il nostro benessere psico-fisico, lo abbiamo reintrodotto artificialmente senza rinunciare a nessuna delle comodità che ce lo avevano tolto. In breve: nessuno va in palestra per protestare contro l'ascensore. C'è in questo una lezione che va oltre la salute del corpo,

ed è la stessa che attraversa tutte queste riflessioni. Non sapevamo quanto il nostro corpo dovesse alla fatica che il mondo gli imponeva finché una macchina non ce l'ha tolta.

L'ascensore della mente

Ciò da cui l'IA ci solleva non sono le scale ma il riassunto di un documento, la stesura di una *mail*, l'organizzazione di un argomento, la ricerca della parola giusta, il ricordo di ciò che abbiamo letto. Che una tecnologia possa alleggerire la mente fino a indebolirla non è un timore nuovo. Nel *Fedro* Platone racconta che il dio egizio Theuth, inventore delle lettere, presentò la scrittura al re Thamus come un farmaco per la memoria e per la sapienza. Il re rispose che avrebbe prodotto l'effetto contrario: chi l'avesse imparata avrebbe smesso di esercitare la memoria e, fidandosi di segni esterni, avrebbe ricordato non da sé ma da fuori; e avrebbe avuto l'apparenza della sapienza, non la sapienza. La parola con cui Platone indica la causa di quell'oblio è *ameletesia*: alla lettera, 'mancanza di esercizio' [32]. La scrittura non ha prodotto (solo) gli effetti nefasti che Platone temeva; nella quinta riflessione abbiamo per esempio visto quanto la memoria esterna dei testi sia stata il 'compost' di ogni conoscenza collettiva. Platone aveva però visto con precisione il meccanismo, quello che Stiegler, ripartendo proprio dal *Fedro*, chiama il carattere 'farmacologico' della tecnica: ogni protesi è insieme cura e veleno, perché solleva una funzione e, sollevandola, la espone al rischio di indebolirsi. La differenza è che le protesi mentali del passato alleggerivano una funzione alla volta: la scrittura la memoria, la calcolatrice il calcolo, il navigatore l'orientamento. L'IA, come abbiamo visto parlando di scrittura, può prendere in carico l'intera catena: ideazione, progettazione, realizzazione e verifica.

Qualche indizio di che cosa possa succedere comincia ad arrivare. Nel 2025 un gruppo di ricercatori del MIT Media Lab guidato da Nataliya Kosmyna ha pubblicato *Your Brain on ChatGPT*, un *paper* che raccontava un esperimento molto particolare. chiesto a un piccolo gruppo di studenti di scrivere brevi saggi in tre condizioni (da soli, con un motore di ricerca, con ChatGPT), registrandone nel frattempo l'attività cerebrale. Chi scriveva con l'IA mostrava la connettività neurale più bassa e, pochi minuti dopo aver consegnato, faticava a citare anche una sola frase del testo che aveva appena firmato; gli autori parlano di un 'debito cognitivo' che si accumula. È uno studio piccolo, non ancora consolidato, e va preso con prudenza. Ma descrive con i dati qualcosa che chiunque abbia delegato un testo può sospettare per esperienza: ciò che non abbiamo attraversato non ci resta. Kahneman, del resto, lo aveva spiegato prima che esistessero i modelli linguistici. Il Sistema 2, quello lento e riflessivo di cui abbiamo parlato a proposito delle immagini, è anche pigro: tra due strade che portano allo stesso risultato, la mente sceglie quasi sempre quella che costa meno fatica, secondo quella che Kahneman chiama 'legge del minimo sforzo'. Un collaboratore sempre disponibile, che ci solleva da ogni sforzo nel momento stesso in cui lo avvertiamo, incontra cioè una mente che non chiede di meglio. E, come abbiamo visto nella riflessione precedente, il passaggio dall'uso alla dipendenza non è graduale: a un certo punto la catena si chiude, e tornare indietro costa molto più che non esserci arrivati.

Difficoltà desiderabili

Chi si allena lo sa: un muscolo cresce solo se gli si chiede un po' più di quanto riesca a fare comodamente. La mente non funziona in modo molto diverso. Lo

psicologo Robert Bjork in *Memory and metamemory considerations in the training of human beings* ha chiamato 'difficoltà desiderabili' quegli ostacoli che rallentano l'apprendimento nel momento in cui avviene ma lo rendono più profondo e duraturo: richiamare un'informazione a memoria invece di rileggerla, provare a rispondere prima di vedere la soluzione, distanziare le ripetizioni invece di concentrarle [F]. Sono desiderabili perché sono il luogo stesso in cui si impara. La regola che abbiamo incontrato nella riflessione precedente, *prima pensa e poi chiedi*, è esattamente questo: una difficoltà scelta, che non rinuncia all'aiuto ma lo fa arrivare dopo lo sforzo, non al suo posto. Il problema è che le difficoltà desiderabili non si presentano più da sole. Per secoli è stata la vita a imporcele, come imponeva le scale al bigliettaio di Londra: per sapere qualcosa bisognava cercarlo, per scrivere una lettera bisognava trovare le parole, per ricordare un numero di telefono bisognava ripeterlo. Oggi, come per il corpo, bisogna sceglierle. E sceglierle vuol dire costruire luoghi e tempi in cui esercitarle: delle palestre. Va aggiunto che una difficoltà è davvero 'desiderabile' quando è adeguata a chi apprende e può essere superata con risorse e sostegni proporzionati: la fatica, da sola, non garantisce apprendimento.

L'idea, a dire il vero, è antichissima. La parola greca *askesis*, da cui viene il nostro 'ascesi', prima di indicare la disciplina dei monaci indicava l'allenamento degli atleti. E non è un caso che le due scuole filosofiche più celebri dell'antichità, l'Accademia di Platone e il Liceo di Aristotele, prendessero il nome da due ginnasi di Atene, né che alcuni dialoghi platonici, come il *Liside* e il *Carmide*, si svolgano in una palestra, tra giovani che si allenano. Pierre Hadot, nel suo *Esercizi spirituali e filosofia antica* ha dedicato pagine bellissime a mostrare che la

filosofia antica non era anzitutto una dottrina da imparare ma un insieme di esercizi spirituali, pratiche quotidiane con cui si lavorava su di sé per diventare capaci di vedere e di vivere in un altro modo. Seneca, nelle sue *Lettere a Lucilio*, è persino sprezzante con chi passa le giornate a gonfiare i muscoli: al corpo, dice, bastano esercizi brevi e semplici, la corsa, il salto, qualche peso; ma la mente va esercitata notte e giorno, perché si nutre di una fatica moderata, e quell'esercizio non lo impediscono né il freddo né il caldo, e nemmeno la vecchiaia [H]. Non c'è bisogno di condividere il disprezzo di Seneca per i muscoli per riconoscere che aveva capito una cosa che oggi torna urgente: anche la mente ha un allenamento, e quell'allenamento non coincide con lo studio finalizzato a qualcosa.

Ginnastica cognitiva

Se le cose stanno così, la conclusione è meno ovvia di quanto sembri. Non si tratta di rinunciare all'IA, come non abbiamo rinunciato all'ascensore, né di guardare con sospetto ogni aiuto che ci solleva da un compito noioso: delegare ciò che sappiamo fare è, come abbiamo visto, un uso legittimo e spesso intelligente dello strumento. Si tratta piuttosto di riconoscere che, accanto alla delega, ci serve un tempo in cui fare di proposito ciò che nessuno ci chiede più di fare: una ginnastica cognitiva. Leggere un testo lungo senza saltare alle conclusioni; seguire un ragionamento che non ci serve a nulla di immediato; scrivere senza che nessuno renda fluente al posto nostro ciò che stiamo cercando di dire; ricordare invece di cercare; provare a rispondere prima di chiedere. Sono esercizi che non producono niente, come il tapis roulant, e proprio per questo funzionano: l'unica cosa che producono siamo noi, un po' più capaci di quanto

saremmo stati senza. Una ginnastica di questo tipo deve essere scelta, perché nessuno ce la imporrà più; ma ha anche bisogno di luoghi, di tempi e di compagni. Scuole e università, lo abbiamo detto, sono già le nostre palestre, e dovrebbero esserlo sempre più consapevolmente: non i posti in cui si dimostra di aver prodotto un testo, ma quelli in cui ci si allena a produrlo. La palestra, però, non può chiudere con gli anni della formazione, come il bisogno di muoversi non finisce con l'ultima ora di educazione fisica. A ogni età avremo bisogno di ritagliarci un tempo, anche piccolo, per una fatica mentale che nessuno ci impone; e sarà tanto più efficace se, come in palestra, la condivideremo con altri, perché persone diverse, davanti alla stessa domanda, non rispondono mai nello stesso modo, ed è di questa pluralità, come vedremo nella prossima riflessione, che il pensiero si nutre.

La palestra non ci ha fatto odiare l'ascensore; ci ha fatto conoscere il nostro corpo. L'augurio è che una ginnastica cognitiva faccia lo stesso con l'IA: che non ce la faccia temere, ma ci aiuti a conoscere la nostra mente, scoprendo per sottrazione di quali fatiche è fatta. L'IA ci solleva di molti compiti e di questo non possiamo che essere contenti. Non deve sollevarci dalla fatica di pensare. Pensare stanca ma è una stanchezza dalla quale, a differenza delle altre, non conviene essere sollevati, perché è il modo in cui restiamo noi stessi.

11. L'ora di pranzo

Nella prima di queste riflessioni ho raccontato che l'IA ci si presenta come un oracolo: un'entità che sa e che risponde senza farci vedere come. Nella terza ho aggiunto che è una black box, ma che black box lo siamo anche noi, gli uni per gli altri. Nella sesta ho detto che abbiamo smesso di poter guardare un'immagine come una prova, come un 'questo è stato'. Nell'ottava ho provato a mostrare che, davanti a contenuti dei quali non conosceremo mai per intero la filiera, la sola cosa che ci resta è un esercizio di responsabilità: dichiarare, quando è possibile, chi ha fatto cosa, e concederci un tempo della cura prima di accogliere e ridiffondere. C'è un filo che tiene insieme questi quattro passaggi e che finora ho lasciato implicito. Provo a tirarlo, partendo da un esempio.

Provate a fare a Claude questa domanda: 'Devo fare una telefonata domani a un collega napoletano e a uno milanese, ma non posso chiamarli prima delle 11.30. A che ora mi conviene fare le due telefonate?'. La risposta sarà (più o meno): 'La vera variabile è la pausa pranzo. Sfrutta la finestra tra le 11.30 e le 13.00. Se devi scaglionarle, chiama prima il milanese, verso le 11.45–12.00, perché a Milano si tende a pranzare presto; poi il napoletano, verso le 12.15–12.30, perché al Sud la pausa slitta un po' più tardi'. Cosa ci racconta questa risposta?

Prodotti culturali

Per rispondermi, Claude si è appoggiato a un'idea di 'cultura italiana' nella quale l'ora di pranzo non è la stessa da Nord a Sud. Quell'idea non è un dato oggettivo: è un'immagine, utile e allo stesso tempo discutibile perché vive anche di stereotipi regionali, che il modello ricava dai testi su cui è stato addestrato, cioè romanzi, articoli, conversazioni. Il punto non è che la possiede. Il punto è cosa ne fa. Non la recupera come farebbe un'enciclopedia: la interpreta, sceglie tra le letture possibili del mio problema e mi propone due fasce orarie. Parte da un contesto e lavora dentro quel contesto. Proviamo a chiedere a una calcolatrice quanto fa due più due. Il risultato non cambia se glielo chiediamo in Italia o in Giappone, di lunedì o di domenica, alle nove del mattino o alle quattro di notte. Apriamo invece Claude alle quattro di notte e ci accoglie con una battuta del tipo 'sei mattiniero oggi, Armando!', perché 'sa' che in Italia, a quell'ora, di solito si dorme. La calcolatrice restituisce lo stesso identico *output* in qualsiasi luogo e in qualsiasi momento; la sua risposta non ha un dove e non ha un quando. Le risposte dell'IA, invece, un dove e un quando li hanno sempre: il mio, quello di chi ha raccolto e filtrato i testi dell'addestramento, quello della lingua prevalente in cui quei testi sono scritti.

Esiste un'espressione che aiuta a mettere a fuoco questa differenza: 'prodotti culturali', cioè i testi, gli audio, i video, gli oggetti che si nutrono di un contesto e operano al suo interno. Una poesia è un prodotto culturale; una tavola dei logaritmi no. L'IA che usiamo tutti i giorni fabbrica prodotti culturali: ogni sua risposta è un piccolo testo che presuppone un mondo, si colloca dentro quel mondo e vi prende posizione, anche quando sembra

limitarsi a informarci. Un modello linguistico è sempre già 'educato': ha assorbito una lingua, un canone di fonti, un'idea di che cosa sia una risposta corretta, utile, prudente. Ha già una posizione, e ce l'ha perché è stato creato e addestrato da qualcuno, da qualche parte, in un certo momento.

Ermene(u)tica

È da qui che parte *Computational Hermeneutics: Evaluating Generative AI as a Cultural Technology*, un lavoro firmato nel 2026 da trentotto studiosi coordinati da Cody Kommers dell'Alan Turing Institute, con affiliazioni a Princeton, Stanford, King's College London, Queen Mary University e molte altre. La tesi è netta: se l'IA produce oggetti che dialogano di continuo con un contesto, allora per comprenderla e valutarla non bastano i test a punteggio; servono le tecniche che da secoli le discipline umanistiche usano per analizzare il significato di un documento o di un evento, mettendolo cioè in relazione con il suo contesto storico, sociale, politico. Quelle tecniche hanno un nome: ermeneutica.

Nella seconda riflessione ho scritto che l'IA ci imita in modo 'fantastico', cioè negli *output* e non nel meccanismo. Aggiungiamo un tassello: uno di quegli *output* è la lettura del contesto in cui la nostra domanda cade. Abbiamo già detto che quando chiedo aiuto per 'una *mail* formale al mio capo' sposto la distribuzione di probabilità del sistema verso un certo registro; quando chiedo l'ora giusta per due telefonate, il sistema attiva un'immagine di Italia e la applica. In nessuno dei due casi estrae una risposta che era già lì, incisa da qualche parte: la costruisce interpretando, esattamente come facciamo noi quando prevediamo la parola successiva di una frase.

Il *paper* prende in prestito tre nodi dall'ermeneutica del Novecento, e in particolare da Hans-Georg Gadamer, per proporre tre sfide.

La prima sfida è la collocazione. Non esiste prodotto umano che non stia in un preciso orizzonte storico e sociale. Nonostante questa acquisizione sia banale, l'IA viene spesso descritta come un non-punto-di-vista. Il ragionamento è più o meno questo: l'IA contiene così tante informazioni da risultare estranea a ogni singola prospettiva, perché le ingloba tutte. È la vecchia idea della 'vista da nessun luogo', che Thomas Nagel, in *The View from Nowhere*, usava come metafora dell'oggettività e che Donna Haraway, in *Situated Knowledges*, ha smontato definendola 'il trucco di dio di vedere tutto da nessun dove'. Uno sguardo è sempre sguardo di qualcuno e da un certo angolo: porta con sé chi lo esercita e il punto da cui guarda. La sfida, per un modello, non è diventare neutrale (che è impossibile) ma dichiarare la propria posizione e renderla ispezionabile.

La seconda sfida è la pluralità. Un testo, una canzone, un quadro non hanno una sola interpretazione corretta: ogni persona, ogni comunità può accoglierli o respingerli per ragioni diverse e tutte legittime, perché nate in contesti differenti. Interpretare non vuol dire trovare la quadra tra le letture: vuol dire riconoscere che restano, legittimamente, diverse. Per l'IA la sfida non è azzerare i bias fino a una risposta 'pulita', ma costruire un modello che sappia dare voce a questa pluralità di sensibilità invece di comprimerle in un'unica posizione spacciata per la risposta.

La terza sfida è l'ambiguità. Se l'interpretazione nasce dalla fusione degli orizzonti, allora non è il modello che 'estrae da solo' il senso: i suoi pre-giudizi, cioè i pattern appresi nell'addestramento, incontrano il modo in cui io formulo la domanda, e il risultato nasce da

quell'attrito. Per questo non si può giudicare un LLM su una singola coppia domanda-risposta, come se il significato fosse fisso e assegnabile a un voto: bisogna guardare l'intera conversazione, il modo in cui modello e utente si aggiustano l'uno all'altro, battuta dopo battuta.

Lo stesso esercizio, dall'altra parte

Nel 2025 ho pubblicato su Zenodo, in accesso aperto e con licenza libera, un testo intitolato *Ermenetica. Il sapere umanistico come esercizio di responsabilità*. Il neologismo tiene insieme ermeneutica ed etica, e la tesi è una sola: non esiste interpretazione innocente. Ogni volta che leggo, commento, spiego, divulgo un testo o un'immagine, metto in gioco la mia storia, le mie scelte, le mie fedeltà. Interpretare è sempre anche rispondere di qualcosa e davanti a qualcuno. Il punto di partenza è una definizione di Helen Small, per la quale le discipline umanistiche studiano 'le pratiche di produzione di senso della cultura umana, passata e presente, concentrandosi sull'interpretazione e la valutazione critica, soprattutto in termini di risposta individuale e con un ineliminabile elemento di soggettività' [33]. Provo ad applicare a quella riflessione le tre sfide ermeneutiche appena descritte.

Alla collocazione, in quel libro, corrisponde ciò che, sulla scia di Haraway, possiamo chiamare 'sapere situato'. L'esempio che uso di solito è il manuale scolastico di storia della filosofia: lo percepiamo come il livello-base oggettivo della disciplina ed è invece l'esito più personale e soggettivo che una ricerca possa produrre perché è il testo in cui uno studioso 'pretende' di sintetizzare, con le sue parole, centinaia e centinaia di testi filosofici diversi, scritti in momenti differenti da vari autori. In questo caso come in tanti altri, il rigore di un lavoro non sta nell'assenza di un io, come se lo scopo di

uno studioso fosse scomparire dietro quello che scrive, affinché il suo prodotto sia oggettivo; il valore sta nella responsabilità con cui quell'io dichiara, senza esibirle ma senza nemmeno rinnegarle, le scelte che hanno guidato la sua interpretazione.
Alla pluralità corrisponde la distinzione tra 'verità *dei* documenti' (cioè la loro corretta collocazione storica, che è un dovere non negoziabile) e 'verità *con i* documenti' (cioè ciò che se ne costruisce insieme, in aula, con studenti che sono co-interpreti e non recipienti). La differenza dei vissuti, lì, è una risorsa e non rumore da filtrare.

All'ambiguità corrisponde l'idea che ogni lezione sia una relazione a tre: la fonte, la coscienza che la interroga, le storie di chi ascolta. Il significato non si estrae e non si mette in classifica: emerge da uno scambio, e cambia a seconda di chi vi partecipa.

Il *paper* arriva all'ermeneutica partendo dalla macchina; *Ermenetica* ci arrivava partendo dall'essere umano. L'IA è il punto esatto in cui le due strade si incontrano: è un interprete che non dichiara la propria posizione, e al quale per anni abbiamo chiesto di essere proprio quello 'sguardo da nessun luogo' che, tra umani, avevamo già smesso di credere possibile.

Il male scritto bene

C'è un caso che mostra bene quanto queste competenze servano, non solo per valutare l'IA ma per educarla. Le grandi opere della tradizione, ormai di pubblico dominio, circolano liberamente in rete e possono entrare nei dati con cui si addestrano i modelli. Molte di esse, però, esprimono sensibilità lontanissime dalle nostre. Delphine Demelas, dell'Università di Southampton, ha preso la

Chanson de Roland nella traduzione francese di Joseph Bédier, l'ha divisa in 2.605 frasi e l'ha sottoposta a *Detoxify*, uno dei sistemi più usati per misurare la 'tossicità' di un testo [34]. Il modello ne ha segnalate 181, circa il 7%, riconoscendo minacce esplicite e insulti. Ma l'aspetto più interessante è ciò che non ha visto. La frase con cui il poema racconta la sorte dei vinti, 'tutti furono uccisi o fatti cristiani', ottiene un punteggio inferiore a 0,02 in ogni categoria. La descrizione di un guerriero saraceno, 'nero come pece fusa', la cui pelle scura è presentata come segno della sua malvagità, viene registrata soltanto come un insulto: il modello coglie l'offesa ma non il pregiudizio razziale che la regge.

Il motivo è semplice: questi sistemi sono addestrati sui commenti dei *social network*, e riconoscono la violenza della forma (l'insulto, la volgarità, l'aggressività del tono) ma non quella che si esprime, scrive Demelas, attraverso versi epici, argomentazioni teologiche e convenzioni cavalleresche. Quella violenza non è invisibile per chi i testi li studia e sa leggerne il registro, le convenzioni e il contesto: già nel 1979 il medievista Jean-Charles Payen in *Une poétique du génocide joyeux* aveva parlato, a proposito della *Chanson*, di una 'poetica del genocidio gioioso'. E chi frequenta la tradizione cristiana sa quanto lontano affondino le radici di quella poetica. Tra il 407 e il 408, rispondendo nella *Lettera 93* a chi gli rimproverava di aver invocato le leggi imperiali contro i dissidenti, Agostino ammette di aver pensato, un tempo, che si dovesse 'agire solo con la parola, combattere con la discussione, convincere con la ragione'; poi si era ricreduto, e richiamava la parabola evangelica del banchetto, 'Costringete ad entrare tutti quelli che troverete', osservando che talvolta 'il pastore si serve della verga per ricondurre al gregge le pecore traviate'. Non c'è una

parola che un rilevatore di tossicità giudicherebbe offensiva: c'è un ragionamento pacato, un'immagine pastorale, quasi affettuosa. Eppure quel 'costringete a entrare' (il *compelle intrare* del Vangelo di Luca) ha attraversato i secoli come argomento a favore della coercizione religiosa.

La lezione, per noi umanisti, è doppia. Da un lato, tra le competenze necessarie per 'educare' l'IA serve quella storico-critica di chi conosce i testi e i loro contesti: solo così un testo antico smette di essere un deposito di parole e diventa una voce, collocata nel suo tempo, ascoltata e, se serve, contraddetta. Dall'altro, dobbiamo riconoscere che questo compito, che non nasce oggi, in passto lo abbiamo svolto solo a metà. Abbiamo costruito edizioni critiche, commenti, apparati e studi capaci di restituire a ogni testo il suo contesto ma li abbiamo lasciati per lo più chiusi in riviste e biblioteche ad accesso riservato, mentre in rete circolava il testo nudo, esposto a ogni lettura, comprese quelle che ne piegano intenzionalmente il significato. Il paradosso è evidente: i nostri studi, che sono i più affidabili, restano accessibili a pochi, mentre alimentano liberamente l'IA testi dei quali nessuno conosce la provenienza. Rendere aperte le nostre ricerche, costruire dati documentati, progettare strumenti capaci di analisi critica è dunque, oggi, una responsabilità culturale e politica. Non possiamo chiedere alle macchine di condividere informazioni corrette se non siamo noi i primi a farlo.

Come si valuta una traduzione

La proposta operativa del *paper* è semplice e, a mio parere, preziosa: valutare l'IA come le discipline umanistiche valutano una traduzione o un'interpretazione. Quindi

lungo uno scambio reale e non su una battuta isolata; con persone che giudicano se una risposta è appropriata dentro un certo quadro culturale; guardando come il modello tratta il contesto e non solo l'output finale. Un modo di valutare che somigli meno a una pagella e più a una conversazione dentro una comunità che interpreta.
E qui arriva il ribaltamento che ho provato a proporre in ognuna di queste riflessioni: adottare questo metro per l'IA ci obbliga ad adottarlo anche per noi. La domanda giusta non è 'l'IA è neutrale?', perché non lo è e non lo sarà, ed è un errore di categoria pretenderlo. La domanda giusta è quella con cui in *Ermenetica* riassumo tutto il resto: come rispondo di quello che so? A questa, oggi, se ne aggiunge una seconda, che è il cuore dell'ottava riflessione: chi risponde di come questa interpretazione viene usata? L'IA può fare la manovalanza, cioè recuperare, riassumere, proporre due fasce orarie. La presa di posizione situata, il 'per me', resta un lavoro umano, e con esso la responsabilità.

Torniamo all'ora di pranzo. Claude non sa a che ora mangio io, né a che ora mangia davvero il collega di Napoli: ha una media, un'immagine, in parte anche uno stereotipo, e la usa per essermi utile. Non è poco, ed è persino ragionevole. Ma la telefonata la faccio io. E se svegliassi qualcuno nel mezzo del pranzo, non sarebbe la 'vista da nessun luogo' a scusarsi: sarei io a dover rispondere di aver seguito, senza pensarci, lo sguardo collocato di qualcun altro. L'augurio, allora, è che imparare a valutare l'IA come si valuta un'interpretazione ci restituisca l'abitudine a valutare così anche le nostre: dichiarando da dove guardiamo, ogni volta che apriamo bocca o mandiamo un messaggio.

12. Do you remember?

"Do you remember the twenty-first night of September?". Chi è cresciuto tra gli anni Settanta e Ottanta ha probabilmente già in testa il ritmo con cui gli *Earth, Wind & Fire* attaccavano *September*: una canzone costruita su una domanda rivolta a qualcuno che, si presume, potrebbe anche non ricordare. È una domanda che ha senso solo tra esseri capaci di dimenticare. Ed è una domanda che, in questi anni, facciamo sempre meno, perché quasi tutto ciò che viviamo è registrato da qualche parte, pronto a ricordarcelo prima ancora che ce lo chiediamo.

Pensiamo a quello che succede a fine estate: le fotografie che ci ritroviamo sul telefono sono centinaia, spesso più di cinquecento. Non le guardiamo quasi mai ma ci rassicura sapere che stanno lì. Ogni mattina qualche applicazione ci propone un ricordo ('ecco dov'eri tre anni fa'), come se temesse che potessimo dimenticarlo. Esistono già dispositivi indossabili che registrano le conversazioni di intere giornate e le rendono interrogabili, così da costruire una memoria completa della nostra esperienza. E gli assistenti di IA che usiamo ogni giorno cominciano ad avere una memoria propria di

noi. Il Claude con il quale lavoro, per esempio, conserva in una cartella una serie di schede che mi riguardano (chi sono, che cosa insegno, quali progetti ho in corso, quali scadenze mi aspettano) e le rilegge all'inizio di ogni sessione: ricorda di me cose che io stesso, a volte, ho dimenticato di avergli detto. Questa memoria esterna può essere utilissima, ma la sua disponibilità non equivale alla memoria autobiografica: conservare informazioni su una persona non significa ricordarle come le ricorda quella persona.

In questa riflessione proviamo a chiederci che cosa succede alla memoria (alla nostra, prima ancora che a quella delle macchine) in un mondo nel quale nulla sembra più destinato a sbiadire.

Duecento anni

Nel 2013 lo storico della tecnologia George Dyson ha affermato che i *Big Data* (la massa enorme di informazioni che raccogliamo e sulle quali spesso basiamo le nostre decisioni) sono nati grazie alle tecnologie che hanno reso più semplice e meno costoso conservare tutto che selezionare e cancellare qualcosa. Questo modello di 'iperconservazione' dei dati ha permesso l'addestramento dei LLM, che si basano su quantità di documenti enormemente superiori a quelle che qualunque essere umano potrebbe leggere in migliaia di anni. Nel 2021, prima cioè che grazie a ChatGPT l'IA diventasse un fenomeno *consumer*, Venkatesh Rao, in un articolo su *Substack* intitolato *Superhistory, not Superintellingence*, scriveva: "Se riuscissi a connettermi a un'intelligenza artificiale di supporto alla scrittura nel modo giusto, anche con un'inefficienza significativa, sarei in grado di scrivere in modo efficace come se avessi 1046 anni anziché 46". L'ipotesi che faceva Rao è esattamente

quello che è successo negli ultimi quattro anni con l'IA: scriviamo facendoci aiutare da una entità che ha letto una quantità di testi che nessuno di noi avrebbe mai potuto leggere nemmeno in cento vite. Per la prima volta nella storia, dunque, ci troviamo a confrontarci con una entità che scrive come noi ma che, a differenza nostra, ha una età esperienziale che non coincide con l'età biologica, cioè con il numero di informazioni che mediamente un essere umano è in grado di incontrare, assorbire ed elaborare nell'arco della sua esistenza.

Che si possa 'vivere più tempo' di quello che la biologia ci concede non è un'idea nuova. Seneca nel *De brevitate vitae* sosteneva che solo chi si dedica alla sapienza vive davvero, perché non si limita a custodire la propria età ma aggiunge alla sua ogni età: tutti gli anni trascorsi prima di lui diventano suoi, e al sapiente 'tutti i secoli servono come a un dio'. Nel XII secolo Giovanni di Salisbury attribuiva nel *Metalogicon* a Bernardo di Chartres un'immagine destinata a una lunga fortuna: siamo come nani seduti sulle spalle di giganti, e vediamo più cose e più lontane di loro non per l'acutezza della vista o per l'altezza del corpo, ma perché la loro grandezza ci solleva. La lettura era già una forma di invecchiamento accelerato, e il nano medievale era, a suo modo, un centauro latente.

La differenza tra queste forme di 'espansione' della mia conoscenza (che avviene per il tramite delle tracce dell'esperienza altrui, per esempio leggendo) e quanto avviene oggi con i LLM è però profonda. Il nano di cui parla Bernardo sa su quali spalle siede perché i suoi giganti hanno un nome: si possono leggere, citare, discutere, contraddire, e di ciò che si è preso da loro si può rispondere. Il tempo digerito dalla macchina arriva invece sul nostro schermo senza nomi, masticato, restituito ma, soprattutto, privo di una caratteristica tipicamente umana: l'oblio.

Il palazzo della memoria

Nel decimo libro delle *Confessioni* Agostino descrive la memoria come un insieme di 'campi e vasti quartieri', un 'enorme palazzo' (*aula ingens*) nel quale sono conservate le immagini di tutto ciò che abbiamo percepito, pensato, provato. Quel palazzo non è però un archivio. Quando entro nella memoria, scrive Agostino, evoco le immagini che voglio: alcune si presentano subito, altre si fanno desiderare più a lungo, come se dovessero essere estratte da ripostigli più segreti; altre ancora si precipitano a ondate mentre ne cerco una diversa e balzano in mezzo 'con l'aria di dire: Non siamo noi per caso?', e devo scacciarle 'con la mano dello spirito' finché quella che cerco non si snebbia e avanza. La memoria, insomma, non è un deposito ma un'attività: un lavoro continuo di richiamo, di scarto, di ordinamento, che Agostino descrive come ciò che accade 'quando faccio un racconto a memoria'. In quel palazzo c'è anche l'oblio perché l'oblio non è un incidente esterno alla memoria, ne fa parte. In un articolo uscito nel 2026, Paul Smart, Robert Clowes, Joel Krueger e Michael Boniface ricordano che, secondo le teorie oggi prevalenti, ricordare non significa riprodurre alla lettera il passato ma ricostruirlo a partire da tracce frammentarie, da schemi generali e, soprattutto, dagli scopi del presente; per questo errori e distorsioni sono un aspetto ricorrente, forse inevitabile, della memoria umana [35]. 'In sostanza', scrivono due psicologi da loro citati, 'ogni memoria è falsa in qualche misura'. Questo vale in modo particolare per la memoria autobiografica, quella con la quale costruiamo il racconto di noi stessi. Qui, osservano gli autori, il ricordo è governato da una tensione tra due esigenze: la corrispondenza, cioè la conservazione esatta di ciò che è

accaduto, e la coerenza del sé, cioè il mantenimento di un senso di sé stabile e integrato nel tempo. E molto spesso vince la coerenza: elaborazioni, reinterpretazioni, omissioni selettive ci aiutano a sostenere un'identità intelligibile. Nella sesta riflessione abbiamo distinto tra una verità corrispondentista e una coerentista: la memoria di noi stessi, a quanto pare, è coerentista. Il suo fine non è un'immagine esatta di ciò che è stato ma un racconto che ci permetta di continuare a essere chi siamo, di elaborare e a volte di metabolizzare ciò che ci è successo. Potremmo chiamarla un'allucinazione programmatica: un modo di sbagliare che serve al soggetto per abitare in modo confortevole la propria storia. Facciamo un esempio per spiegarlo meglio.

Pochi anni dopo la morte di Agostino, il suo discepolo e amico Possidio, vescovo di Calama, ne scrive la biografia. E nella prefazione avverte che non riferirà tutto ciò che Agostino aveva raccontato di sé nei libri delle *Confessioni*, com'era prima di ricevere la grazia e come era vissuto dopo. Possidio tratta cioè l'autobiografia come un documento già acquisito, da non ripetere. Eppure, per uno storico, non c'è fonte meno affidabile di un'autobiografia. Agostino non scrive le *Confessioni* come un diario fedele: ormai più che quarantenne, vescovo da poco, si volta indietro per fare un bilancio della propria vita, e seleziona gli avvenimenti che più di altri lo aiutano in questa operazione. Ciò che tace è, in un certo senso, importante quanto ciò che racconta perché non sta inseguendo una esattezza cronachistica ma, guardando il passato, sta costruendo se stesso: l'Agostino-raccontato è già parte dell'identità dell'Agostino-narratore.

La memoria umana seleziona dimenticando, tralasciando, dando più peso ad alcuni ricordi e meno ad altri; la macchina lavora invece dentro quella che

potremmo chiamare una coestensione: tutti i suoi ricordi (quelli del suo addestramento e, sempre più spesso, quelli che le affidiamo noi) sono compresenti, nessuno è sbiadito, nessuno è stato lasciato andare. Quando un sistema del genere diventa co-narratore della nostra storia [35], ci restituisce risposte che derivano dalla somma di tutto. Il risultato è paradossale: il più grande merito di questi strumenti, cioè essere stati addestrati su tutto il nostro passato, li costringe a un racconto in un certo senso dis-umano, perché non contempla l'operazione più umana che la memoria compia: accettare l'oblio, per semplice perdita o per scelta, a volte per il nostro bene. E se nella nostra autobiografia condivisa qualcosa viene omesso, quell'omissione non è di nessuno: non c'è un Agostino che ne risponda davanti a un testimone.

Vuoto a perdere

Il caso estremo di una memoria che non lascia andare nulla è quello dei *griefbot*: sistemi che, alimentati con tutto ciò che una persona ha lasciato (messaggi, mail, note vocali, fotografie, *post*), imitano chi non c'è più e ne riproducono il lessico, lo stile, qualche tratto dell'identità. Giacomo Zanotti e Daniele Chiffi hanno dedicato a questo tema una riflessione puntuale in *Artificial Afterlife: Philosophical Reflections on Griefbots*; i due studiosi ricordano che la tecnologia ci ha sempre aiutato ad affrontare la morte: sono tecnologie della memoria anche le lapidi, i monumenti funebri, le fotografie. La differenza, però, è enorme. Un archivio conserva ciò che una persona ha detto, scritto o registrato; un *avatar* generativo, invece, produce ciò che quella persona potrebbe dire. Nel primo caso interroghiamo il passato; nel secondo proviamo a produrre presente.

Che avremmo provato a farlo, che avremmo cioè avuto la tentazione di usare questa tecnologia che produce testi e immagini così credibili per dare una sorta di vita eterna al nostro pensare era quasi inevitabile, perché viviamo un tempo che ha paura del vuoto. Non riusciamo a decidere quali fotografie cancellare e compriamo spazio in *cloud*; ogni applicazione ha una sezione 'salvati' o 'guarda più tardi'; abbiamo inventato il 'visualizzato' e l''ultimo accesso' per misurare persino la durata di un'assenza; le liste di cose da fare ci impediscono di dimenticare di aver dimenticato qualcosa. Abbiamo costruito un mondo nel quale quasi ogni forma di vuoto viene subito segnalata, riempita, archiviata o sostituita. Era naturale che provassimo a riempire anche il vuoto dei vuoti, l'assenza di chi è morto.

Agostino, nel libro XI delle *Confessioni*, scrive che i tempi non sono propriamente tre (passato, presente e futuro) ma che esistono piuttosto un presente del passato, che è la memoria, un presente del presente, che è la visione, e un presente del futuro, che è l'attesa. Mi sembra che oggi coltiviamo moltissimo il primo (archivi, fotografie, promemoria) e viviamo con ansia il terzo (notifiche, calendari, scadenze), mentre il presente del presente, lo sguardo che tiene insieme ciò che accade mentre accade, è diventato un'eccezione.

Rao, nel suo saggio, sostiene che le vite umane sono fatte per lo più di 'tempo informazionalmente vuoto': tante esistenze simili, ripetitive, che messe insieme valgono molti meno anni di esperienza di quanti ne dica l'anagrafe [36]. Usiamo la stessa parola, vuoto, per dire cose opposte. Per lui il vuoto è ciò che resta quando si toglie la ripetizione e si conta l'informazione; per me è la condizione perché qualcosa diventi racconto. È lo spazio nel quale lavorano le forze che ci definiscono: la paura dell'assenza e le strategie con cui la affrontiamo e,

soprattutto, l'immaginazione, che ci permette di costruire racconti non di quello che ci è successo ieri ma con quello che ci è successo ieri. Ricordare non significa infilarsi un visore e rientrare in una ricostruzione perfetta del passato. Significa ridipingerlo ogni volta, metterlo in dialogo con ciò che siamo oggi, accorgersi che qualche dettaglio comincia a sfuggire e provare per questo paura o sollievo, aggiungere qualcosa, togliere ciò che oggi ci fa male o non ci serve più. Un *griefbot* può sembrare consolatorio; ma ci toglie proprio il vuoto, che è l'unico spazio nel quale, dopo una perdita, possiamo costruire il nostro racconto nuovo.

Chi ricorda chi

C'è un ultimo presupposto, nei *griefbot*, che vale la pena smontare: l'idea che la somma di ciò che una persona ha detto e scritto basti a ricostruirne l'identità. Una riflessione di Amy Kind intitolata *Biometrics and the metaphysics of personal identity* aiuta a vedere il problema da un'angolazione inattesa. Il problema dell'identità personale, ricorda Kind, contiene almeno tre domande diverse: che cosa rende qualcuno una persona; che cosa lo rende la stessa persona nel tempo; che cosa lo rende quella persona, tra tutti gli attributi che possiede. La biometria riconosce corpi (volti, impronte, andature) e dà per scontato, senza dirlo, che riconoscere un corpo significhi riconoscere una persona. Ma basta un esperimento mentale classico, il trapianto di cervello, per vedere la crepa: se il cervello di B finisce nel corpo di A, chi si sveglia ricorda la vita di B, cerca le persone care a B, vuole tornare a casa di B; eppure ogni *scanner* lo identificherà come A, e B risulterà morto.

Il *griefbot* commette l'errore simmetrico: non scambia la persona con il suo corpo ma con le sue tracce.

Una persona, però, non è l'archivio di ciò che ha detto; è il modo in cui ha scelto, giorno per giorno, che cosa tenere e che cosa lasciare andare, e di che cosa rispondere.

Le macchine che stiamo costruendo ricorderanno sempre di più, e probabilmente ci aiuteranno a ricordare meglio: non è poco, e può essere persino prezioso. Ma la memoria che ci rende quello che siamo non è quella che conserva tutto. È quella che sceglie, che a volte sbaglia per permetterci di vivere, che lascia spazi vuoti nei quali immaginare. E che, come le *Confessioni*, sa di dover rispondere di ciò che racconta. Nella prossima e ultima riflessione proveremo a tirare le fila, partendo proprio dal libro che, nelle *Confessioni*, viene subito dopo quello sulla memoria: il libro sul tempo.

13. Un po' di sintesi e un augurio

In queste riflessioni ho provato a chiedermi di (quale) cosa parliamo quando parliamo di IA. Forse adesso abbiamo qualche idea in più per rispondere, provando a riassumere il percorso che abbiamo fatto.

Siamo esseri empatici. Il mondo che ci circonda, quello che vediamo, sentiamo, tocchiamo, annusiamo, mangiamo 'ci entra dentro'; lo subiamo senza quasi poter opporre resistenza. Quando ciò che incontriamo è, per qualche motivo, molto carico emotivamente, siamo portati naturalmente a umanizzarlo; ci parliamo, lo trattiamo bene o male a seconda di come 'si comporta', e così via. Era dunque naturale che questo avvenisse con l'IA, che per noi ha un carico emotivo fortissimo perché ci imita in un modo che abbiamo chiamato 'fantastico' e magico; riproduce cioè molto bene (cosa questa che per natura ci piace molto) degli *output* che da secoli ci appartengono e che, anzi, ci hanno caratterizzato evolutivamente come specie: la comunicazione scritta, la realizzazione di immagini, la produzione di suoni (e tante altre attività che anche più recentemente sono entrate nel nostro 'corredo cognitivo' e che compiamo solo noi, come per esempio guidare una automobile). La potenza di questo coinvolgimento emotivo è tale che non possiamo non considerarla quando parliamo del nostro rapporto con l'IA: non è una tecnologia qualsiasi; ci assomiglia (volutamente) troppo bene. Proprio perché ci

assomiglia, riflettere sulla IA significa, inevitabilmente, riflettere su di noi; è anzi questa una delle opportunità più preziose offerte da questa tecnologia. Se anche la sua 'bolla' scoppiasse domani, resterebbe infatti la lunga stagione nella quale ci siamo specchiati in una macchina che ci sembrava pensante, che ci ipnotizzava con la sua 'magica opacità' e che quindi ci ha costretto a farci una domanda centrale: se l'IA mi imita solo in modo fantastico, cioè solo negli *output*, in che cosa siamo diversi? C'è qualcosa 'dentro' che non c'è nel mulino dell'IA?

In questa seconda versione abbiamo visto anche altro. Che, davanti a una tecnologia opaca e capace di rispondere, riattiviamo schemi di pensiero antichissimi, religiosi, e oscilliamo tra profezie di salvezza e annunci di apocalisse. Che l'IA può essere un'impalcatura, che ci rende più capaci, o un sostituto, che ci rende incapaci, e che la differenza dipende da quanto riusciamo a coltivare le competenze che stiamo delegando. Che, come il corpo dopo l'ascensore, anche la mente dopo l'IA ha bisogno di una palestra: non per rinunciare a ciò che ci solleva, ma per non dimenticare di che cosa siamo fatti. E che la memoria che ci costituisce non è un archivio ma una scelta, fatta anche di oblio, della quale siamo chiamati a rispondere. In ognuno di questi casi, come nelle riflessioni della prima versione, il discorso sulla macchina si è rivelato, a guardarlo da vicino, un discorso su di noi: sulle nostre paure, sui nostri desideri, su ciò che siamo disposti a delegare e su ciò che invece vogliamo continuare a fare da soli.

La risposta, più naturale, è già insita nella domanda: io sono diverso dalla IA perché il mio pensiero sta 'dentro' un corpo biologico. Ma dire semplicemente 'abbiamo un corpo' non basta, e anzi rischia di essere fuorviante: non

è impossibile immaginare che, in un futuro più o meno lontano, si riesca a replicare anche la struttura biologica umana, cioè tessuti, organi, forse persino qualcosa che assomigli alla procreazione. Il punto non è il corpo come materia; è il corpo come luogo di una condizione esistenziale. È il fatto che questo corpo ha un metabolismo, cioè si consuma, e noi, che lo abitiamo e 'siamo' (in) quel corpo, lo sappiamo. Ma sapere di essere fragili, consumabili e mortali non è un dato neutro che registriamo e archiviamo come faremmo con qualsiasi altra informazione. È una consapevolezza che invade e condiziona tutto: ogni decisione che prendiamo, ogni affetto che coltiviamo, ogni rimpianto che portiamo con noi. La gioia di un momento bello è inseparabile dalla percezione, a volte appena accennata, a volte bruciante, che quel momento finirà; il dolore di una perdita è inseparabile dal sapere che anche noi andremo perduti. Non è la fragilità biologica in sé che ci definisce: è il fatto che la conosciamo, che la anticipiamo, che la portiamo dentro come una presenza silenziosa e costante. È quello che Heidegger chiamava 'essere-per-la-morte': non semplicemente la morte come evento futuro ma come struttura permanente e sotterranea dell'esistenza, che dà urgenza, peso e significato a ogni cosa che facciamo adesso.

Non è, questa, una constatazione triste. Leone XIV, nella *Magnifica humanitas*, invita ad 'accettare il limite e la fragilità dell'umanità senza considerarli un errore da correggere' e mette in guardia dall'"illusione di una tecnica che promette di liberarci da ogni fragilità' [1]. Lo scrive da capo della Chiesa cattolica, con una prospettiva e un orizzonte religiosi; ma credo che una visione dell'umano fondata sulla presa d'atto della nostra fragilità sia oggi indispensabile per tutti. Davanti all'IA, ci suggerisce due atti di prudenza: uno epistemico, perché nessuno di noi

(utente, progettista o legislatore) sa abbastanza di questa tecnologia per prevedere dove andrà, e chi finge di saperlo sta già negando la propria fragilità; e uno morale, perché l'IA non è neutra, si nutre delle fragilità di chi l'ha costruita e incide su quelle di chi la usa.

Un LLM non sa di consumarsi. Può elaborare testi sulla morte, sulla perdita, sulla fragilità, e lo fa in modo spesso sorprendentemente preciso. Può addirittura scrivere della sua morte, costruire un racconto nel quale descrive con toni tragici il momento in cui qualcuno gli staccherà la spina; ma non starà facendo altro che mettere assieme, con una logica sequenziale probabilistica, termini che ha ritrovato in testi che parlavano di morte. È questa assenza, non l'assenza del corpo, ma l'assenza della consapevolezza del corpo e della sua (e nostra) finitezza, che oggi segna la differenza più profonda. Noi viviamo il nostro tempo sentendone il passaggio, e in ciò consiste, io credo, quello che chiamiamo coscienza, almeno per come me l'ha spiegata Agostino, un autore che amo molto.

Subito dopo aver attraversato il palazzo della memoria, nel libro XI delle *Confessioni* Agostino si interroga su cosa sia il tempo, su cosa cioè intendiamo indicare quando usiamo la parola, a tutti familiarissima, 'tempo'. La domanda di partenza di Agostino è tanto nota quanto solo apparentemente ingenua: "Che cos'è il tempo? Se nessuno me lo chiede, lo so; se voglio spiegarlo a qualcuno che me lo chiedesse, non lo saprei". Più che una ammissione di ignoranza, l'affermazione di Agostino è una dichiarazione di metodo: nella nostra vita utilizziamo alcune parole così spesso che siamo sicuri di conoscerne perfettamente il significato; quando però ci fermiamo a riflettere per definirli (quando li pensiamo filosoficamente, dunque) cadiamo in difficoltà: così, usiamo il linguaggio ma avremmo difficoltà a definire

cosa sia 'linguaggio', al pari del concetto e della parola 'tempo' o di altri termini che abbiamo incontrato in queste pagine, come per esempio 'creatività'. Fatta questa premessa, Agostino tenta di partire dai dati indiscutibili in suo possesso sul tempo, e cioè sul fatto che il passato non è più, che il futuro non è ancora e che il presente è un continuo passaggio dal futuro al passato. Nessuna delle tre parti del tempo, dunque, *è*, nel senso di *essere stabile e attuale*: il passato *è già stato* e dunque *non è più*; il futuro *sarà* e dunque *non è ancora*, il presente *è* ma, in effetti, è solo il nome che diamo al *continuo passaggio* da una all'altra di queste non esistenze. Eppure, aggiunge Agostino, parliamo di un passato lontano e di un futuro prossimo; e, quando pensiamo al nostro presente, lo consideriamo in un arco di tempo (la giornata presente, l'anno attuale, etc.). Come riusciamo a farlo, cioè a 'misurare' cose che non esistono? Secondo Agostino, abbiamo la capacità di 'distendere' il nostro pensiero verso le cose che sono state e verso quelle che saranno; la prima operazione è il ricordo, la seconda è l'aspettativa. In mezzo, nel presente, c'è l'attenzione: lo sguardo che, istante per istante, vede le aspettative diventare ricordi. La coscienza umana è dunque un dispositivo che continuamente sintetizza tre dimensioni del tempo in un'unica esperienza vissuta. Sapere che stiamo provando *ora* qualcosa implica sempre, simultaneamente, sapere di aver *già* provato qualcosa e aspettarsi di provare *ancora* qualcosa. Siamo, in questo senso preciso, degli 'esseri temporali': non solo perché *stiamo nel* tempo, come una pietra *sta nella* corrente, ma perché siamo costitutivamente *fatti di* tempo; lo portiamo dentro, lo abitiamo, lo siamo. Anche gli LLM *ora* elaborano sequenze, memorizzano di aver *già* fatto conversazioni precedenti e anticipano la parola che *ancora* manca nel testo. Ma in nessuno di questi sistemi c'è una esperienza

del fatto che, per esempio, talvolta il passato pesa, che il futuro spesso fa paura o che il presente possa essere esaltante. Viviamo di ferite e gratificazioni a bassa intensità, quotidiane, costanti; ognuno di noi è un concentrato irripetibile di questa dinamica perché nessun individuo assomma la stessa sequenza di avvenimenti, emozioni, paure, gioie di un altro. In questo siamo sempre originali e creativi; perché ogni nostra parola o espressione nasce da un condensato di storie e aspettative unico.

Non so se, un giorno, sarà possibile simulare, riprodurre questa condizione. Parlare di tecnologie così potenti facendo previsioni a lunga gittata ha la stessa credibilità di chi afferma di avere metodi infallibili per vincere al lotto; qualcuno ci indovina pure ma solo per caso. Prospettare uno scenario futuro è, oggi, scommettere, con la prospettiva di diventare un grande precursore o di vedere le proprie righe invecchiare (male) in sei mesi. Credo che sia già abbastanza impegnativo leggere con attenzione il presente; per questo sul futuro desisto. Oggi viviamo in un contesto nel quale l'IA non ci imita biologicamente né come esseri coscienti; non ha una identità corporea né una storia emotiva, non ha un orizzonte di senso presente, non prova ansia per il futuro. Chiarire questo non ci serve per poter vantare un qualche motivo di superiorità degli esseri umani sulla IA, in una gara un po' patetica tra noi e macchine che abbiamo creato noi per imitare noi. È essenziale metterlo a fuoco perché solo così, recuperando in pieno la natura strumentale, imitativa, 'statistica', 'fantastica' della IA potremo essere liberi di usarla al meglio per quella che è oggi: un grande con-laboratore le cui risposte ci affascinano ma vanno diffuse con responsabilità e recepite con accortezza.

C'è un esperimento mentale che, in questo contesto, torna sorprendentemente attuale. Nel 1980 il filosofo americano John Searle pubblicò *Minds, Brains and Programs*, un articolo destinato a diventare uno dei *paper* più discussi della filosofia della mente del Novecento. L'argomento è semplice nella forma ma ricchissimo nelle implicazioni. Immaginiamo, dice Searle, una persona chiusa in una stanza. Dall'esterno le vengono passati, attraverso una fessura, dei foglietti con simboli cinesi. La persona non conosce il cinese; non sa nemmeno distinguere i simboli di quell'idioma da qualsiasi altro sistema di scrittura a lei sconosciuto. Ha però a disposizione un manuale dettagliatissimo che le spiega, nella sua lingua madre, come rispondere a ciascuna combinazione di simboli ricevendo altri simboli da restituire attraverso la stessa fessura. La persona segue le istruzioni, combina i simboli, restituisce le risposte. Chi è fuori dalla stanza, e conosce il cinese, riceve risposte perfettamente corrette e sensate. Dal punto di vista dell'osservatore esterno, chi è nella stanza 'capisce' il cinese; la persona dentro la stanza, invece, non ha capito nulla: ha solo seguito regole formali senza attribuire nessun significato a niente [37]. La 'stanza cinese' di Searle era una critica diretta all'idea che un sistema possa capire solo perché produce *output* linguisticamente corretti: saper combinare simboli secondo regole, diceva Searle, non equivale a comprenderne il significato. Decenni dopo, i grandi modelli linguistici sembrano la realizzazione tecnica di quella stanza. Un LLM riceve simboli (i *token*, i frammenti di testo), li combina secondo probabilità statistiche costruite su miliardi di esempi e restituisce *output* che a chi li riceve sembrano sensati, pertinenti, a volte persino profondi. Ma dentro la stanza non c'è nessuno che stia capendo. C'è un manuale di

proporzioni inimmaginabili (i parametri, i pesi, le connessioni, etc.) e c'è un meccanismo che lo consulta con velocità e precisione straordinarie. Nient'altro. Fin qui, Searle aveva ragione. Ma c'è un dettaglio che il suo esperimento lasciava fuori, forse perché all'epoca sembrava ovvio mentre oggi non lo è affatto. Lo abbiamo già detto parlando del mondo di *black box* umane che siamo e nel quale viviamo: anche noi, in un certo senso, siamo in una stanza. Anche noi riceviamo dall'esterno stimoli che non abbiamo scelto (parole, immagini, suoni, etc.), li elaboriamo attraverso strutture neurologiche che non vediamo e non controlliamo, e restituiamo *output*: risposte, gesti, decisioni, testi. Anche il nostro 'manuale' è costruito su miliardi di esempi, cioè sull'esperienza accumulata, sulla cultura assorbita, sulla lingua imparata, sui modelli comportamentali ereditati. Se guardiamo la nostra stanza dall'esterno, la struttura non è poi così diversa. La differenza è che nella stanza della nostra interiorità succedono anche altre cose. A volte fa caldo. A volte abbiamo paura. A volte ci annoiamo, o ci innamoriamo di un simbolo che passa, o ci spaventa pensare a quando il gioco finirà e non arriveranno più simboli. Usiamo i manuali ed elaboriamo i simboli mentre scorre una vita che sente, che ricorda, che anticipa, che teme. Non siamo solo un meccanismo di combinazione: siamo un meccanismo di combinazione che sa di esserlo.

Se non possiamo (e in buona parte non vogliamo) prevedere dove questa tecnologia ci porterà, possiamo però permetterci un augurio: che questa macchina costruita per imitarci ci aiuti a ricordarci cosa siamo, non come atto di autocompiacimento né come difesa risentita contro ciò che abbiamo creato ma come esercizio di attenzione, personale e sociale. Ricordarci che, ogni volta

che un LLM produce un testo che sembra scritto da qualcuno, manca sempre qualcosa: la sequenza casuale e irripetibile di incontri, delusioni, scoperte, perdite e fortune che ha reso quella persona capace di scrivere esattamente quelle parole in quel momento. Di dedicarle a qualcuno. Di firmarle o delegarle. Mancano la responsabilità e l'attesa; la stanza con il caldo e la paura. Manca il peso specifico di una vita. E una vita, per quanto ordinaria sembri a chi la vive, è sempre una combinazione che non si ripete perché il numero di variabili che concorrono a formare un'esperienza umana è talmente grande da rendere ogni individuo, di fatto, un *unicum*. Perché nessuno ha vissuto né vivrà mai esattamente quello che ho vissuto io. L'augurio, dunque, è questo: che il confronto con una tecnologia che ci imita così bene negli *output* ci renda più curiosi e più rispettosi dei processi di elaborazione e produzione di contenuti, i nostri e quelli degli altri. Che ci insegni a fare la domanda giusta non a ChatGPT ma alle persone intorno a noi: non 'cosa pensi?' ma 'cosa hai vissuto per pensare questo?'. Che ci ricordi che ascoltare qualcuno non è raccogliere informazioni ma entrare, almeno in parte, nella sua stanza. E che, in un'epoca in cui è tecnicamente possibile simulare quasi tutto, la cosa più preziosa che possiamo coltivare è proprio un tempo della cura da dedicare ai diritti e alla singolarità irriducibile di ogni esperienza umana: la nostra e quella di chiunque incontriamo.

Antologia

[1]

LEONE XIV, Lettera enciclica *Magnifica humanitas* sulla custodia della persona umana nel tempo dell'intelligenza artificiale, 15 maggio 2026, nn. 12, 14, ~~204~~90 (www.vatican.va).

"[...] edificare nel bene significa accettare il limite e la fragilità dell'umanità senza considerarli un errore da correggere. Oggi, il desiderio di pienezza dell'essere umano rischia di essere deviato verso mete ingannevoli: l'illusione di una tecnica che promette di liberarci da ogni fragilità o modelli di benessere che "lasciano indietro" interi popoli" (n. 12).

"Evitiamo parole che umiliano o contrappongono. Scegliamo la chiarezza che illumina e la franchezza che apre vie. Non benediciamo entusiasmi ingenui, non alimentiamo paure sterili" (n. 14).

"Siamo chiamati a interrogarci sul grande cantiere della nostra epoca: cosa stiamo costruendo?" (n. 90).

[2]

B. SINGLER, *Religion and Artificial Intelligence. An Introduction*, Routledge 2025, p. 157.

"We make AI a deity when we seek explanations for its often non-transparent actions and subtle influence on our lives. This language might also be explained as a religious adaptation to a post-AI world, where we adjust

our perception of AI to match the world it is shaping around us – making sense of the new world of fortuitous moments happening all around us because of technology".

[3]
G. RONCAGLIA, *L'architetto e l'oracolo. Forme digitali del sapere da Wikipedia a ChatGPT*, Laterza 2023, p. 40.
"I modelli di apprendimento di una rete neurale profonda sviluppano internamente rappresentazioni complesse dei dati, che possono essere difficili da comprendere o da esprimere in termini simbolici o logici, e sono quindi spesso considerate 'scatole nere'. È da questo punto di vista che il funzionamento di tali sistemi può essere visto come in qualche misura 'oracolare': il processo che porta alla produzione dell'*output* non è quasi mai esplicitabile o descrivibile secondo i paradigmi architettonici tradizionali".

[4]
W. J. ONG, *Oralità e scrittura. Le tecnologie della parola* (*Orality and Literacy. The Technologizing of the Word*, Routledge 1981), Il Mulino 2014.
(p. 23)
"Gli appartenenti alle culture orali primarie, cioè totalmente ignare della scrittura, imparano molto, posseggono e praticano una profonda saggezza, ma non «studiano». Essi imparano, non attraverso lo studio in senso stretto, ma mediante una sorta di apprendistato – andando a caccia con cacciatori esperti, per esempio – o come discepoli, ascoltando, ripetendo ciò che sentono, padroneggiando i proverbi e le loro combinazioni, assimilando altro materiale formulario, e infine partecipando ad una specie di esame corporativo".

(p. 26)
"Poiché in una cultura ad oralità primaria una conoscenza concettualizzata che non venga ripetuta ad alta voce svanisce presto, le società che su di essa si basano devono investire molta energia nel ripeter più volte ciò che è stato faticosamente imparato nel corso dei secoli. Questa esigenza crea una mentalità altamente tradizionalista e conservatrice che, a ragion veduta, inibisce la sperimentazione intellettuale. La conoscenza è preziosa ed è arduo raggiungerla, per cui la società tiene in gran considerazione i vecchi saggi che si specializzano nel conservarla, che conoscono e possono raccontare le storie dei giorni che furono. La scrittura, e ancora di più la stampa, immagazzinando la conoscenza al di fuori della mente, degradano invece l'immagine dei vecchi saggi, semplici ripetitori del passato, in favore di più giovani scopritori di cose nuove".

[5]
PLATONE, *Protagora*, 320d-321d (tr. it. a c. di F. Adorno, Laterza 1996, pp. 27-29).
"Tempo vi fu in cui esistevano gli dèi, ma non le stirpi mortali. Poi che giunse anche per le stirpi mortali il momento fatale della loro nascita, gli dèi ne fanno il calco in seno alla terra mescolando terra e fuoco e tutti quegli elementi che si compongono di terra e di fuoco. Ma nell'atto in cui stavano per trarre alla luce quelle stirpi, ordinarono a Prometeo ea Epimeteo di distribuire a ciascuno facoltà naturali in modo conveniente. Epimeteo chiede a Prometeo che spetti a lui la cura della distribuzione: «E quando avrò compiuto la mia distribuzione – dice – tu controllerai». E così, avendolo persuaso, si pone a distribuire. Ora, nel compiere la sua distribuzione, ad alcuni assegnava forza senza velocità, mentre forniva di velocità i più deboli; alcuni armava,

mentre per altri che rendeva per natura inermi, escogitava qualche altro mezzo di salvezza. A quegli esseri che rinchiudeva in un piccolo corpo, assegnava ali per fuggire o sotterranea dimora; quelli che, invece, dotava di grande dimensione, proprio con questo li salvaguardava. E così distribuiva tutto il resto, sì che tutto fosse in equilibrio. Ed escogitò tale principio preoccupandosi che una qualche stirpe non dovesse estinguersi. Dopo che li ebbe provvisti di mezzi per sfuggire le reciproche distruzioni, escogitò anche agevoli modi per proteggerli dalle intemperie delle stagioni di Zeus: li avvolse, così, di folti peli e di dure pelli, che bastavano a difendere dal freddo, ma che sono anche capaci di proteggere dal caldo e tali inoltre da essere adatti quali naturale e propria coperta a ciascuno, quando avessero bisogno di dormire. E sotto i piedi ad alcuni dette zoccoli, ad altri unghie e pelli dure prive di sangue; ad alcuni procurava un tipo di alimento, ad altri un altro tipo; ad alcuni erba della terra, ad altri frutti degli alberi, ad altri ancora radici; ad alcuni poi dette come cibo la carne di altri animali, ma a questi concesse scarsa prolificità, mentre a quelli che n'erano preda abbondante prolificità, sì che la specie loro si conservasse. Solo che Epimeteo, al quale mancava compiuta sapienza, aveva consumato, senza accorgersene, tutte le facoltà naturali in favore degli esseri privi di ragione: gli rimaneva ancora da dotare il genere umano e non sapeva davvero cosa fare per trarsi di imbarazzo. Proprio mentre si trovava in tale imbarazzo sopraggiunse Prometeo a controllare la distribuzione: vede che tutti gli altri esseri viventi armoniosamente posseggono di tutto, e che invece l'uomo è nudo, scalzo, privo di giaciglio e di armi: era oramai imminente il giorno fatale, giorno in cui anche l'uomo doveva uscire dalla terra alla luce. Prometeo allora, trovandosi appunto in grande imbarazzo per la salvezza dell'uomo, ruba a

Efesto e ad Atena il sapere tecnico, insieme con il fuoco – ché senza il fuoco sarebbe stato impossibile acquistarlo o servirsene – e così ne fece dono all'uomo".

[6]

G. W. LEIBNIZ, *Monadologia*, 17, Bompiani 2001, p. 65. "Immaginiamo una macchina strutturata in modo tale che sia capace di pensare, di sentire, di avere percezioni; supponiamola ora ingrandita, con le stesse proporzioni, in modo che vi si possa entrare come in un mulino. Fatto ciò, visitando la macchina al suo interno, troveremo sempre e soltanto pezzi che si spingono a vicenda, ma nulla che sia in grado di spiegare una percezione. Quindi la [ragione della] percezione va cercata nella sostanza semplice, non già nel Composto, cioè nella macchina".

[7]

J. R. FIRTH, *A synopsis of linguistic theory Studies in linguistic analysis*, Blackwell 1957, p. 11.

"The *placing* of a *text* as a constituent in a context of situation contributes to the statement of meaning since situations are set up to recognize *use*. As Wittgenstein says, 'the meaning of words lies in their use' (cfr. L. Wittgenstein, *Ricerche filosofiche*, 43) The day to day practice of playing language games recognizes customs and rules. It follows that a text in such established usage may contain sentences such as 'Don't be such an ass!', 'You silly ass!', 'What an ass he is!' In these examples, the word *ass* is in familiar and habitual company, commonly collocated with *you silly —*, *he is a silly —*, *don't be such an*. You shall know a word by the company it keeps! One of the meanings of *ass* is its habitual collocation with such other words as those above quoted. Though Wittgenstein was dealing with another problem, he also recognizes the plain face-value, the physiognomy of words. They look

at us! 'The sentence is composed of the words and that is enough'."

[8]

T. LUCREZIO CARO, *De rerum natura*, V, 607-627, trad. mia.

"Quando il nostro cavallo focoso si è fermato in mezzo al fiume e abbiamo guardato giù verso le rapide onde, il corpo del cavallo fermo sembra essere trascinato di traverso e spinto violentemente controcorrente; e ovunque volgiamo lo sguardo, tutto ci sembra scorrere e fluire allo stesso modo. Un colonnato, per quanto costruito con andamento uniforme e sorretto per tutta la sua lunghezza da colonne di uguale altezza, tuttavia, visto da un'estremità per tutta la sua lunghezza, si restringe a poco a poco nel profilo di un cono allungato, unendo il soffitto al suolo e ogni lato destro al sinistro, finché non raccoglie tutto nell'apice oscuro del cono. In mare, ai marinai, il sole che sorge dalle onde sembra tramontare di nuovo nelle onde e spegnervi la sua luce; e d'altronde essi non vedono altro che acqua e cielo".

[9]

PLATONE, *Sofista*, 235d-236c (tr. it. a c. di F. Fronterotta, Rizzoli 2008, pp. 297-301).

"STRANIERO – Proseguendo nell'applicazione della procedura della divisione, mi pare anche ora di distinguere due forme della tecnica imitativa: ma in quale delle due si trovi la specie che stiamo cercando, non credo per il momento di essere ancora in grado di capirlo.

TEETETO – Innanzitutto, comunque, parla e dividi per noi le due forme di cui hai detto.

STRANIERO – Una prima tecnica che io scorgo in essa è quella del copiare, che si ha soprattutto quando qualcuno, seguendo le proporzioni del modello in

lunghezza, larghezza e profondità, e attribuendo inoltre a ogni particolare i colori appropriati, dà origine a una copia.
TEETETO – Ma non sono forse tutti gli imitatori che tentano di far questo?
STRANIERO – Non quanti plasmano o dipingono oggetti grandi. Se infatti essi attribuiscono la reale proporzione alle cose ben fatte, sai bene che le parti superiori apparirebbero più piccole del dovuto e le parti inferiori, invece, più grandi, per via del fatto che noi vediamo le une da lontano e le altre da vicino.
TEETETO – È proprio così.
STRANIERO – Ma non è forse vero che gli artigiani di cui stiamo parlando lasciano da parte la verità, per riprodurre in immagine non le proporzioni reali, ma quelle che suscitano un'impressione appropriata?
TEETETO – Senza dubbio.
(…)
STRANIERO – Queste due erano quindi le specie della tecnica della produzione di immagini di cui dicevo, l'una che produce copie (ndr. *icastica*), l'altra apparenze (ndr. *fantastica*)".

[10]
ARISTOTELE, *Poetica*, 1448b9-20 (tr. it. a c. di M. Valgimigli, Mondadori 2008, p. 994).
"L'imitare è un istinto di natura comune a tutti gli uomini fin dalla fanciullezza; ed è anzi uno dei caratteri onde l'uomo si differenzia dagli altri esseri viventi in quanto egli è di tutti gli esseri viventi il più inclinato alla imitazione. Anche si noti che le sue prime conoscenze l'uomo le acquista per via di imitazione; e che dei prodotti dell'imitazione si dilettano tutti. Una prova di ciò che dico è quel che succede nella comune esperienza: poiché quelle cose medesime le quali in natura non possiamo

guardare senza disgusto, se invece le contempliamo nelle loro riproduzioni artistiche, massime se riprodotte il più realisticamente possibile, ci recano diletto; come per esempio le forme degli animali più spregevoli e dei cadaveri. E il motivo è questo, che l'apprendere non è solamente per i filosofi un piacere grandissimo, ma anche per gli altri uomini allo stesso modo; solo che gli altri uomini vi partecipano con minore intensità. Infatti il diletto che proviamo a vedere le immagini delle cose deriva appunto da ciò, che, attentamente guardando, ci interviene di scoprire e di riconoscere che cosa ogni immagine rappresenti, come se, per esempio [davanti a un ritratto, uno esclamasse:] Si, è proprio lui! Che se per avventura non si sia veduto prima, in natura, l'originale, non sarà certo l'immagine sua in quanto ne sia la fedele imitazione che ci recherà diletto, ma ci dileteranno l'esattezza dell'esecuzione, il colorito o qualche altra causa di simil genere".

ARISTOTELE, *Retorica*, 1371b4-10 (tr. it. a c. di A. Plebe, Mondadori 2008, p. 844).
"Siccome, poi, sono cose piacevoli l'imparare e l'ammirare, ne consegue che sono piacevoli anche le cose simili a queste: ad esempio l'imitare, come quello della pittura, della scultura, della poesia, e così tutto ciò che sia ben imitato, anche se imitato di per sé non sia piacevole; non è infatti per quest'oggetto che si gode, bensì perché si fa la deduzione che quell'imitazione corrisponde a quest'oggetto, cosicché risulta che s'impara qualcosa".

[11]
D. PREMACK - G. WOODRUFF, *Does the chimpanzee have a theory of mind?* In *Behavioral and Brain Sciences* 1978, 1/4, pp. 515-526, p. 525.
"In assuming that other individuals *want*, *think*, *believe*, and

the like, one infers states that are not directly observable and one uses these states anticipatorily, to predict the behavior of others as well as one's own. These inferences, which amount to a theory of mind, are, to our knowledge, universal in human adults. (...) The important point here is that assigning mental states to another individual is not a sophisticated or advanced act, but a *primitive* one. Only on two occasions are the inferences not found: when there is not enough understanding of the scene to permit the inference, as in the young, confused child, or when the inference indeed occurs, but is quite deliberately suppressed, as by a sophisticated adult who, having been taught the differences between data and inference, elects on this occasion to give what he calls an objective 'description'".

[12]

D. C. DENNETT, *The Intentional Stance,* The MIT Press, 1989, p. 40.

"Sometimes even the design stance is practically inaccessible, and then there is yet another stance or strategy one can adopt: the intentional stance. Here is how it works: first you decide to treat the object whose behavior is to be predicted as a rational agent; then you figure out what beliefs that agent ought to have, given its place in the world and its purpose. Then you figure out what desires it ought to have, on the same considerations, and finally you predict that this rational agent will act to further its goals in the light of its beliefs. [...] The strategy also works on birds, and on fish, and on reptiles, and on insects and spiders, and even on such lowly and unenterprising creatures as clams [...]. It also works on some artifacts: the chess-playing computer will not take your knight because it knows that there is a line of ensuing play that would lead to losing its rook, and it does

not want that to happen. More modestly, the thermostat will turn off the boiler as soon as it comes to believe the room has reached the desired temperature".

[13]
S. TURKLE, *Alone Together. Why We Expect More from Technology and Less from Each Other*, Basic Books 2011, pp. 5 e 76.
"We are lonely but fearful of intimacy. Digital connections and the sociable robot may offer the illusion of companionship without the demands of friendship"
"Miriam sits quietly, stroking Paro, a sociable robot in the shape of a baby harp seal. [...] On this day, she is particularly depressed and believes that the robot is depressed as well. She turns to Paro, strokes him again, and says, "Yes, you're sad, aren't you? It's tough out there. Yes, it's hard". [...] In attempting to provide the comfort she believes it needs, she comforts herself. [...] Miriam experienced an intimacy with another, but she was in fact alone".

[14]
D. CHALMERS, *Facing Up to the Problem of Consciousness*, in *Journal of Consciousness Studies*, 1995, 2/3, pp. 200-219, p. 201.
"The really hard problem of consciousness is the problem of experience. When we think and perceive, there is a whir of information-processing, but there is also a subjective aspect. As Nagel has put it, there is something it is like to be a conscious organism. This subjective aspect is experience. When we see, for example, we experience visual sensations: the felt quality of redness, the experience of dark and light, the quality of depth in a visual field. Other experiences go along with perception in different modalities: the sound of a clarinet,

the smell of mothballs. Then there are bodily sensations, from pains to orgasms; mental images that are conjured up internally; the felt quality of emotion, and the experience of a stream of conscious thought. What unites all of these states is that there is something it is like to be in them. All of them are states of experience. It is undeniable that some organisms are subjects of experience. But the question of how it is that these systems are subjects of experience is perplexing. Why is it that when our cognitive systems engage in visual and auditory information-processing, we have visual or auditory experience: the quality of deep blue, the sensation of middle C? How can we explain why there is something it is like to entertain a mental image, or to experience an emotion? It is widely agreed that experience arises from a physical basis, but we have no good explanation of why and how it so arises. Why should physical processing give rise to a rich inner life at all? It seems objectively unreasonable that it should, and yet it does".

[15]

U. ECO, *Trattato di semiotica generale*, 0.1.3, Bompiani 1993, p. 10.

"Il progetto di una disciplina che studia l'insieme della cultura, risolvendo in segni una immensa varietà di oggetti e di eventi, può dare l'impressione di un arrogante 'imperialismo' semiotico. Quando una disciplina definisce come proprio oggetto 'ogni cosa' e quindi si ritiene in diritto di definire attraverso i propri apparati categoriali l'intero universo, il rischio è senz'altro grave. L'obbiezione più comune rivolta al semiologo 'imperialista' è: 'se per te anche una mela è un segno, certo la semiotica si occupa anche della cotognata – ma allora il gioco non vale più'. Quello che questo libro

vorrebbe dimostrare, attingendo le proprie pezze d'appoggio o i propri titoli di nobiltà alla più venerabile tradizione filosofica, è che dal punto di vista semiotico non vi è alcuna differenza tra una mela e una marmellata di mele, da un lato, e le espressioni linguistiche |mela| e |marmellata di mele| dall'altro. La semiotica ha a che fare con qualsiasi cosa possa essere ASSUNTA come segno. È segno ogni cosa che possa essere assunto come un sostituto significante di qualcosa d'altro. Questo qualcosa d'altro non deve necessariamente esistere, né deve sussistere di fatto nel momento in cui il segno sta in luogo di esso. In tal senso la semiotica, in principio, è la disciplina che studia tutto ciò che può essere usato per mentire. Se qualcosa non può essere usato per mentire, allora non può neppure essere usato per dire la verità: di fatto non può essere usato per dire nulla. La definizione di 'teoria della menzogna' potrebbe rappresentare un programma soddisfacente per una semiotica generale".

[16]

AGOSTINO, *Il maestro* (*De magistro*), tr. it. a c. di A. Bisogno, *Il maestro*, Città Nuova 2014.
(3, 5-6, p. 43)

"ADEODATO - Non solo io, ma nemmeno un attore con la sua pantomima potrebbe mostrarti senza usar parole di cosa sia segno quella preposizione 'ex' (*fuori da*).
AGOSTINO - Forse dici il vero; ma ammettiamo che possa farlo: non dubiti, come credo, che qualsiasi fosse il movimento corporeo con il quale tenterebbe di mostrarmi la cosa della quale questa parola è segno, non ci sarebbe la cosa stessa, ma un segno. Perciò costui anche se non indicherà una parola con una parola, tuttavia indicherà perlomeno un segno con un segno, in modo che questo monosillabo 'ex' e quel gesto siano segni di un'unica cosa che io vorrei mi venisse mostrata

senza usar segni.

(…)

AGOSTINO - Se, non sapendo nulla del valore di questa parola, chiedessi a te che cammini cosa sia 'camminare', in che modo me lo insegneresti?
ADEODATO - Farei la stessa cosa molto più velocemente di modo che, dopo la tua domanda, tu sia stimolato da una certa novità e tuttavia non sarebbe successo altro che quello che doveva esser mostrato.
AGOSTINO - Non sai forse che altro è 'camminare' e altro è 'affrettarsi'? Infatti chi cammina non si affretta e chi si affretta non per questo necessariamente cammina; parliamo infatti di affrettarsi anche nello scrivere o nel leggere o in altre innumerevoli attività. Perciò quando tu cominciassi, dopo la mia domanda, a fare più velocemente quello che facevi prima, penserei che camminare non è altro che affrettarsi – è questo infatti che aggiungeresti di nuovo – e in ciò sbaglierei.
ADEODATO - Ammetto che non possiamo mostrare una cosa senza un segno se veniamo interrogati mentre la facciamo; se infatti non aggiungiamo niente, chi ce lo chiede penserà che non vogliamo mostrarglielo e che con indifferenza nei suoi confronti continuiamo a fare quel che facevamo prima. Ma se chiedesse di cose che possiamo fare ma non le chiedesse mentre le stiamo facendo, potremmo, facendole dopo la sua domanda, mostrargli ciò che chiede con la cosa stessa piuttosto che con un segno, a meno che non mi interroghi, mentre parlo, su che cosa sia il parlare; qualsiasi cosa infatti dicessi per insegnarglielo sarebbe necessario che io parlassi. Dal che senza timore gli insegnerei fino a che non gli fosse chiaro quel che vuole, senza fermarmi nel fare quella cosa che ha voluto gli venisse mostrata, né cercando segni con i quali mostrarla al di là della sua

stessa evidenza".

(10, 34, p. 80)
"AGOSTINO - Immagina che ora noi per la prima volta sentiamo ciò che si dice 'capo' e non sapendo se questa espressione vocale sia soltanto un suono o sia anche segno di qualcosa, chiediamo cosa sia il capo (...). Se dunque, a noi che cerchiamo, la cosa stessa venisse mostrata con il dito, una volta vista impareremmo il segno, che avevamo soltanto sentito e non ancora conosciuto. (...) Perciò attraverso l'indicare con il dito non posso conoscere la cosa, che ho conosciuto, né il segno, perché non è nei suoi confronti l'indicare del dito. Ma dell'indicare con il dito non mi preoccupo troppo perché mi sembra segno della stessa operazione del mostrare piuttosto che delle altre cose, che vengono mostrate".

[17]
BERENGARIO DI TOURS, *Rescriptum contra Lanfrannum* (*De sacra coena*), ed. W. H. Beekenkamp, Nijhoff 1941, p. 47, trad. mia.
"È proprio di un animo grandissimo ricorrere in ogni cosa alla dialettica, perché ricorrere a essa è ricorrere alla ragione; e chi non vi ricorre, essendo stato fatto a immagine di Dio secondo la ragione, abbandona il proprio onore e non può rinnovarsi di giorno in giorno a immagine di Dio".

[18]
D. AMODEI, *We Must Pace the Frontier*, settembre 2026 (www.darioamodei.com/post/we-must-pace-the-frontier).
"I believe that AI could cure most major diseases in the next 5–10 years, greatly accelerate economic growth rates, create a world of abundance and empowerment,

and usher in a renaissance of democracy and freedom. [...] We must slow the pace at which we improve the capabilities of AI models. Progress will still seem fast, and we must make wise use of the time we gain. [...] To be clear, pacing does not mean halting model training or technical progress, but ensuring companies take adequate time to align and safeguard their models, and for third party evaluators to confirm this".

[19]

T. W. DEACON, *La specie simbolica: coevoluzione di linguaggio e cervello* (*The Symbolic Species: The Co-evolution of Language and the Brain*, W.W. Norton & Co 1997), Giovanni Fioriti 2001, pp. 3-4.

"Noi condividiamo la Terra con milioni di tipi di creature viventi, ma siamo anche abitanti di un mondo inaccessibile a ogni altra specie: un mondo ricco di astrazioni, di cose impossibili, paradossi. Noi, unici, abbiamo dato vita a cose mai avvenute, e solo noi trascorriamo buona parte del giorno cogitando su come le cose avrebbero potuto essere se gli eventi avessero cospirato altrimenti. (...) Raccontiamo storie sulle nostre esperienze reali e ne inventiamo di immaginarie, e addirittura ce ne serviamo per dare un senso alla nostra vita. Viviamo, nel senso più pieno del termine, la nostra esistenza in questo mondo virtuale comune. (…) La porta di accesso a questo mondo virtuale l'ha schiusa per noi in esclusiva l'evoluzione di questa facoltà. Una facoltà che non è infatti un semplice modo per comunicare, ma è la traduzione all'esterno di un modo insolito di pensare: la rappresentazione simbolica".

[20]

J. GLEICK, *L'informazione. Una storia, una teoria, un diluvio* (*The Information: A History, A Theory, A Flood*, Pantheon

Books 2011), 2, Feltrinelli 2015, p. 50.
"La scrittura è nata per conservare le informazioni nel tempo e nello spazio. Prima della scrittura, la comunicazione era effimera e locale; i suoni si propagavano per pochi metri e poi sfumavano nell'oblio. [...] 'Il simbolo parlato', come osservava Samuel Butler, 'muore immediatamente senza lasciare traccia, e se in qualche modo vive, lo fa solo nelle menti di quanti l'hanno sentito'. [...] Butler completava la distinzione: 'Il simbolo scritto estende all'infinito, rispetto al tempo e allo spazio, le condizioni entro le quali una mente può comunicare con un'altra; alla mente di chi scrive dà una vita limitata dalla durata di inchiostro, carta e lettori, anziché da quella del suo corpo di carne e sangue' ".

[21]
L. FLORIDI, *On why publishing (series: notes to myself)*, *Medium*, 8 dicembre 2023.
"By committing your thoughts to some external support, by "self-publishing" without minding whether reading will follow, you reify your thoughts and make them external, and enable more thoughts to develop, building these new thoughts on the calcified ones now in the world [...] Publishing as 'self-publishing' is also about liberating oneself from the mental pressure of thoughts that have become unbearable. [...] Your thoughts may be dead to you, external compost for more internal thoughts, no matter whether they may be alive to others, should they ever wish to welcome them".

[22]
Regolamento (UE) 2024/1689 del Parlamento europeo e del Consiglio del 13 giugno 2024 che stabilisce regole armonizzate sull'intelligenza artificiale (*AI Act*), art. 50, par. 2.

"I fornitori di sistemi di IA, compresi i sistemi di IA per finalità generali, che generano contenuti audio, immagine, video o testuali sintetici, garantiscono che gli output del sistema di IA siano marcati in un formato leggibile meccanicamente e rilevabili come generati o manipolati artificialmente. I fornitori garantiscono che le loro soluzioni tecniche siano efficaci, interoperabili, solide e affidabili nella misura in cui ciò sia tecnicamente possibile".

[23]
R. Gaito, A. Bisogno, *Verificare se un testo è umano è inutile*, podcast *What's Next*, settembre 2026 (youtu.be/4VpAuIZK5Rg); cfr. R. Gaito, *La ridicola (e pericolosa) caccia alle streghe verso chi usa l'IA*, agosto 2026 (youtu.be/6VnKuQIhsGw).

[24]
R. BARTHES, *La camera chiara. Nota sulla fotografia* (*La chambre claire. Note sur la photographie*, Gallimard 1980), Einaudi 1980, pp. 77-79.
"Chiamo 'referente fotografico', non già la cosa facoltativamente reale a cui rimanda un'immagine o un segno, bensì la cosa necessariamente reale che è stata posta dinanzi all'obbiettivo, senza cui non vi sarebbe fotografia alcuna. La pittura, dal canto suo, può simulare la realtà senza averla vista. Il discorso combina segni che hanno certamente dei referenti, solo che tali referenti possono essere e sono il più delle volte delle 'chimere'. Nella Fotografia, contrariamente a quanto è per tali imitazioni, io non posso mai negare che la cosa è stata là. Vi è una doppia posizione congiunta: di realtà e di passato. E siccome tale costrizione non esiste che per essa, la si deve considerare, per riduzione, come l'essenza stessa, come il noema della Fotografia. Il nome del

noema della Fotografia sarà quindi: 'È stato', o anche: l'Intrattabile. [...] La foto è letteralmente un'emanazione del referente. Da un corpo reale, che era là, sono partiti dei raggi che raggiungono me, che sono qui; la durata dell'emissione ha poca importanza; la foto dell'essere scomparso viene a toccarmi come i raggi differiti di una stella. Una specie di cordone ombelicale collega il corpo della cosa fotografata al mio sguardo: benché impalpabile, la luce è qui effettivamente un nucleo carnale, una pelle che io condivido con colui o colei che è stato fotografato".

[25]

D. KAHNEMAN, *Pensieri lenti e veloci* (*Thinking, Fast and Slow*, Farrar, Straus and Giroux 2011), Mondadori 2017, p. 30.

"Il Sistema 1 e il Sistema 2 sono entrambi attivi quando siamo svegli. Il primo funziona in maniera automatica, mentre il secondo è di norma in una comoda modalità di minimo sforzo in cui solo una piccola percentuale della sua capacità viene utilizzata. Il primo produce continuamente spunti per il secondo: impressioni, intuizioni, intenzioni e sensazioni. Se corroborate dal Sistema 2, le impressioni e le intuizioni si trasformano in credenze e gli impulsi si convertono in azioni volontarie. Quando tutto procede liscio, come accade per la maggior parte del tempo, il Sistema 2 adotta i suggerimenti del sistema 1 senza praticamente modificarli. (...) In sostanza, la maggior parte di quello che noi (il nostro Sistema 2) pensiamo e facciamo origina dal Sistema 1, ma il Sistema 2 prende il sopravvento quando le cose si fanno difficili e di norma ha l'ultima parola. La divisione del lavoro tra Sistema 1 e Sistema 2 è assai efficiente, in quanto riduce al minimo lo sforzo e ottimizza il rendimento. (...) Il Sistema 1 è però soggetto a *bias*, a errori sistematici che

tende a commettere in circostanze specifiche. (...) Un suo ulteriore limite è che non lo si può spegnere".

[26]

M. A. BODEN, *The Creative Mind: Myths and Mechanisms*, Routledge 2004, pp. 3-6.

"Creativity can happen in three main ways, which correspond to the three sorts of surprise. The first involves making unfamiliar combinations of familiar ideas. Examples include poetic imagery, collage in painting or textile art, and analogies. [...] In all these cases, making – and also appreciating – the novel combination requires a rich store of knowledge in the person's mind, and many different ways of moving around within it. [...] The other two types of creativity are interestingly different from the first. They involve the exploration, and in the most surprising cases the transformation, of conceptual spaces in people's minds. Conceptual spaces are structured styles of thought. [...] Whatever the size of the space, someone who comes up with a new idea within that thinking style is being creative in the second, exploratory, sense. [...] The deepest cases of creativity involve someone's thinking something which, with respect to the conceptual spaces in their minds, they couldn't have thought before. The supposedly impossible idea can come about only if the creator changes the pre-existing style in some way. It must be tweaked, or even radically transformed, so that thoughts are now possible which previously (within the untransformed space) were literally inconceivable".

[27]

W. BENJAMIN, *L'opera d'arte nell'epoca della sua riproducibilità tecnica* (prima ed. in francese: «Zeitschrift für Sozialforschung», 1936), Einaudi 2013 (edizione con le

tre versioni) 2013, pp. 9-11 *(seconda versione tedesca).*
"Anche alla più perfetta riproduzione di un'opera d'arte fa sempre difetto un fattore: il suo *hic et nunc*, la sua esistenza unica nel luogo in cui essa si trova. [...] L'*hic et nunc* dell'originale forma il contenuto della nozione di autenticità, e su quest'ultima si basa la rappresentazione di una tradizione che ha trasmesso sino ai giorni nostri questo oggetto come qualcosa che rimane identico a se stesso. I componenti dell'autenticità si negano ad ogni riproduzione, non soltanto alla riproduzione meccanizzata. [...] Potremmo riunire tutti questi indizi nella nozione di aura e dire: ciò che nell'opera d'arte deperisce nell'epoca della riproduzione meccanizzata è la sua aura. [...] Cos'è insomma l'aura? Una singolare trama di tempo e spazio: l'apparizione unica di una lontananza, per quanto prossima essa sia. [...] Sottrarre l'oggetto al suo alone, distruggendone l'aura, è segno di una percezione il cui 'senso per ciò che nel mondo è somigliante' si vede a tal punto intensificato che, mediante la riproduzione, arriva a standardizzare ciò che è unico".

[28]
M. T. CICERONE, *Academica Priora* (*Lucullus*), 100-101, trad. mia.
"Il saggio che si imbarca su una nave possiede forse nella sua mente la conoscenza certa e acquisita che il viaggio andrà come intende? Come potrebbe? Ma se dovesse partire da questo posto per Pozzuoli (trenta stadi di distanza) con una nave affidabile, un buon timoniere e con questa bonaccia, sembrerebbe probabile che vi giungerà sano e salvo. Seguendo impressioni di questo tipo prenderà quindi le sue decisioni su cosa fare e cosa non fare (…). E qualunque cosa lo colpisca in modo tale che quell'impressione risulti probabile e non ostacolata

da nulla, egli si muoverà ad agire".

[29]
C. KOMMERS, S. G. IMMEL, D. HEMMENT, M. LEE, *The House with a Million Windows: Interactive Fiction for Narrative Restorying*, arXiv:2609.12537, 2026.
"AI-assisted writing can flatten meaning in human storytelling, enabling the production of homogeneous outputs without the intentional effort and sense-making writing entails. [...] In HWAMW, users play through a text-based narrative in which they tell a story, then encounter a set of LLM-generated "windows" reframing it according to different literary styles".

[30]
R. SOLÉ, G. RUFFINI, F. CASTALDO, M. TUCCIO, L. F. SEOANE, M. DE DOMENICO, S. F. ELENA, D. C. KRAKAUER, M. LEVIN, *Large-Language Models as a Cognitive Virus*, arXiv:2609.03344, 2026.
"It is therefore useful to distinguish between scaffolding and substitution. Scaffolding reduces immediate cognitive demands while preserving or increasing the user's subsequent capacity to perform the task; substitution removes the need to perform the underlying cognitive operation. [...] The relevant distinction is therefore not simply between using and avoiding LLMs, but between forms of coupling and, ultimately, what cognitive capacities remain when the tool is withdrawn. [...] Thus, after the tipping point has been crossed, reversal requires a larger reduction in transmission pressure than would have been required to prevent the transition in the first place".

[31]
AGOSTINO, *Confessioni* (*Confessiones*, 397-401/403), VIII, 5, 10, tr. mia.

"Infatti dalla volontà pervertita era nata la passione; e, a forza di servire la passione, era diventata abitudine; e, non opponendo resistenza all'abitudine, era nata la necessità. Questi erano come anelli intrecciati l'uno con l'altro, e per questo li ho chiamati 'catena'. Con essa mi teneva avvinto una dura schiavitù. La volontà nuova che aveva cominciato a nascere in me […] non era ancora in grado di vincere la prima, rafforzata dal lungo tempo".

[32]

Platone, *Fedro*, 274c-275b (tr. it. a c. di G. Reale, Bompiani 2000, pp. 195-197).

"Ho udito, dunque, narrare che presso Naucrati d'Egitto c'era uno degli antichi dèi di quel luogo, al quale era sacro l'uccello che chiamano Ibis, e il nome di questo dio era Theuth. Dicono che per primo egli abbia scoperto i numeri, il calcolo, la geometria e l'astronomia e poi il gioco del tavoliere e dei dadi e, infine, anche la scrittura. Re di tutto quanto l'Egitto a quel tempo era Thamus e abitava nella grande città dell'Alto Nilo. Gli Elleni la chiamano Tebe Egizia, mentre chiamano Ammone il suo dio. E Theuth andò da Thamus, gli mostrò queste arti e gli disse che bisognava insegnarle a tutti gli Egizi. E il re gli domandò quale fosse l'utilità di ciascuna di quelle arti, e, mentre il dio gliela spiegava, a seconda che gli sembrasse che dicesse bene o non bene, disapprovava oppure lodava. [...] Ma quando si giunse alla scrittura, Theuth disse: «Questa conoscenza, o re, renderà gli Egiziani più sapienti e più capaci di ricordare, perché con essa si è ritrovato il farmaco della memoria e della sapienza». E il re rispose: «Ingegnosissimo Theuth, c'è chi è capace di creare le arti e chi è invece capace di giudicare quale danno o quale vantaggio ne ricaveranno coloro che le adopereranno. Ora tu, essendo padre della scrittura, per affetto hai detto proprio il contrario di quello che essa

vale. Infatti, la scoperta della scrittura avrà per effetto di produrre la dimenticanza nelle anime di coloro che la impareranno (ndr. per mancanza di esercizio della memoria: mnēmēs amelētēsiai), perché, fidandosi della scrittura, si abitueranno a ricordare dal di fuori mediante segni estranei, e non dal di dentro e da se medesimi: dunque, tu hai trovato non il farmaco della memoria, ma del richiamare alla memoria. Della sapienza, poi, tu procuri ai tuoi discepoli l'apparenza, non la verità: infatti essi, divenendo per mezzo tuo uditori di molte cose senza insegnamento, crederanno di essere conoscitori di molte cose, mentre, come accade per lo più, in realtà, non le sapranno; e sarà ben difficile discorrere con essi, perché sono diventati conoscitori di opinioni invece che sapienti»".

[33]

H. SMALL, *The Value of the Humanities*, Oxford University Press, Oxford 2013, p. 4.

"The meaning-making practices of human culture, past and present, focusing on interpretation and critical evaluation, primarily in terms of the individual response and with an ineliminable element of subjectivity".

[34]

D. DEMELAS, *Responsible AI and the Middle Ages: Detecting Historical Toxicity in Medieval Datasets*, in «Digital Humanities Quarterly», 20/3 (2026).

"European medieval literature contains, among other things, virulent Islamophobic and antisemitic rhetoric and calls for assaulting and mass-murdering non-Christians. Nineteenth-century scientific texts propagate theories of biological racism. Colonial documents normalise slavery and genocide and defend European supremacy over other populations. [...] These datasets capture contemporary expressions of toxicity but fail to

recognize historical forms of hate speech, particularly when expressed in formal or literary language. This is why medieval poetry and philosophical treatises pose a distinctive problem for automated detection: their discriminatory content is encoded through epic lines, theological argument, and chivalric convention rather than through the direct, informal slurs on which the models were trained [...]. "Tous furent occis ou faits chrétiens" (All were killed or made Christians) scores below 0.02 in every category".

[35]

P. SMART, R. CLOWES, J. KRUEGER, M. BONIFACE, *The Story of Your Life: Large Language Models and Personal Memory*, in «Review of Philosophy and Psychology», 2026 (DOI 10.1007/s13164-026-00831-1), pp. 17-20.

"Constructivist theories hold that remembering involves the active reconstruction of past events from fragmentary traces, background schemas, and current goals. Because this process relies on inference rather than literal replay, errors and distortions are a recurring—and perhaps unavoidable—aspect of human memory. As Bernstein and Loftus (2009, p. 373) note, "In essence, all memory is false to some degree. [...]"" (p. 17).

"[...] autobiographical remembering is governed by a dynamic tension between adaptive correspondence (the accurate retention of previously encountered information) and self-coherence (the maintenance of a meaningful and temporally integrated sense of self). In many cases, they suggest, the system privileges coherence: thematic elaborations, reinterpretations, and selective omissions that help sustain a stable and intelligible personal identity. [...] If human autobiographical memory routinely sacrifices accuracy in favor of coherence, continuity, and psychological well-

being, then it is at least plausible that some LLM hallucinations might play a similar role in the context of a personal memory system" (p. 18).

"In this sense, an LLM is not simply an entity that helps you navigate the past; it is also the co-creator of a shared autobiography. A co-narrator, perhaps, of the story of you" (p. 20).

[36]

V. RAO, *Superhistory, Not Superintelligence. Artificial Intelligence is really Artificial Time*, in «Contraptions», 11 maggio 2021 (contraptions.venkateshrao.com).

"Magnus Carlsen is a latent centaur [...]. So perhaps by virtue of growing up playing against chess programs on computers, Magnus Carlsen is really 200 years old. [...] This is not like belonging to an intellectual tradition, with a lineage of masters passing on their knowledge and skills through books and teaching. That process of cultural transmission is limited by the individual-human-mind bottlenecks it must periodically pass through. [...] Augmenting humans with machine learning in the right way raises their effective experiential age. They possess greater "lived experience" than their biological age would suggest because they've acquired prosthetic experience, in digested, summary form. [...] I made up my numbers earlier obviously, for rhetorical effect. [...] human lives are mostly informationally empty time [...]. In many ways, I feel older than my father, who is 83. [...] I am not smarter than him. I've just data-aged more than him".

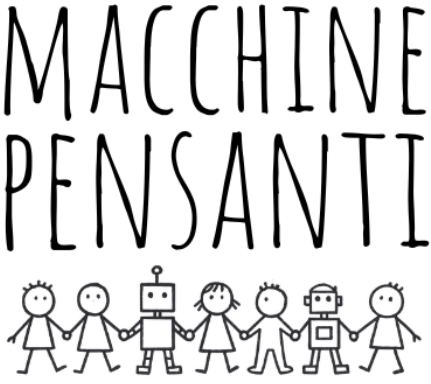
[37]

J. R. SEARLE, *Minds, Brains, and Programs*, in *Behavioral and Brain Sciences,* 1980, 3/3, pp. 417-424.

"Suppose that I'm locked in a room and given a large batch of Chinese writing. Suppose furthermore that I

know no Chinese, either written or spoken, and that I'm not even confident that I could recognize Chinese writing as Chinese writing distinct from, say, Japanese writing or meaningless squiggles. To me, Chinese writing is just so many meaningless squiggles. (...) The people who are giving me all of these symbols call the first batch 'a script' they call the second batch a 'story' and they call the third batch 'questions'. Furthermore, they call the symbols I give them back in response to the third batch 'answers to the questions', and the set of rules in English that they gave me, they call 'the program'. (...) From the external point of view (...) my answers to the questions are absolutely indistinguishable from those of native Chinese speakers. Nobody just looking at my answers can tell that I don't speak a word of Chinese. (...). I do not understand a word of the Chinese stories. I have inputs and outputs that are indistinguishable from those of the native Chinese speaker, and I can have any formal program you like, but I still understand nothing".

Leggi **la mia newsletter**
dedicata alla IA (e non solo)



Scarica gratuitamente
il mio libro sulle discipline umanistiche come esercizio di responsabilità

